



Psychometrische Diagnostik

MSc Psychologie

MSc Umweltpsychologie / Mensch-Technik-Interaktion

SoSe 2026

Prof. Dr. Dirk Ostwald

(2) Item-Response-Theorie

Grundlagen

Birnbaum-Modell

Rasch-Modell

Selbstkontrollfragen


Grundlagen

Birnbaum-Modell


Rasch-Modell

Selbstkontrollfragen

Psychologische Datenwissenschaft



Psychologische Datenwissenschaft



Item-Response-Theorien

Probabilistische Modelle für die funktionalen Beziehungen zwischen

- latenten Personeneigenschaften,
- Itemparametern und
- Itemantwortwahrscheinlichkeiten

Typische latente Personeneigenschaften sind dabei

- Fähigkeiten in der Leistungsmessung
- Einstellungen in der Persönlichkeitsmessung

Typische Itemparameter sind dabei

- Schwierigkeit, Diskriminationsfähigkeit, Ratewahrscheinlichkeit

Item-Response-Theorien bilden eine große Modellfamilie

- Von eindimensionalen Personeneigenschaften zu mehrdimensionalen Personeneigenschaften
- Von dichotomen Items zu polytomen Items
- Wir betrachten hier nur eindimensionale Personeneigenschaften und dichotome Items
- Dichotome Items werden hier als binär ausgewertete Items verstanden

Weite Verbreitung in Bildungsforschung (PISA, GRE), Medizin (PROMIS), Psychometrie und Sozialwissenschaften

Theoretische Grundlage für adaptive Testverfahren mit interaktiver Itemauswahl

Eine grundlegende Einführung gibt das dreibändige *Handbook of Item Response Theory* von Linden (2016)

Traditionen

Frühe Ansätze von Item-Response-Theorien unter anderem bei Binet & Simon (1904)

Statistische Tradition

- Datenanalytisch geprägter Ansatz nach Mosier (1940), Richardson (1936), Lawley (1943), Lord (1951)
- Seminale Arbeiten von Allan Birnbaum (1923 - 1976) in Lord & Novick (1968) (vgl. auch Birnbaum (1962))
- 1PL-, 2PL- und 3PL-Modelle als Weiterentwicklung des Normal-Ogive-Modells
- Marginal-Maximum-Likelihood / Expectation-Maximization
- Frühe Implementationen in Programmen wie LOGIST, BILOG-MG, TESTFACT, MULTILOG
- Recht klar im datenanalytischen Mainstream verortet

Messtheoretische Tradition

- Axiomatisch geprägter europäischer Ansatz nach Georg Rasch (1901–1980) (Rasch (1960), Rasch (1966))
- Seminale Arbeiten von Erling Bernhard Andersen (1939-2004) in Andersen (1970) und Andersen (1977)
- Popularisierung in den USA unter anderem durch Wright (1977) und Andrich (1978)
- Europäische Weiterführung durch Fischer (1938 -) und Molenaar (1935-2018) (vgl. Fischer (1995))
- Conditional-Maximum-Likelihood / Suffizienz
- Frühe Implementation in Programmen wie WinSteps, ConQuest, RUMM
- Nicht im datenanalytischen Mainstream verortet, aber bei psychologischen Anwendern populär

vgl. Embretson & Reise (2000)

Anwendungsbeispiel

Simulierter Datensatz basierend auf den 10 dichotomen Items

	I1	I2	I3	I4	I5	I6	I7	I8	I9	I10
P 1	1	1	1	1	1	0	0	0	0	1
P 2	1	1	1	0	1	1	1	0	0	1
P 3	1	1	0	1	1	0	0	0	0	1
P 4	1	1	1	1	1	0	1	0	1	1
P 5	1	1	1	1	0	0	0	0	0	1
P 6	1	1	1	0	1	1	1	0	0	1
P 7	1	1	1	0	1	1	1	0	0	1
P 8	1	1	1	1	1	1	0	0	1	1
P 9	1	1	1	0	1	1	1	0	0	1
P 10	1	1	1	1	0	0	0	0	1	1
P 11	1	0	1	1	1	1	1	0	0	1
P 12	1	0	1	1	1	0	1	0	0	1
P 13	1	1	1	0	1	1	1	0	0	1
P 14	1	1	1	0	0	1	1	0	1	1
P 15	1	1	1	0	1	1	1	0	1	1
P 16	1	1	1	1	0	1	1	0	1	1
P 17	1	1	1	0	1	0	1	0	0	1
P 18	1	1	1	0	0	1	0	0	1	1
P 19	1	0	1	0	0	1	1	0	0	1
P 20	1	1	1	1	1	1	1	0	1	1

$n = 20$ von $n = 1000$ Personen, keine KA-Antworten

Überblick

Birnbaum-Modell

- Logistische Funktion
- Modellformulierung
- Modelleigenschaften
- Marginal-Maximum-Likelihood-Schätzung durch ELBO-Maximierung
- Expectation-Maximization-Algorithmus nach Woodruff (1996) und Bock & Aitkin (1981)

Rasch-Modell

- Objektive Messungen und spezifische Objektivität
- Modellformulierung
- Modelleigenschaften
- Conditional-Maximum-Likelihood-Schätzung
- Suffizienz und Parameterseparierbarkeit

Grundlagen

Birnbaum-Modell

Rasch-Modell

Selbstkontrollfragen

Definition (Logistische Funktion)

Die Funktion

$$f : \mathbb{R} \rightarrow]0, 1[, x \mapsto f(x) := \frac{1}{1 + \exp(-a(x - b))} \text{ mit } a, b \in \mathbb{R} \quad (1)$$

heißt *logistische Funktion*.



Bemerkungen

- Die logistische Funktion geht auf Verhulst (1845) zurück und findet breite mathematische Anwendung.
- Sie wird zur Modellierung von Wachstumsprozessen, Kondensatorladung, Pharmakokinetik u.v.a.m genutzt.
- Verwendung findet sie auch in der Logistischen Regression, dem Deep Learning und im Reinforcement Learning.
- Wir betrachten im Folgenden immer den Fall einer ansteigenden logistischen Funktion mit $a > 0$.
- Die **R** Funktion `plogis()` implementiert die *logistische Standardfunktion*

$$h : \mathbb{R} \rightarrow]0, 1[, x \mapsto h(x) := \frac{1}{1 + \exp(-x)} \quad (2)$$

- Formal ist `plogis` dabei die KVF der *logistischen Verteilung*.
- Es gilt also insbesondere $h(a(x - b)) = f(x)$.
- Die logistische Funktion ist die zentrale Komponente von Birnbaum- und Rasch-Modell.

Logistische Funktion



⇒ b verschiebt die logistische Funktion bezüglich der x -Achse, a moduliert ihre Steigung

Theorem (Eigenschaften der logistischen Funktion)

Für $a > 0, b \in \mathbb{R}$ sei

$$f: \mathbb{R} \rightarrow]0, 1[, x \mapsto f(x) := \frac{1}{1 + \exp(-a(x - b))} \quad (3)$$

die *logistische Funktion*. Dann gelten

(1) $f(x) \rightarrow 0$ für $x \rightarrow -\infty$ und $f(x) \rightarrow 1$ für $x \rightarrow \infty$ (Grenzwerte)

(2) $f(x) = \frac{\exp(a(x-b))}{1 + \exp(a(x-b))}$ (Alternative Form)

(3) $f(b) = \frac{1}{2}$ (Spezieller Wert)

(4) $f'(x) = a(1 - f(x))f(x)$ (Ableitung)

(5) $f'(x) > 0$ für alle $x \in \mathbb{R}$ (Strenge Monotonie)

(6) $f'(b) = \frac{1}{4}a$ (Spezieller Ableitungswert)

(7) $\arg \max f'(x) = b$ (Maximalstelle der Ableitung)

Beweis

(1) Mit den Eigenschaften der Exponentialfunktion gilt

$$x \rightarrow -\infty \Rightarrow \exp(-a(x-b)) \rightarrow \infty \Rightarrow \frac{1}{1 + \exp(-a(x-b))} \rightarrow \frac{1}{1 + \infty} = 0 \quad (4)$$

sowie

$$x \rightarrow \infty \Rightarrow \exp(-a(x-b)) \rightarrow 0 \Rightarrow \frac{1}{1 + \exp(-a(x-b))} \rightarrow \frac{1}{1} = 1 \quad (5)$$

(2) Mit den Eigenschaften der Exponentialfunktion gilt

$$\frac{1}{1 + \exp(-a(x-b))} = \frac{1}{1 + \frac{1}{\exp(a(x-b))}} = \frac{\exp(a(x-b))}{\exp(a(x-b)) + \frac{\exp(a(x-b))}{\exp(a(x-b))}} = \frac{\exp(a(x-b))}{1 + \exp(a(x-b))} \quad (6)$$

(3) Mit den Eigenschaften der Exponentialfunktion gilt

$$f(b) = \frac{1}{1 + \exp(-a(b-b))} = \frac{1}{1 + \exp(0)} = \frac{1}{1+1} = \frac{1}{2} \quad (7)$$

Beweis (fortgeführt)

(4) Es gilt

$$\begin{aligned}f'(x) &= \frac{d}{dx} (1 + \exp(-a(x-b)))^{-1} \\&= -(1 + \exp(-a(x-b)))^{-2} \frac{d}{dx} (1 + \exp(-a(x-b))) \\&= -(1 + \exp(-a(x-b)))^{-2} \exp(-a(x-b))(-a) \\&= a \left(\frac{\exp(-a(x-b))}{(1 + \exp(-a(x-b)))^2} \right) \\&= a \left(\frac{1 + \exp(-a(x-b)) - 1}{(1 + \exp(-a(x-b)))^2} \right) \\&= a \left(\frac{1 + \exp(-a(x-b))}{(1 + \exp(-a(x-b)))^2} - \frac{1}{(1 + \exp(-a(x-b)))^2} \right) \\&= a \left(\frac{1}{1 + \exp(-a(x-b))} - \frac{1}{(1 + \exp(-a(x-b)))^2} \right) \\&= a \left(\frac{1}{1 + \exp(-a(x-b))} \left(1 - \frac{1}{1 + \exp(-a(x-b))} \right) \right) \\&= a f(x)(1 - f(x))\end{aligned} \tag{8}$$

Beweis (fortgeführt)

(5) Mit dem Beweis der für die Ableitung von f gilt

$$f'(x) = a \left(\frac{\exp(-a(x-b))}{(1 + \exp(-a(x-b)))^2} \right) \quad (9)$$

Dabei ist $a > 0$ nach Voraussetzung, $\exp(-a(x-b)) > 0$ mit den Eigenschaften der Exponentialfunktion und $(1 + \exp(-a(x-b)))^2 > 0$ mit den Eigenschaften der Exponential- und Quadratfunktion. Also gilt $f'(x) > 0$ für alle $x \in \mathbb{R}$ und f ist damit streng monoton steigend.

(6) Mit Eigenschaft (4) gilt

$$f'(b) = a(1 - f(b))f(b) = a \left(1 - \frac{1}{2} \right) \frac{1}{2} = \frac{1}{4}a \quad (10)$$

Beweis (fortgeführt)

(7) Da a konstant ist, nimmt die Ableitung der logistischen Funktion ihr Maximum genau dann an, wenn $f(x)(1-f(x))$ ein Maximum annimmt. Wir setzen also $y := f(x)$ und betrachten die Funktion

$$g : \mathbb{R} \rightarrow \mathbb{R}, y \mapsto g(y) := (1-y)y = y - y^2. \quad (11)$$

Dann gilt

$$g'(y) = 1 - 2y \text{ und } g''(y) = -2. \quad (12)$$

Nullsetzen der ersten Ableitung ergibt

$$g'(y^*) = 0 \Leftrightarrow 1 - 2y^* = 0 \Leftrightarrow y^* = \frac{1}{2} \quad (13)$$

und mit $g''(y) < 0$ handelt es sich dabei um ein Maximum. Die Ableitung der logistischen Funktion nimmt also für den Wert $f(x) = \frac{1}{2}$ ein Maximum an. Offenbar gilt mit (3), dass dann $x = b$ gilt. Da f nach Eigenschaft (5) streng monoton steigend ist, nimmt f den Wert $\frac{1}{2}$ nur einmal an.

Definition (Birnbaum-Modell)

Für $i = 1, \dots, n$ Personen und $j = 1, \dots, m$ dichotome Items seien

- x_i die Zufallsvariable zur Modellierung der Eigenschaft von Person i ,
- y_{ij} die Zufallsvariable zur Modellierung der j -ten Itemantwort von Person i mit Wertebereich $\{0, 1\}$,
- $y_i := (y_{i1}, \dots, y_{im})^T$ der Zufallsvektor der Itemantworten von Person i ,
- $a_j \in \mathbb{R}_{>0}, b_j \in \mathbb{R}, c_j \in [0, 1]$ die *Itemdiskriminations-, Itemschwierigkeits- bzw. Itemrateparameter* von Item j
- $\kappa_j := (a_j, b_j, c_j)$ der Itemparametervektor von Item j ,
- $\kappa := (\kappa_1, \dots, \kappa_m)$ die Gesamtheit der Itemparameter.

Dann heißt die bedingte Item-Response-Verteilung

$$p_{\kappa}(y_i|x_i) := \prod_{j=1}^m p_{\kappa_j}(y_{ij}|x_i) \quad (14)$$

mit

$$p_{\kappa_j}(y_{ij}|x_i) := \text{Bern}(\mu_{ij}^{\kappa}) \text{ und } \mu_{ij}^{\kappa} := c_j + (1 - c_j) \frac{1}{1 + \exp(-a_j(x_i - b_j))} \quad (15)$$

Birnbaum-Modell oder *3-Parameter-Logistisches-Modell (3PL-Modell)*. Weiterhin wird das Modell für

- $c_j := 0$ *2PL-Modell* und für
- $c_j := 0$ und $a_j := 1$ *1PL-Modell* oder *Rasch-Modell*.

genannt.

Bemerkungen

- Das Modell wird ausführlich in Kapiteln 17 - 20 von Lord & Novick (1968) diskutiert.
- Die Modellierung von Personeneigenschaften x_i als Zufallsvariablen unterstellt MML-Schätzung.
- $p_{\kappa_j}(y_{ij}|x_i)$ wird die *Item-Response-Funktion* oder *Item-Characteristic-Curve (ICC)* des Modells genannt.
- $\prod_{j=1}^m p_{\kappa_j}(y_{ij}|x_i)$ enkodiert die bedingte Unabhängigkeit von Itemantworten bei gegebener Eigenschaft x_i .
- Diese Faktorisierungseigenschaft des Modells über Items wird klassisch auch "lokale Unkorreliertheit" genannt.
- Für den Parameterraum der Parameter eines Items gilt $(a_j, b_j, c_j) \in]0, \infty[\times]-\infty, \infty[\times [0, 1]$.
- In der Literatur findet man oft die Bezeichnung *ability* und das Symbol θ_i für x_i .
- Die Bedeutung der Itemparameter verdeutlichen wir untenstehend.
- Lord (1951) entwickelte ursprünglich das sogenannte *Normal-Ogive-Modell* mit

$$\mu_{ij} := \int_{-\infty}^{a_j(x_i - b_j)} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}s^2\right) ds = \Phi(a_j(x_i - b_j)) \quad (16)$$


bei dem also die KVF der Standardnormalverteilung als Item-Response-Funktion diente.

- Die logistische Funktion approximiert die KVF der Standardnormalverteilung und ist mathematisch einfacher.
- Birnbaum adaptierte in Lord & Novick (1968) frühere Arbeiten durch z.B. Finney (1952) im Bereich Bioassays.

Birnbaum-Modell

Bemerkungen (Normal-Ogive-Modell und 2PL-Modell)

- Haley (1952) hat gezeigt, dass $|f(1.7x) - \Phi(x)| < 0.01$ für alle $x \in \mathbb{R}$.



Birnbaum-Modell


Bemerkungen (Itemschwierigkeitsparameter)

- Es seien $c_j = 0$ und $x_i = b_j$. Dann gilt

$$p_{\kappa_j}(y_{ij}|x_i) = 0 + (1 - 0) \frac{1}{1 + \exp(-a_j(b_j - b_j))} = \frac{1}{1 + \exp(0)} = \frac{1}{1 + 1} = \frac{1}{2} \quad (17)$$

- Der Itemschwierigkeitsparameter b_j entspricht hier dem Eigenschaftswert x_i , für den $p_{\kappa_j}(y_{ij} = 1|x_i) = \frac{1}{2}$ ist.
- Höhere Schwierigkeitsparameter b_j implizieren hier höhere Eigenschaften x_i , für die $p_{\kappa_j}(y_{ij} = 1|x_i) = \frac{1}{2}$ ist.

Effekt des Itemschwierigkeitsparameters bei $a_j = 1$, $c_j = 0$



Birnbaum-Modell

Bemerkungen (Itemdiskriminationsparameter)

- Es seien $c_j = 0$. Dann gilt mit Aussage (6) von Theorem [Eigenschaften der logistischen Funktion](#)


$$\left. \frac{d}{dx_i} p_{\kappa_j}(y_{ij} = 1 | x_i) \right|_{x_i = b_j} = \frac{1}{4} a_j. \quad (18)$$

- Für $x_i^{(1)} < b_j < x_i^{(2)}$ gilt also

$$a_j \uparrow \Rightarrow p_{\kappa_j}(y_{ij} = 1 | x_i^{(2)}) - p_{\kappa_j}(y_{ij} = 1 | x_i^{(1)}) \uparrow \quad (19)$$


bei identischer Differenz $x_i^{(2)} - x_i^{(1)}$

- In diesem Sinne diskriminiert ein Item mit höherem a_j stärker zwischen zwei Eigenschaftswerten $x_i^{(1)}, x_i^{(2)}$.



Bemerkungen (Itemrateparameter)

- c_j entspricht $p_{\kappa_j}(y_{ij}|x_i)$ für $x_i \rightarrow -\infty$.
- Mit $c_j \neq 0$ ist das 3PL-Modell kein logistisches Modell.
- c_j wird sicherlich besser als "Pseudorateparameter" gedacht.



Bemerkungen (Itemrateparameter)

- Das 3PL-Modell ist kein "logistisches Modell".
- Die Parameterinterpretationen sind Parameterinteraktionen unterworfen:
- $\Rightarrow$ Für $c_j \neq 0$ ist die Steigung in b_j auch von c_j abhängig.
- $\Rightarrow$ Für $c_j \neq 0$ ist der Wert x_i für $p_{\kappa}(y_{ij}|x_i) = 0.5$ auch von c_j abhängig.
- Die Interpretationen von a_j und b_j sind also nicht absolut.
- Als *Itemparameter* modelliert c_j nicht das Raten von individuellen *Personen*.
- $c_j > 0$ mag auch daran liegen, dass Distraktoren auffällig sein können.
- $\Rightarrow$ "Welchen Durchmesser hat ein Mitochondrium?" (a) Etwa $1\mu m$ (b) Känguru

Birnbaum-Modell Datengeneration

```
# 3PL Modell Bernoulli-Erwartungswertparameter
mu = function(x,kappa){
  a      = kappa[1]          # Diskriminationsparameter
  b      = kappa[2]          # Schwierigkeitsparameter
  c      = kappa[3]          # Rateparameter
  mu     = c + (1-c)*plogis(a*(x-b))  # Erwartungswertparameter
}

# Datengeneration
set.seed(0)                  # Reproduzierbarkeit
n        = 100               # Anzahl Personen
m        = 10                # Anzahl Items
kappa_tbu = rbind(runif(m,0,2), runif(m,-3,3), runif(m,0,1))  # True-but-unknown Itemparameter
X_tbu    = matrix(rnorm(n,0,1), nrow = n)                    # True-but-unknown Personeneigenschaften
Y        = matrix(rep(NA, n*m), nrow = n)                   # Observierbare Item-Responses
for(i in 1:n){
  for(j in 1:m){
    Y[i,j] = rbinom(1,1, mu(X_tbu[i], kappa_tbu[,j]))        #  $y_{ij} \sim \text{Bern}(\mu_{ij}^{\kappa})$ 
  }
}
colnames(Y) = paste("I", 1:m, sep = "")                     # Itemlabel
write.csv(Y, "2-Daten/2-irt.csv", row.names = FALSE)         # Datenspeicherung
```

Überblick zur Parameterschätzung

Joint-Maximum-Likelihood-Schätzung (JML)

- Eher historische Anwendung nach Birnbaum in Lord & Novick (1968) für 1PL und 2PL, selten 3PL
- Personeneigenschaften x_i als feste unbekannte Parameter, nicht als latente Zufallsvariablen konzeptualisiert
- Iterative Maximierung der Likelihood-Funktion bezüglich Personeneigenschaften und Itemparameter
- Personeneigenschaftsparameteranzahl $x_1, \dots, x_n$ steigt mit Stichprobenumfang
- $\Rightarrow$ Keine Konsistenz der Itemparameterschätzer

Marginal-Maximum-Likelihood-Schätzung (MML)

- 1PL (weniger zentral bei Rasch-Modellen), 2PL, 3PL
- Personeneigenschaften als latente Zufallsvariablen konzeptualisiert
- Marginalisierung der Likelihood über Personeneigenschaften zur sogenannten *Marginalen Likelihood*
- Itemparameterschätzung durch Maximierung der Marginalen Likelihood
- $\Rightarrow$ Konsistente und asymptotisch unverzerzte Itemparameterschätzungen

Überblick zur Marginal-Maximum-Likelihood-Schätzung

Im Rahmen der Marginal-Maximum-Likelihood (MML)-Schätzung wird das Birnbaum-Modell als parametrisiertes Modell mit latenten Zufallsvariablen konzipiert, wobei die Personeneigenschaften x_i , $i = 1, \dots, n$ die Rolle der latenten Zufallsvariablen einnehmen. Seien formal dazu

- y die Gesamtheit aller nm beobachtbaren Datenpunkte,
- x die Gesamtheit aller n latenten Personeneigenschaften,
- θ die Gesamtheit aller Item- und Personenpopulationsparameter.

Dann entspricht ein Birnbaum-Modell einer gemeinsamen Wahrscheinlichkeitsverteilung $p_\theta(x, y)$. Grundlegende Idee der MML-Schätzung ist es, über die latenten Variablen zu mitteln und analog zur Maximum-Likelihood-Schätzung zu fragen, welche Parameterwerte die sogenannte *Marginal-Likelihood-Funktion*

$$L : \theta \rightarrow \mathbb{R}_{\geq 0}, \theta \mapsto L(\theta) := p_\theta(y) = \int p_\theta(x, y) dx, \quad (20)$$

oder, äquivalent, die *Log-Marginal-Likelihood-Funktion*

$$\ell : \theta \rightarrow \mathbb{R}, \theta \mapsto \ell(\theta) := \ln p_\theta(y) = \ln \int p_\theta(x, y) dx \quad (21)$$

für einen festen beobachteten Datensatz y maximieren. Für das Birnbaum-Modell nutzt man dazu Varianten des sogenannten *Expectation-Maximization-Algorithmus* (vgl. Bock & Aitkin (1981), Thissen (1982), Rigdon & Tsutakawa (1983)). Der exakte EM-Algorithmus ist eine Spezialform der koordinatenweisen ELBO-Maximierung der variationalen Inferenz (vgl. Ostwald et al. (2014), Blei & Smyth (2017), Starke & Ostwald (2017)). Wir führen zunächst den exakten EM-Algorithmus ein und betrachten dann seine Spezialisierung nach Woodruff (1996).

Theorem (Evidence Lower Bound)

Für einen Datensatz $y \in \mathbb{R}^{m \times n}$ sei $\ln p_\theta(y)$ die Log-Marginal-Likelihood eines latenten Variablenmodells $p_\theta(x, y)$. Dann gilt für eine beliebige Verteilung $q(x)$ der latenten Variablen, dass

$$\ln p_\theta(y) \geq \int q(x) \ln p_\theta(x, y) dx - \int q(x) \ln q(x) dx =: \text{ELBO}(q(x), \theta).$$

$\text{ELBO}(q(x), \theta)$ heißt *Evidence Lower Bound*.

Beweis

Mit der Jensenschen Ungleichung (Theorem [Jensensche Ungleichung](#)) gilt

$$\ln p_\theta(y) := \ln \int p_\theta(x, y) dx = \ln \int q(x) \left(\frac{p_\theta(x, y)}{q(x)} \right) dx \geq \int q(x) \ln \left(\frac{p_\theta(x, y)}{q(x)} \right) dx.$$

Damit aber folgt

$$\begin{aligned} \ln p_\theta(y) &\geq \int q(x) \ln \left(\frac{p_\theta(x, y)}{q(x)} \right) dx = \int q(x) (\ln p_\theta(x, y) - \ln q(x)) dx \\ &= \int q(x) \ln p_\theta(x, y) dx - \int q(x) \ln q(x) dx. \end{aligned}$$

Bemerkungen

- Für einen festen Datensatz y ist $\text{ELBO}(q(x), \theta)$ eine Funktion von $q(x)$ und θ .
- Die Bezeichnung Evidence Lower Bound geht auf den Begriff "Evidence" für $p_\theta(y)$ zurück.
- In den kognitiven Neurowissenschaften ist die ELBO weiterhin als "Freie Energie" bekannt.
- Die Signifikanz der ELBO geht weit über das Birnbaum-Modell hinaus.
- Die ELBO ist für Variational Inference zentral.
- Variational Inference (VI) ist für zeitgenössische Gehirntheorien zentral (Parr et al. (2022)).
- Es gibt auch einen expliziten VI-Zugang zum Birnbaum-Modell (vgl. Linden (2016) II.14, Wu et al. (2020)).
- Wir fokussieren hier auf den etwas traditionelleren MML/EM-Ansatz.

Definition (Expectation-Maximization-Algorithmus)

Die iterative koordinatenweise Maximierung der ELBO heißt *Expectation-Maximization (EM)-Algorithmus*.

Der Algorithmus hat die allgemeine Form:

EM-Algorithmus

0. Initialisierung von $q^{(0)}(x)$ und $\theta^{(0)}$

Für $k = 1, 2, \dots$

1. E-Schritt: Setze $q^{(k)}(x) := \arg \max_{q(x)} \text{ELBO}(q(x), \theta^{(k-1)})$
2. M-Schritt: Setze $\theta^{(k)} := \arg \max_{\theta} \text{ELBO}(q^{(k)}(x), \theta)$

Nach Konvergenz, nutze $\hat{\theta} := \theta^{(k)}$ als Parameterschätzer.

Bemerkungen

- “Expectation-Schritt” ist eine Fehlbezeichnung, weil es sich auch um einen Maximierungsschritt handelt.
- Die Bezeichnung ergibt im sogenannten exakten EM-Algorithmus dennoch Sinn, weil der M-Schritt dort einen bedingten Erwartungswert der vollständigen Log-Likelihood maximiert.

Theorem (Exakter Expectation-Maximization-Algorithmus)

Das Setzen von

$$q^{(k)}(x) := p_{\theta^{(k-1)}}(x|y) \text{ für alle } k = 1, 2, \dots \quad (22)$$

im E-Schritt des EM-Algorithmus maximiert die ELBO hinsichtlich $q(x)$ und heißt *exakter E-Schritt*.

Der Algorithmus hat dann die folgende Form:

Exakter EM-Algorithmus

0. Initialisierung von $\theta^{(0)}$

Für $k = 1, 2, \dots$

1. E-Schritt: $q^{(k)}(x) := p_{\theta^{(k-1)}}(x|y)$
2. M-Schritt: $\theta^{(k)} := \arg \max_{\theta} \int p_{\theta^{(k-1)}}(x|y) \ln p_{\theta}(x, y) dx$

Nach Konvergenz, nutze $\hat{\theta} := \theta^{(k)}$ als Parameterschätzer.

Bemerkungen

- Im Ansatz von Woodruff (1996) wird $p_{\theta^{(k-1)}}(x|y)$ "nichtparametrisch" evaluiert.
- Der M-Schritt des exakten EM-Algorithmus nach Woodruff (1996) benötigt numerische Optimierung.

Beweis

Wir zeigen zunächst, dass die ELBO $q^{(k)}(x) := p_{\theta^{(k-1)}}(x|y)$ den maximalen Wert $\ln p_{\theta^{(k-1)}}(y)$ annimmt:


$$\begin{aligned}\text{ELBO}(p_{\theta^{(k-1)}}(x|y), \theta^{(k-1)}) &= \int p_{\theta^{(k-1)}}(x|y) \ln \left(\frac{p_{\theta^{(k-1)}}(x, y)}{p_{\theta^{(k-1)}}(x|y)} \right) dx \\ &= \int p_{\theta^{(k-1)}}(x|y) \ln \left(\frac{p_{\theta^{(k-1)}}(y) p_{\theta^{(k-1)}}(x|y)}{p_{\theta^{(k-1)}}(x|y)} \right) dx \\ &= \int p_{\theta^{(k-1)}}(x|y) \ln p_{\theta^{(k-1)}}(y) dx \\ &= \ln p_{\theta^{(k-1)}}(y) \int p_{\theta^{(k-1)}}(x|y) dx \\ &= \ln p_{\theta^{(k-1)}}(y).\end{aligned}$$

Der M-Schritt hat dementsprechend die Form

$$\begin{aligned}\theta^{(k)} &= \arg \max_{\theta} \text{ELBO} \left(p_{\theta^{(k-1)}}(x|y), \theta \right) \\ &= \arg \max_{\theta} \int p_{\theta^{(k-1)}}(x|y) \ln p_{\theta}(x, y) dx - \int p_{\theta^{(k-1)}}(x|y) \ln p_{\theta^{(k-1)}}(x|y) dx.\end{aligned}$$

Der M-Schritt des exakten EM-Algorithmus folgt dann damit, dass der zweite Integralterm hier nicht von θ abhängt.

Visuelle Intuition



Bemerkungen

- Der M-Schritt der k ten Iteration des exakten EM-Algorithmus entspricht der Maximierung des Erwartungswertes der logarithmierten WDF der gemeinsamen Datenverteilung $p_{\theta}(x, y)$ hinsichtlich θ , wobei der Erwartungswert hinsichtlich der WDF der bedingten Datenverteilung von x gegeben y basierend auf der Parameterschätzung $\theta^{(k-1)}$ gebildet wird, die in der $(k-1)$ ten Iteration des exakten EM-Algorithmus gewonnen wurde.

- Aufgrund der inhärenten Logik des EM-Algorithmus führt die Maximierung des Erwartungswertes

$$\mathbb{E}_{p_{\theta^{(k-1)}}(x|y)}(\ln p_{\theta}(x, y)) = \int p_{\theta^{(k-1)}}(x|y) \ln p_{\theta}(x, y) dx \quad (23)$$

bei exaktem E-Schritt und exaktem M-Schritt zu einer nicht fallenden Log-Marginal-Likelihood,

$$\ell(\theta^{(k)}) \geq \ell(\theta^{(k-1)}) \quad \text{für } k = 1, 2, \dots \quad (24)$$

EM garantiert damit, dass die Zielfunktion ℓ über Iterationen hinweg monoton nicht fällt.

- Für konkrete Algorithmen und für das Birnbaum-Modell muss obiger Erwartungswert als Funktion von $\theta^{(k-1)}$ ausgewertet werden und dann hinsichtlich θ maximiert werden, um die Parameterschätzung $\theta^{(k)}$ zu erhalten.

Bock & Aitkin (1981) haben die MML-EM-Methode für das Birnbaum-Modell eingeführt.

- Behandlung der Personeneigenschaften $x_1, \dots, x_n$ als kontinuierliche normalverteilte latente Zufallsvariablen
- Evaluation des M-Schritt-Likelihood-Integrals durch numerische Integration (Gauss-Hermite-Quadratur)

Woodruff (1996) hat die MML-EM-Methode als endliches Mischungsmodell neu konzeptualisiert.

- Behandlung der Personeneigenschaften $x_1, \dots, x_n$ als diskrete latente Zufallsvariablen
- Das Modell ist dann direkt als MML-EM-Algorithmus für endliche Mischungsmodelle formulierbar.
- Eindeutige Verortung von IRT innerhalb von endlichen Mischungsmodellen (vgl. Titterton et al. (1994))
- Es ist keine spezielle "Item-Response-Theorie-spezifische" EM-Theorie erforderlich (vgl. Murphy (2023)).
- Viele Konvergenzeigenschaften können aus der Theorie endlicher Mischungsmodelle übernommen werden.
- Wird das Modell als Mischung aufgefasst, können nicht-normale latente Verteilungen geschätzt werden.
- Insgesamt erleichtert Woodruff (1996) das Verständnis.

Aktuelle **R**-Pakete wie `ltm` oder `mirt` implementieren quadraturbasierte MML-EM-Verfahren, die sich bei fester Quadraturpunktmenge als endliche Mischungsmodelle auffassen lassen und damit eng mit der Perspektive von Woodruff (1996) verbunden sind.

Definition (Verteilungsform des Birnbaum-Modells nach Woodruff (1996))

Für $i = 1, \dots, n$ Personen, $j = 1, \dots, m$ dichotome Items, und $s = 1, \dots, r$ diskrete Eigenschaftswerte seien

- x_i die Zufallsvariable zur Modellierung der Eigenschaft von Person i mit Wertebereich $\{\xi_1, \dots, \xi_r\} \subset \mathbb{R}$,
- $x := (x_1, \dots, x_n)$ der Zufallsvektor der x_i ,
- y_{ij} die Zufallsvariable zur Modellierung der j ten Itemantwort von Person i mit Wertebereich $\{0, 1\}$,
- $y_i := (y_{i1}, \dots, y_{im})^T$ der Zufallsvektor der Itemantworten von Person i ,
- $y := (y_1, \dots, y_n)$ die Zufallsmatrix der y_i ,
- $\kappa := (a_j, b_j, c_j)_{j=1, \dots, m}$ die Itemparameter des Birnbaum-Modells mit $a_j > 0$, $b_j \in \mathbb{R}$ und $0 \leq c_j < 1$,
- π mit $\pi_s \geq 0$ und $\sum_{s=1}^r \pi_s = 1$ der Parameter der Personeneigenschaftsverteilung,
- $\theta := (\pi, \kappa)$ der Gesamtparameter.

Dann ist die Verteilungsform des Birnbaum-Modells nach Woodruff (1996) gegeben durch

$$p_\theta(x, y) := \prod_{i=1}^n p_\theta(x_i, y_i) := \prod_{i=1}^n p_\pi(x_i) p_\kappa(y_i | x_i) := \prod_{i=1}^n p_\pi(x_i) \prod_{j=1}^m p_{\kappa_j}(y_{ij} | x_i) \quad (25)$$

mit der Personeneigenschaftsverteilung

$$p_\pi(x_i) = \prod_{s=1}^r \pi_s \mathbb{I}^{x_i = \xi_s} \quad (26)$$

und der Item-Response-Verteilung

$$p_{\kappa_j}(y_{ij} | x_i) := \text{Bern}(\mu_{ij}^\kappa) \quad \text{mit} \quad \mu_{ij}^\kappa := c_j + (1 - c_j) \frac{1}{1 + \exp(-a_j(x_i - b_j))}. \quad (27)$$

Bemerkungen

- Die Personeneigenschaft nimmt hier die r diskreten Werte $\xi_1, \dots, \xi_r$ an.
- $\llbracket x_i = \xi_s \rrbracket$ bezeichnet die Iverson-Klammer mit $\llbracket x_i = \xi_s \rrbracket = 1$ für $x_i = \xi_s$ und $\llbracket x_i = \xi_s \rrbracket = 0$ sonst.
- Die Wahrscheinlichkeit, dass die Personeneigenschaft für Person i den Wert ξ_s annimmt, ist also

$$p_\pi(x_i = \xi_s) = \prod_{\tilde{s}=1}^r \pi_{\tilde{s}}^{\llbracket x_i = \xi_{\tilde{s}} \rrbracket} = \pi_s. \quad (28)$$

- Die Definition

$$p_\theta(x, y) := \prod_{i=1}^n p_\theta(x_i, y_i) \quad (29)$$

enkodiert die Unabhängigkeitsannahme über Personen.

- Die Definition

$$p_\theta(x_i, y_i) := p_\pi(x_i) p_\kappa(y_i | x_i) \quad (30)$$

enkodiert die partielle Wirksamkeit der Parameter π und κ .

- Die oft als "lokale Unkorreliertheit" bezeichnete Definition

$$p_\pi(x_i) p_\kappa(y_i | x_i) := p_\pi(x_i) \prod_{j=1}^m p_{\kappa_j}(y_{ij} | x_i) \quad (31)$$

enkodiert die bedingte Unabhängigkeit der Itemantworten von Person i bei gegebener Eigenschaft x_i .

Theorem (Birnbaum-Modell-EM-Algorithmus nach Woodruff (1996))

Gegeben sei die Verteilungsform des Birnbaum-Modells nach Woodruff (1996). Dann hat der exakte EM-Algorithmus zur Schätzung der Personeneigenschaftsverteilungsparameter π und der Itemparameter κ die Form:

0. Initialisierung von $\theta^{(0)} = (\pi^{(0)}, \kappa^{(0)})$

Für $k = 1, 2, \dots$

1. E-Schritt: Setze $q^{(k)}(x) := p_{\theta^{(k-1)}}(x|y)$ mit

$$p_{\theta^{(k-1)}}(x|y) = \prod_{i=1}^n p_{\theta^{(k-1)}}(x_i|y_i) \text{ und } p_{\theta^{(k-1)}}(x_i = \xi_s|y_i) = \frac{\pi_s^{(k-1)} p_{\kappa^{(k-1)}}(y_i|x_i = \xi_s)}{\sum_{\tilde{s}=1}^r \pi_{\tilde{s}}^{(k-1)} p_{\kappa^{(k-1)}}(y_i|x_i = \xi_{\tilde{s}})} \quad (32)$$

für alle $i = 1, \dots, n$ und $s = 1, \dots, r$.

2. M-Schritt: Es seien $\nu_s^{(k-1)} := \sum_{i=1}^n p_{\theta^{(k-1)}}(x_i = \xi_s|y_i)$ und $\rho_{js}^{(k-1)} := \sum_{i=1}^n y_{ij} p_{\theta^{(k-1)}}(x_i = \xi_s|y_i)$.

Dann gilt für $\theta^{(k)} = (\pi^{(k)}, \kappa^{(k)})$, dass

$$\pi_s^{(k)} := \frac{1}{n} \nu_s^{(k-1)} \text{ für } s = 1, \dots, r \quad (33)$$

und mit

$$\mu_{sj}^{\kappa} := c_j + (1 - c_j) \frac{1}{1 + \exp(-a_j(\xi_s - b_j))} \quad (34)$$

$$\kappa_j^{(k)} = \arg \max_{\kappa_j \in \mathbb{R}_{>0} \times \mathbb{R} \times [0,1]} \sum_{s=1}^r \left(\ln(\mu_{sj}^{\kappa}) \rho_{js}^{(k-1)} + \ln(1 - \mu_{sj}^{\kappa}) (\nu_s^{(k-1)} - \rho_{js}^{(k-1)}) \right) \text{ für } j = 1, \dots, m. \quad (35)$$

Beweis

(1) E-Schritt

Zur Vereinfachung der Notation setzen wir $\theta := \theta^{(k-1)}$. Wir halten dann zunächst fest, dass durch wiederholte Anwendung der Linearitätseigenschaften von Summen folgt, dass

$$\begin{aligned} p_{\theta}(y) &= \sum_x p_{\theta}(x, y) \\ &= \sum_{x_1} \cdots \sum_{x_n} p_{\theta}(x_1, \dots, x_n, y_1, \dots, y_n) \\ &= \sum_{x_1} \cdots \sum_{x_n} \left(\prod_{i=1}^n p_{\theta}(x_i, y_i) \right) \\ &= \prod_{i=1}^n \left(\sum_{x_i} p_{\theta}(x_i, y_i) \right) \\ &= \prod_{i=1}^n p_{\theta}(y_i). \end{aligned} \tag{36}$$

Dann aber gilt

$$p_{\theta}(x|y) = \frac{p_{\theta}(x, y)}{p_{\theta}(y)} = \frac{\prod_{i=1}^n p_{\theta}(x_i, y_i)}{\prod_{i=1}^n p_{\theta}(y_i)} = \prod_{i=1}^n \frac{p_{\theta}(x_i, y_i)}{p_{\theta}(y_i)} = \prod_{i=1}^n p_{\theta}(x_i|y_i). \tag{37}$$

Beweis (fortgeführt)

Weiterhin gilt

$$p_{\theta}(x_i|y_i) = \frac{p_{\theta}(x_i, y_i)}{p_{\theta}(y_i)} = \frac{p_{\pi}(x_i)p_{\kappa}(y_i|x_i)}{\sum_{x_i} p_{\pi}(x_i)p_{\kappa}(y_i|x_i)}. \quad (38)$$

Insgesamt ergibt sich also

$$p_{\theta^{(k-1)}}(x|y) = \prod_{i=1}^n p_{\theta^{(k-1)}}(x_i|y_i) = \prod_{i=1}^n \frac{p_{\pi^{(k-1)}}(x_i)p_{\kappa^{(k-1)}}(y_i|x_i)}{\sum_{x_i} p_{\pi^{(k-1)}}(x_i)p_{\kappa^{(k-1)}}(y_i|x_i)}. \quad (39)$$

Speziell ergibt sich für einen Wert $\xi_s \in \{\xi_1, \dots, \xi_r\}$ der möglichen Werte von x_i , dass

$$p_{\theta^{(k-1)}}(x_i = \xi_s|y_i) = \frac{\pi_s^{(k-1)} p_{\kappa^{(k-1)}}(y_i|x_i = \xi_s)}{\sum_{\tilde{s}=1}^r \pi_{\tilde{s}}^{(k-1)} p_{\kappa^{(k-1)}}(y_i|x_i = \xi_{\tilde{s}})}. \quad (40)$$

Beweis (fortgeführt)

(2) M-Schritt

Wir werten zunächst das im M-Schritt bezüglich θ zu maximierende Integral

$$\int p_{\theta(k-1)}(x|y) \ln p_{\theta}(x, y) dx, \quad (41)$$

das aufgrund der diskreten Natur der Personeneigenschaften im vorliegenden Fall einer Summe über die möglichen Werte von x entspricht, aus. Dabei ergibt sich mit dem Ergebnis des E-Schritts und der Definition von $p_{\theta}(x, y)$, dass sich dieses Integral als Summe einer Funktion der Personeneigenschaftsverteilungsparameter $f(\pi)$ und einer Funktion der Itemparameter $g(\kappa)$ schreiben lässt, welche sich dann in der Folge unabhängig voneinander bezüglich der Komponenten von θ maximieren lassen. Es ergibt sich

Beweis (fortgeführt)

$$\begin{aligned}
 \int p_{\theta^{(k-1)}}(x|y) \ln p_{\theta}(x, y) dx &= \sum_{x_1} \dots \sum_{x_n} \left(p_{\theta^{(k-1)}}(x_1, \dots, x_n | y_1, \dots, y_n) \ln \left(\prod_{i=1}^n p_{\theta}(x_i, y_i) \right) \right) \\
 &= \sum_{x_1} \dots \sum_{x_n} \left(p_{\theta^{(k-1)}}(x_1, \dots, x_n | y_1, \dots, y_n) \sum_{i=1}^n \ln p_{\theta}(x_i, y_i) \right) \\
 &= \sum_{x_1} \dots \sum_{x_n} \sum_{i=1}^n p_{\theta^{(k-1)}}(x_1, \dots, x_n | y_1, \dots, y_n) \ln p_{\theta}(x_i, y_i) \\
 &= \sum_{i=1}^n \left(\sum_{x_1} \dots \sum_{x_n} p_{\theta^{(k-1)}}(x_1, \dots, x_n | y_1, \dots, y_n) \ln p_{\theta}(x_i, y_i) \right) \\
 &= \sum_{i=1}^n \sum_{x_i} p_{\theta^{(k-1)}}(x_i | y_i) \ln p_{\theta}(x_i, y_i) \\
 &= \sum_{i=1}^n \sum_{s=1}^r p_{\theta^{(k-1)}}(x_i = \xi_s | y_i) \ln p_{\theta}(x_i = \xi_s, y_i) \\
 &= \sum_{i=1}^n \sum_{s=1}^r p_{\theta^{(k-1)}}(x_i = \xi_s | y_i) \ln (p_{\pi}(x_i = \xi_s) p_{\kappa}(y_i | x_i = \xi_s)) \\
 &= \sum_{i=1}^n \sum_{s=1}^r p_{\theta^{(k-1)}}(x_i = \xi_s | y_i) (\ln p_{\pi}(x_i = \xi_s) + \ln p_{\kappa}(y_i | x_i = \xi_s)) \\
 &= \sum_{i=1}^n \sum_{s=1}^r p_{\theta^{(k-1)}}(x_i = \xi_s | y_i) \ln p_{\pi}(x_i = \xi_s) + \sum_{i=1}^n \sum_{s=1}^r p_{\theta^{(k-1)}}(x_i = \xi_s | y_i) \ln p_{\kappa}(y_i | x_i = \xi_s) \\
 &=: f(\pi) + g(\kappa).
 \end{aligned}$$

Beweis (fortgeführt)

Dabei ergibt sich die fünfte Gleichung beispielhaft für $n := 3$ und $i := 1$ durch

$$\begin{aligned} & \sum_{x_1} \sum_{x_2} \sum_{x_3} p_{\theta^{(k-1)}}(x_1, x_2, x_3 | y_1, y_2, y_3) \ln p_{\theta}(x_1, y_1) \\ &= \sum_{x_1} \ln p_{\theta}(x_1, y_1) \sum_{x_2} \sum_{x_3} p_{\theta^{(k-1)}}(x_1, x_2, x_3 | y_1, y_2, y_3) \\ &= \sum_{x_1} \ln p_{\theta}(x_1, y_1) p_{\theta^{(k-1)}}(x_1 | y_1, y_2, y_3) \\ &= \sum_{x_1} p_{\theta^{(k-1)}}(x_1 | y_1) \ln p_{\theta}(x_1, y_1), \end{aligned} \tag{42}$$

wobei sich die letzte Gleichung mit der bedingten Unabhängigkeit von x_1 von y_2, y_3 gemäß des Beweises des E-Schritts ergibt.

Es verbleiben also die Maximierung von f bezüglich π und von g bezüglich κ . Dabei kann die Maximierung von f bezüglich der Personeneigenschaftsparameter π mit einem Lagrangeansatz auf analytische Weise durchgeführt werden, wohingegen die Maximierung von g bezüglich der Itemparameter κ eine Auslagerung in die numerische Optimierung benötigt.

Beweis (fortgeführt)

Wir vereinfachen die Schreibweisen der Funktionen f und g noch etwas. Speziell gelten

$$\begin{aligned} f(\pi) &= \sum_{i=1}^n \sum_{s=1}^r p_{\theta^{(k-1)}}(x_i = \xi_s | y_i) \ln p_{\pi}(x_i = \xi_s) \\ &= \sum_{s=1}^r \sum_{i=1}^n p_{\theta^{(k-1)}}(x_i = \xi_s | y_i) \ln p_{\pi}(x_i = \xi_s) \\ &= \sum_{s=1}^r \sum_{i=1}^n p_{\theta^{(k-1)}}(x_i = \xi_s | y_i) \ln(\pi_s) \\ &= \sum_{s=1}^r \ln(\pi_s) \sum_{i=1}^n p_{\theta^{(k-1)}}(x_i = \xi_s | y_i) \\ &= \sum_{s=1}^r \ln(\pi_s) \nu_s^{(k-1)} \end{aligned} \tag{43}$$

mit

$$\nu_s^{(k-1)} := \sum_{i=1}^n p_{\theta^{(k-1)}}(x_i = \xi_s | y_i). \tag{44}$$

Beweis (fortgeführt)

Weiterhin gilt mit $\mu_{sj}^{\kappa} = \mu_{ij}^{\kappa}$ für $x_i = \xi_s$, dass

$$\begin{aligned} g(\kappa) &= \sum_{i=1}^n \sum_{s=1}^r p_{\theta(k-1)}(x_i = \xi_s | y_i) \ln p_{\kappa}(y_i | x_i = \xi_s) \\ &= \sum_{i=1}^n \sum_{s=1}^r p_{\theta(k-1)}(x_i = \xi_s | y_i) \ln \left(\prod_{j=1}^m p_{\kappa_j}(y_{ij} | x_i = \xi_s) \right) \\ &= \sum_{i=1}^n \sum_{s=1}^r p_{\theta(k-1)}(x_i = \xi_s | y_i) \left(\sum_{j=1}^m \ln \left(p_{\kappa_j}(y_{ij} | x_i = \xi_s) \right) \right) \\ &= \sum_{i=1}^n \sum_{s=1}^r p_{\theta(k-1)}(x_i = \xi_s | y_i) \left(\sum_{j=1}^m \ln \left((\mu_{sj}^{\kappa})^{y_{ij}} (1 - \mu_{sj}^{\kappa})^{1-y_{ij}} \right) \right) \\ &= \sum_{i=1}^n \sum_{s=1}^r p_{\theta(k-1)}(x_i = \xi_s | y_i) \left(\sum_{j=1}^m (y_{ij} \ln (\mu_{sj}^{\kappa}) + (1 - y_{ij}) \ln (1 - \mu_{sj}^{\kappa})) \right). \end{aligned}$$

Beweis (fortgeführt)

und damit

$$\begin{aligned} g(\kappa) &= \sum_{i=1}^n \sum_{s=1}^r p_{\theta(k-1)}(x_i = \xi_s | y_i) \sum_{j=1}^m (y_{ij} \ln(\mu_{sj}^{\kappa})) + \\ &\quad \sum_{i=1}^n \sum_{s=1}^r p_{\theta(k-1)}(x_i = \xi_s | y_i) \sum_{j=1}^m \ln(1 - \mu_{sj}^{\kappa}) - \\ &\quad \sum_{i=1}^n \sum_{s=1}^r p_{\theta(k-1)}(x_i = \xi_s | y_i) \sum_{j=1}^m y_{ij} \ln(1 - \mu_{sj}^{\kappa}) \\ &= \sum_{i=1}^n \sum_{s=1}^r \sum_{j=1}^m p_{\theta(k-1)}(x_i = \xi_s | y_i) (y_{ij} \ln(\mu_{sj}^{\kappa})) + \\ &\quad \sum_{i=1}^n \sum_{s=1}^r \sum_{j=1}^m p_{\theta(k-1)}(x_i = \xi_s | y_i) \ln(1 - \mu_{sj}^{\kappa}) - \\ &\quad \sum_{i=1}^n \sum_{s=1}^r \sum_{j=1}^m p_{\theta(k-1)}(x_i = \xi_s | y_i) y_{ij} \ln(1 - \mu_{sj}^{\kappa}) \\ &= \sum_{s=1}^r \sum_{j=1}^m \sum_{i=1}^n p_{\theta(k-1)}(x_i = \xi_s | y_i) y_{ij} \ln(\mu_{sj}^{\kappa}) + \\ &\quad \sum_{s=1}^r \sum_{j=1}^m \sum_{i=1}^n p_{\theta(k-1)}(x_i = \xi_s | y_i) \ln(1 - \mu_{sj}^{\kappa}) - \\ &\quad \sum_{s=1}^r \sum_{j=1}^m \sum_{i=1}^n p_{\theta(k-1)}(x_i = \xi_s | y_i) y_{ij} \ln(1 - \mu_{sj}^{\kappa}) \end{aligned}$$

Beweis (fortgeführt)

und weiter

$$\begin{aligned}
 g(\kappa) &= \sum_{s=1}^r \sum_{j=1}^m \ln(\mu_{sj}^{\kappa}) \sum_{i=1}^n p_{\theta^{(k-1)}}(x_i = \xi_s | y_i) y_{ij} + \\
 &\quad \sum_{s=1}^r \sum_{j=1}^m \ln(1 - \mu_{sj}^{\kappa}) \sum_{i=1}^n p_{\theta^{(k-1)}}(x_i = \xi_s | y_i) - \\
 &\quad \sum_{s=1}^r \sum_{j=1}^m \ln(1 - \mu_{sj}^{\kappa}) \sum_{i=1}^n p_{\theta^{(k-1)}}(x_i = \xi_s | y_i) y_{ij} \\
 &= \sum_{s=1}^r \sum_{j=1}^m \ln(\mu_{sj}^{\kappa}) \rho_{js}^{(k-1)} + \sum_{s=1}^r \sum_{j=1}^m \ln(1 - \mu_{sj}^{\kappa}) \nu_s^{(k-1)} - \sum_{s=1}^r \sum_{j=1}^m \ln(1 - \mu_{sj}^{\kappa}) \rho_{js}^{(k-1)} \\
 &= \sum_{s=1}^r \sum_{j=1}^m \left(\ln(\mu_{sj}^{\kappa}) \rho_{js}^{(k-1)} + \ln(1 - \mu_{sj}^{\kappa}) \left(\nu_s^{(k-1)} - \rho_{js}^{(k-1)} \right) \right)
 \end{aligned}$$

mit

$$\nu_s^{(k-1)} := \sum_{i=1}^n p_{\theta^{(k-1)}}(x_i = \xi_s | y_i) \text{ und } \rho_{js}^{(k-1)} := \sum_{i=1}^n y_{ij} p_{\theta^{(k-1)}}(x_i = \xi_s | y_i) \quad (45)$$

Beweis (fortgeführt)

Damit folgt durch Umordnen der Summen

$$\begin{aligned} g(\kappa) &= \sum_{s=1}^r \sum_{j=1}^m \left(\ln(\mu_{sj}^{\kappa}) \sum_{i=1}^n y_{ij} p_{\theta^{(k-1)}}(x_i = \xi_s | y_i) + \ln(1 - \mu_{sj}^{\kappa}) \sum_{i=1}^n (1 - y_{ij}) p_{\theta^{(k-1)}}(x_i = \xi_s | y_i) \right) \\ &= \sum_{s=1}^r \sum_{j=1}^m \left(\ln(\mu_{sj}^{\kappa}) \rho_{js}^{(k-1)} + \ln(1 - \mu_{sj}^{\kappa}) \left(\nu_s^{(k-1)} - \rho_{js}^{(k-1)} \right) \right) \\ &= \sum_{j=1}^m \sum_{s=1}^r \left(\ln(\mu_{sj}^{\kappa}) \rho_{js}^{(k-1)} + \ln(1 - \mu_{sj}^{\kappa}) \left(\nu_s^{(k-1)} - \rho_{js}^{(k-1)} \right) \right) \end{aligned}$$

mit

$$\nu_s^{(k-1)} := \sum_{i=1}^n p_{\theta^{(k-1)}}(x_i = \xi_s | y_i) \text{ und } \rho_{js}^{(k-1)} := \sum_{i=1}^n y_{ij} p_{\theta^{(k-1)}}(x_i = \xi_s | y_i). \quad (46)$$

Insbesondere ist $g(\kappa)$ also itemweise separierbar:

$$g(\kappa) = \sum_{j=1}^m g_j(\kappa_j) \text{ mit } g_j(\kappa_j) := \sum_{s=1}^r \left(\ln(\mu_{sj}^{\kappa}) \rho_{js}^{(k-1)} + \ln(1 - \mu_{sj}^{\kappa}) \left(\nu_s^{(k-1)} - \rho_{js}^{(k-1)} \right) \right). \quad (47)$$

Birnbaum-Modell

Beweis (fortgeführt)

(3) M-Schritt Optimierung von $f(\pi)$

Wir sind auf das restringierte Optimierungsproblem

$$\max f(\pi) \text{ unter der Nebenbedingung } \sum_{s=1}^r \pi_s = 1 \quad (48)$$

für

$$f : \Pi^r \rightarrow \mathbb{R}, \pi \mapsto f(\pi) := \sum_{s=1}^r \ln(\pi_s) \nu_s^{(k-1)} \quad (49)$$

geführt, wobei Π^r den r -dimensionalen Wahrscheinlichkeitssimplex

$$\Pi^r := \left\{ \pi \in \mathbb{R}^r \mid \pi_s \geq 0 \text{ für } s = 1, \dots, r \text{ und } \sum_{s=1}^r \pi_s = 1 \right\} \quad (50)$$

bezeichnen soll. Wir erinnern zunächst an den Lagrangeansatz.

Lagrangeansatz zur Optimierung einer multivariaten Funktion unter Nebenbedingungen

Es sei

$$L(x, \lambda) = f(x) + \sum_{i=1}^m \lambda_i g_i(x) \quad (51)$$

die Lagrangefunktion zur Zielfunktion f und den Nebenbedingungsfunktionen g_i . Dann gelten an der Stelle eines lokalen Extremums x^* , das die Nebenbedingungen erfüllt, die folgenden notwendigen Bedingungen:

- (1) $\nabla_x L(x^*, \lambda^*) = 0 \Leftrightarrow \nabla f(x^*) + \sum_{i=1}^m \lambda_i^* \nabla g_i(x^*) = 0$
- (2) $\nabla_\lambda L(x^*, \lambda^*) = 0$
- (3) $g_i(x^*) = 0$ für alle $i = 1, \dots, m$

Beweis (fortgeführt)

Mit

$$\sum_{s=1}^r \pi_s = 1 \Leftrightarrow \sum_{s=1}^r \pi_s - 1 = 0 \Leftrightarrow: g_1(\pi) = 0 \quad (52)$$

ergibt sich die Lagrangefunktion von (48) als

$$L(\pi, \lambda) = \sum_{s=1}^r \ln(\pi_s) \nu_s^{(k-1)} + \lambda \left(\sum_{s=1}^r \pi_s - 1 \right) = \sum_{s=1}^r \ln(\pi_s) \nu_s^{(k-1)} + \lambda \sum_{s=1}^r \pi_s - \lambda. \quad (53)$$

Für die $s = 1, \dots, r$ Komponenten des Gradienten $\nabla_{\pi} L(\pi, \lambda)$ ergibt sich

$$\begin{aligned} \frac{\partial}{\partial \pi_s} L(\pi, \lambda) &= \frac{\partial}{\partial \pi_s} \left(\sum_{\tilde{s}=1}^r \ln(\pi_{\tilde{s}}) \nu_{\tilde{s}}^{(k-1)} + \lambda \sum_{\tilde{s}=1}^r \pi_{\tilde{s}} - \lambda \right) \\ &= \frac{\partial}{\partial \pi_s} \sum_{\tilde{s}=1}^r \ln(\pi_{\tilde{s}}) \nu_{\tilde{s}}^{(k-1)} + \lambda \frac{\partial}{\partial \pi_s} \sum_{\tilde{s}=1}^r \pi_{\tilde{s}} \\ &= \frac{\partial}{\partial \pi_s} \left(\ln(\pi_s) \nu_s^{(k-1)} \right) + \lambda \frac{\partial}{\partial \pi_s} \pi_s \\ &= \frac{\nu_s^{(k-1)}}{\pi_s} + \lambda \end{aligned} \quad (54)$$

Beweis (fortgeführt)

Für die eine Komponente des Gradienten $\nabla_{\lambda} L(\pi, \lambda)$ ergibt sich

$$\begin{aligned}\frac{\partial}{\partial \lambda} L(\pi, \lambda) &= \frac{\partial}{\partial \lambda} \left(\sum_{s=1}^r \ln(\pi_s) \nu_s^{(k-1)} + \lambda \sum_{s=1}^r \pi_s - \lambda \right) \\ &= \frac{\partial}{\partial \lambda} \sum_{s=1}^r \ln(\pi_s) \nu_s^{(k-1)} + \frac{\partial}{\partial \lambda} \lambda \sum_{s=1}^r \pi_s - \frac{\partial}{\partial \lambda} \lambda \\ &= \sum_{s=1}^r \pi_s - 1\end{aligned}\tag{55}$$

Mit der notwendigen Bedingung (1) gilt dann

$$\nabla_{\pi} L(\pi^*, \lambda^*) = 0 \Leftrightarrow \frac{\nu_s^{(k-1)}}{\pi_s^*} + \lambda^* = 0 \text{ für } s = 1, \dots, r \Leftrightarrow \pi_s^* = -\frac{\nu_s^{(k-1)}}{\lambda^*} \text{ für } s = 1, \dots, r\tag{56}$$

Mit der notwendigen Bedingung (2) (sowie auch mit der notwendigen Bedingung (3)) gilt

$$L_{\lambda}(\pi^*, \lambda^*) = 0 \Leftrightarrow \sum_{s=1}^r \pi_s^* - 1 = 0 \Leftrightarrow \sum_{s=1}^r \pi_s^* = 1.\tag{57}$$

Einsetzen von (1) in (2) erlaubt dann das Auflösen nach dem Lagrangemultiplikator

$$\sum_{s=1}^r \pi_s^* = 1 \Leftrightarrow -\sum_{s=1}^r \frac{\nu_s^{(k-1)}}{\lambda^*} = 1 \Leftrightarrow -\frac{1}{\lambda^*} \sum_{s=1}^r \nu_s^{(k-1)} = 1 \Leftrightarrow \lambda^* = -\sum_{s=1}^r \nu_s^{(k-1)}\tag{58}$$

Beweis (fortgeführt)

Einsetzen des Ergebnisses für λ^* in die Umformulierung von (1) ergibt dann

$$\begin{aligned}\pi_s^* &= \frac{\nu_s^{(k-1)}}{\sum_{\tilde{s}=1}^r \nu_{\tilde{s}}^{(k-1)}} \\ &= \frac{\nu_s^{(k-1)}}{\sum_{\tilde{s}=1}^r \sum_{i=1}^n p_{\theta^{(k-1)}}(x_i = \xi_{\tilde{s}} | y_i)} \\ &= \frac{\nu_s^{(k-1)}}{\sum_{i=1}^n \sum_{\tilde{s}=1}^r p_{\theta^{(k-1)}}(x_i = \xi_{\tilde{s}} | y_i)} \\ &= \frac{\nu_s^{(k-1)}}{\sum_{i=1}^n 1} \\ &= \frac{1}{n} \nu_s^{(k-1)}\end{aligned}\tag{59}$$

für $s = 1, \dots, r$, sodass die Parameterupdategleichung geschrieben werden kann als

$$\pi_s^{(k)} := \frac{1}{n} \nu_s^{(k-1)} \text{ für } s = 1, \dots, r.\tag{60}$$

Beweis (fortgeführt)

(4) M-Schritt Optimierung von $g(\kappa)$

Wir sind auf das restringierte Optimierungsproblem

$$\max g(\kappa) \text{ unter den Nebenbedingungen } \kappa_j \in \mathbb{R}_{>0} \times \mathbb{R} \times [0, 1) \text{ für } j = 1, \dots, m \quad (61)$$

mit

$$g(\kappa) := \sum_{j=1}^m g_j(\kappa_j) \quad (62)$$

und

$$g_j(\kappa_j) := \sum_{s=1}^r \left(\ln(\mu_{sj}^{\kappa_j}) \rho_{js}^{(k-1)} + \ln(1 - \mu_{sj}^{\kappa_j}) \left(\nu_s^{(k-1)} - \rho_{js}^{(k-1)} \right) \right) \quad (63)$$

mit

$$\nu_s^{(k-1)} := \sum_{i=1}^n p_{\theta(k-1)}(x_i = \xi_s | y_i) \text{ und } \rho_{js}^{(k-1)} := \sum_{i=1}^n y_{ij} p_{\theta(k-1)}(x_i = \xi_s | y_i) \quad (64)$$

sowie

$$p_{\theta(k-1)}(x_i = \xi_s | y_i) = \frac{\pi_s^{(k-1)} p_{\kappa(k-1)}(y_i | x_i = \xi_s)}{\sum_{\tilde{s}=1}^r \pi_{\tilde{s}}^{(k-1)} p_{\kappa(k-1)}(y_i | x_i = \xi_{\tilde{s}})} \quad (65)$$

geführt.

Beweis (fortgeführt)

Weil die Itemparameterblöcke $\kappa_1, \dots, \kappa_m$ disjunkt sind und gilt, dass

$$\max_{\kappa} g(\kappa) = \max_{\kappa} \sum_{j=1}^m g_j(\kappa_j) = \sum_{j=1}^m \max_{\kappa_j} g_j(\kappa_j), \quad (66)$$

kann die Maximierung von g bezüglich κ durch die Maximierung der g_j bezüglich κ_j für $j = 1, \dots, m$ durchgeführt werden. Es verbleiben also die m Optimierungsprobleme

$$\max g_j(\kappa_j) \text{ unter der Nebenbedingung } \kappa_j \in \mathbb{R}_{>0} \times \mathbb{R} \times [0, 1) \text{ für } j = 1, \dots, m \quad (67)$$

und damit

$$\kappa_j^{(k)} := \arg \max_{\kappa_j \in \mathbb{R}_{>0} \times \mathbb{R} \times [0, 1)} \sum_{s=1}^r \left(\ln(\mu_{sj}^{\kappa_j}) \rho_{js}^{(k-1)} + \ln(1 - \mu_{sj}^{\kappa_j}) (\nu_s^{(k-1)} - \rho_{js}^{(k-1)}) \right) \text{ für } j = 1, \dots, m. \quad (68)$$

□

Definition (Verteilungsform des Birnbaum-Modells nach Bock-Aitkin (1981))

Für $i = 1, \dots, n$ Personen, $j = 1, \dots, m$ dichotome Items, und $s = 1, \dots, r$ diskrete Fähigkeitswerte seien

- x_i die Zufallsvariable zur Modellierung der Eigenschaft von Person i mit Wertebereich $\{\xi_1, \dots, \xi_r\} \subset \mathbb{R}$,
- $x := (x_1, \dots, x_n)$ der Zufallsvektor der x_i ,
- y_{ij} die Zufallsvariable zur Modellierung der j ten Itemantwort von Person i mit Wertebereich $\{0, 1\}$,
- $y_i := (y_{i1}, \dots, y_{im})^T$ der Zufallsvektor der Itemantworten von Person i ,
- $y := (y_1, \dots, y_n)$ die Zufallsmatrix der y_i ,
- $\kappa := (a_j, b_j, c_j)_{j=1, \dots, m}$ die Itemparameter des Birnbaum-Modells mit $a_j > 0$, $b_j \in \mathbb{R}$ und $0 \leq c_j < 1$,
- $\theta := \kappa$ der Gesamtparameter.

Dann ist die *Verteilungsform des Birnbaum-Modells nach Bock-Aitkin (1981)* gegeben durch

$$p_\theta(x, y) := \prod_{i=1}^n p_\theta(x_i, y_i) := \prod_{i=1}^n p(x_i) p_\kappa(y_i | x_i) := \prod_{i=1}^n p(x_i) \prod_{j=1}^m p_{\kappa_j}(y_{ij} | x_i) \quad (69)$$

mit der *Personeneigenschaftsverteilung*

$$p(x_i) = \prod_{s=1}^r \pi_s^{\mathbb{I}[x_i = \xi_s]} \quad (70)$$

und der *Item-Response-Verteilung*

$$p_{\kappa_j}(y_{ij} | x_i) := \text{Bern}(\mu_{ij}^\kappa) \quad \text{mit} \quad \mu_{ij}^\kappa := c_j + (1 - c_j) \frac{1}{1 + \exp(-a_j(x_i - b_j))}. \quad (71)$$

Bemerkungen

- Formal ist das Birnbaum-Modell nach Bock & Aitkin (1981) zu Woodruff (1996) im Wesentlichen äquivalent.
- Die Modelle unterscheiden sich hinsichtlich Motivation und Interpretation der Personeneigenschaftsverteilung.
- Bock & Aitkin (1981) gehen von einer kontinuierlichen Verteilung $p(x_i) := N(0, 1)$ aus.
- Allerdings approximieren Bock & Aitkin (1981) diese durch eine diskrete Verteilung mit r Stützstellen.
- Speziell approximieren Bock & Aitkin (1981) die Marginalverteilung

$$p(y_i) = \int_{x_i} p(x_i) p_{\kappa}(y_i | x_i) dx_i, \quad (72)$$

die zur Berechnung von $p_{\theta(k-1)}(x_i | y_i)$ im E-Schritt benötigt wird, durch *Gauss-Hermite-Quadratur*

- Dazu wählen Bock & Aitkin (1981) r Stützstellen $\xi_1, \dots, \xi_r$ und Gewichte $\pi_1, \dots, \pi_r$ so, dass

$$\int_{x_i} p(x_i) p_{\kappa}(y_i | x_i) dx_i \approx \sum_{s=1}^r \pi_s p_{\kappa}(y_i | x_i = \xi_s). \quad (73)$$

- Die Stützstellen $\xi_1, \dots, \xi_r$ und Gewichte $\pi_1, \dots, \pi_r$ entnimmt man etwa Abramowitz & Stegun (1964).
- De facto approximieren Bock & Aitkin (1981) damit die kontinuierliche Verteilung $p(x_i)$ durch

$$p(x_i) \approx \prod_{s=1}^r \pi_s \mathbb{I}^{x_i = \xi_s} \text{ mit } \sum_{s=1}^r \pi_s = 1. \quad (74)$$

- Im Unterschied zu Woodruff (1996) ist die Personeneigenschaftsverteilung hier also nicht parameterisiert
- $\Rightarrow$ Die Werte der π_s sind bei Bock & Aitkin (1981) vorgegeben und werden nicht geschätzt.

Theorem (Birnbaum-Modell-EM-Algorithmus nach Bock-Aitkin (1981))

Gegeben sei die Verteilungsform des Birnbaum-Modells nach Bock-Aitkin (1981). Dann hat der EM-Algorithmus zur Schätzung der Itemparameter κ die Form:

0. Initialisierung von $\theta^{(0)} = \kappa^{(0)}$

Für $k = 1, 2, \dots$

1. E-Schritt: Setze $q^{(k)}(x) := p_{\theta^{(k-1)}}(x|y)$ mit

$$p_{\theta^{(k-1)}}(x|y) = \prod_{i=1}^n p_{\theta^{(k-1)}}(x_i|y_i) \quad (75)$$

und

$$p_{\theta^{(k-1)}}(x_i = \xi_s | y_i) = \frac{\pi_s p_{\kappa^{(k-1)}}(y_i | x_i = \xi_s)}{\sum_{\tilde{s}=1}^r \pi_{\tilde{s}} p_{\kappa^{(k-1)}}(y_i | x_i = \xi_{\tilde{s}})} \quad (76)$$

für alle $i = 1, \dots, n$ und $s = 1, \dots, r$.

2. M-Schritt: Es seien $\nu_s^{(k-1)} := \sum_{i=1}^n p_{\theta^{(k-1)}}(x_i = \xi_s | y_i)$ und $\rho_{js}^{(k-1)} := \sum_{i=1}^n y_{ij} p_{\theta^{(k-1)}}(x_i = \xi_s | y_i)$.

Dann gilt für $\theta^{(k)} = \kappa^{(k)}$, dass mit

$$\mu_{sj}^{\kappa} := c_j + (1 - c_j) \frac{1}{1 + \exp(-a_j(\xi_s - b_j))} \quad (77)$$

$$\kappa_j^{(k)} = \arg \max_{\kappa_j \in \mathbb{R}_{>0} \times \mathbb{R} \times [0,1]} \sum_{s=1}^r \left(\ln(\mu_{sj}^{\kappa}) \rho_{js}^{(k-1)} + \ln(1 - \mu_{sj}^{\kappa}) (\nu_s^{(k-1)} - \rho_{js}^{(k-1)}) \right) \quad (78)$$

für $j = 1, \dots, m$.

Theorem (Log-Marginal-Likelihood-Funktion des Bock-Aitkin-EM-Algorithmus)

Gegeben sei die Verteilungsform des Birnbaum-Modells nach Bock-Aitkin (1981) mit festen Stützstellen $\xi_1, \dots, \xi_r$ und festen Gewichten $\pi_1, \dots, \pi_r$ mit $\pi_s > 0$ und $\sum_{s=1}^r \pi_s = 1$. Dann ist die *Log-Marginal-Likelihood-Funktion* als Funktion von κ gegeben durch

$$\ell : K \rightarrow \mathbb{R}, \kappa \mapsto \ell(\kappa) := \sum_{i=1}^n \ln \left(\sum_{s=1}^r \pi_s \prod_{j=1}^m (\mu_{sj}^{\kappa})^{y_{ij}} (1 - \mu_{sj}^{\kappa})^{1-y_{ij}} \right), \quad (79)$$

wobei

$$\mu_{sj}^{\kappa} := c_j + (1 - c_j) \frac{1}{1 + \exp(-a_j(\xi_s - b_j))} \quad (80)$$

für $\kappa := (a_j, b_j, c_j)_{j=1, \dots, m}$.

Beweis

Es gilt

$$\begin{aligned}\ell(\kappa) &:= \ln \sum_x p_\theta(x, y) \\&= \ln \sum_{x_1} \cdots \sum_{x_n} \prod_{i=1}^n p_\theta(x_i, y_i) \\&= \ln \sum_{x_1} \cdots \sum_{x_n} \prod_{i=1}^n p(x_i) p_\kappa(y_i | x_i) \\&= \ln \prod_{i=1}^n \sum_{x_i} p(x_i) p_\kappa(y_i | x_i) \\&= \sum_{i=1}^n \ln \sum_{x_i} p(x_i) p_\kappa(y_i | x_i) \\&= \sum_{i=1}^n \ln \sum_{s=1}^r p(x_i = \xi_s) p_\kappa(y_i | x_i = \xi_s) \\&= \sum_{i=1}^n \ln \sum_{s=1}^r \pi_s \prod_{j=1}^m p_{\kappa_j}(y_{ij} | x_i = \xi_s) \\&= \sum_{i=1}^n \ln \sum_{s=1}^r \pi_s \prod_{j=1}^m (\mu_{sj}^\kappa)^{y_{ij}} (1 - \mu_{sj}^\kappa)^{1-y_{ij}}.\end{aligned}$$

□

Birnbaum-Modell

EM-Algorithmus nach Bock & Aitkin (1981)

```
# 3PL Modell Bernoulli-Erwartungswertparameter
mu = function(x,kappa){
  a  = kappa[1]          # Diskriminationsparameter
  b  = kappa[2]          # Schwierigkeitsparameter
  c  = kappa[3]          # Rateparameter
  mu = c + (1-c)*plogis(a*(x-b)) # Erwartungswertparameter
}

# g_j Funktionen
g_j = function(kappa_j, rho_js, nu_s){
  mu_s = mu(xi, kappa_j) # Berechnung der Erwartungswertparameter
  g_j = sum(log(mu_s)*rho_js + log(1-mu_s)*(nu_s - rho_js)) # Berechnung von g_j(\kappa_j)
}

# Log-Marginal-Likelihood-Funktion
ell = function(kappa, y, xi, pi){
  n  = nrow(y)          # Personenanzahl
  r  = length(xi)       # Anzahl der Stützstellen
  p_y_i = rep(0, n)     # Marginale Likelihood-Beiträge
  for(i in 1:n){        # Personeniterationen
    for(s in 1:r){      # Stützstelleniterationen
      mu_s = apply(kappa, 1, function(kappa_j) mu(xi[s], kappa_j)) # Erwartungswertparameter bei \xi_s
      p_y_i[i] = p_y_i[i] + pi[s]*prod(mu_s^y[i,])*prod((1-mu_s)^(1-y[i,])) # Marginaler Likelihood-Beitrag bei i
    }
  }
  ell = sum(log(p_y_i)) # Log-Marginal-Likelihood
}
```

EM-Algorithmus nach Bock & Aitkin (1981) (fortgesetzt)

```
# Einlesen der Daten
library(statmod)

y      = read.csv("2-Daten/2-irt.csv")      # Dateneinlesen
n      = nrow(y)                            # Personenanzahl
m      = ncol(y)                            # Itemanzahl

# Bock-Aitkin-EM-Algorithmus
k_max  = 8                                  # Maximale Anzahl an Iterationen
r      = 10                                # Anzahl der Stützstellen
gh     = gauss.quad.prob(n = r, dist = "normal") # Gauss-Hermite-Quadratur-Stützstellen und -Gewichte
xi     = gh$nodes                           # Stützstellen
pi     = gh$weights                         # Quadraturgewichte
kappa  = array(NA, dim = c(m, 3, k_max+1)) # Speicher für die Itemparameter
p_xgy  = array(NA, dim = c(n, r, k_max))   # Speicher für  $p(x_i = x_i_s | y_i)$ 
nu     = matrix(NA, nrow = r, ncol = k_max) # Speicher für die  $\nu_s$ 
rho    = array(NA, dim = c(m, r, k_max))   # Speicher für die  $\rho_{j_s}$ 
ell_k  = rep(NA, k_max+1)                  # Speicher für die Log-Marginal-Likelihood
opt     = list(method = "L-BFGS-B",         # Optimierungsalgorithmus
               lower = c(0.01, -Inf, 0),    # Untergrenzen für die Itemparameter
               upper = c(Inf, Inf, 0.99),   # Obergrenzen für die Itemparameter
               control = list(fnscale = -1)) # Maximierungsoption
```

EM-Algorithmus nach Bock & Aitkin (1981) (fortgesetzt)

```
# Initialisierung
kappa[,1] = matrix(c(.1,.1,.1), nrow = m, ncol = 3, byrow = TRUE) # Initialisierung der Itemparameter
ell_k[1] = ell(kappa[,1], y, xi, pi) # Log-Marginal-Likelihood des Startwertes

# Iterationen
for(k in 1:k_max){ # EM-Iterationen

  # E-Schritt
  # -----
  for(i in 1:n){ # Personeniterationen
    for(s in 1:r){ # Stützstelleniterationen
      mu_s = apply(kappa[,k],1,function(kappa_j) mu(xi[s], kappa_j)) # Erwartungswertparameter an Stützstelle s
      p_xgy[i,s,k] = pi[s]*prod(mu_s^y[i,])*prod((1-mu_s)^(1-y[i,])) # Unnormiertes Posteriorgewicht
    }
    p_xgy[i,,k] = p_xgy[i,,k]/sum(p_xgy[i,,k]) # Normierung von p(x_i | y_i)
  }
}
```

Birnbaum-Modell

EM-Algorithmus nach Bock & Aitkin (1981) (fortgesetzt)

```
# M-Schritt
# -----
# Berechnung von nu_s und rho_{js}
for(s in 1:r){
  nu[s,k] = sum(p_xgy[,s,k])
  for(j in 1:m){
    rho[j,s,k] = sum(y[,j]*p_xgy[,s,k])
  }
}

# Optimierung von g_j(\kappa_j) bezüglich \kappa_j
for(j in 1:m){
  kappa[j,,k+1] = optim(
    par      = kappa[j,,k],
    fn       = g_j,
    rho_js   = rho[j,,k],
    nu_s     = nu[,k],
    method    = opt$method,
    lower    = opt$lower,
    upper    = opt$upper,
    control   = opt$control
  )$par
  ell_k[k+1] = ell(kappa[, ,k+1], y, xi, pi)
}

# Speicherung der Ergebnisse
kappa_hat = kappa[, ,k+1]
p_xgy_hat = p_xgy[, ,k]
ell_hat   = ell_k[k+1]
```






Stützstelleniterationen
Berechnung von nu_s
Itemiterationen
Berechnung von rho_{js}

Itemiterationen
Optimierung der Itemparameter
Startwerte für die Optimierung
Zielfunktion
Übergabe der rho_{js} an die Zielfunktion
Übergabe der nu_s an die Zielfunktion
Optimierungsalgorithmus
Untergrenzen für die Itemparameter
Obergrenzen für die Itemparameter
Optimierungsoptionen
Rückgabe der optimierten Itemparameter

Log-Marginal-Likelihood

Speichern der geschätzten Itemparameter
Speichern der geschätzten Posteriorgewichte
Speichern der Log-Marginal-Likelihood

EM-Algorithmus nach Bock-Aitkin



Grundlagen

Birnbaum-Modell

Rasch-Modell

Selbstkontrollfragen

Überblick

Geschichte

- Entwickelt in den 1950er Jahren in der dänischen Bildungsforschung durch Georg Rasch (1901-1980)
- Für Anwender:innen popularisiert durch z.B. Wright & Panchapakesan (1969) und Wright (1977)

Grundlegende Motivationsrhetorik

- “In the present work a new approach to test-psychology is attempted” (Rasch (1960))
- “Spezifisch objektive” Messung psychologischer Eigenschaften von Einzelpersonen
- Verzicht auf Schätzung von “Populationsparametern” im Sinne der klassischen Testtheorie

Rhetorische messtheoretische Anbindung an physikalische Messungen

- Vergleiche von Objekteigenschaften (Masse, Temperatur) sollten unabhängig von Messinstrumenten sein
- Vergleiche von Messinstrumenten (Maßband, Thermometer) sollten unabhängig von Objekten sein

Invariante Vergleichseigenschaften bei psychologischen Messungen

- Personenvergleiche sollten unabhängig von den verwendeten Items sein.
- Itemvergleiche sollten unabhängig von den verwendeten Personen sein.

Aus dem Vorwort von B.D. Wright in Rasch (1960): “The psychometric research done by Rasch between 1951 and 1959, which he explains and illustrates in this book, marks the point at which psychometrics moved from being purely descriptive to become a science of objective measurement.”

Überblick

Zum Begriff der spezifischen Objektivität des Rasch-Modells

- Rasch bezeichnete die invarianten Vergleichseigenschaften seines Modells als “Spezifische Objektivität”
- Rhetorisches Ziel war die Abgrenzung sowohl von naiver Messobjektivität als auch von klassischen Testtheorien
- Grundidee der spezifischen Objektivität sind obige invariante Vergleichseigenschaften
- Dies gilt allerdings für das Modell, nicht notwendigerweise für die Realität

Die Objektivität ist hier “spezifisch” in Bezug

... auf die betrachteten Vergleiche

- Objektivität gilt immer für einzelne konkrete Vergleiche, wie Person 1 vs. Person 2 und Item 1 vs. Item 2

... auf das Modell, d. h., sie gilt nur, wenn

- das Rasch-Modell korrekt spezifiziert ist und die Annahmen des Modells erfüllt sind

... auf die Datenbasis

- Personenparameter sind objektiv bei gegebenen Items, Itemparameter sind objektiv bei gegebenen Personen

“Messung” als Konstruktion von Bedingungen, unter denen Vergleiche sinnvoll und invariant sind.

Das Rasch-Modell hat Bezüge zur additiv-konjunktiven Messung der Repräsentationstheorie (Luce & Tukey (1964))

Das Rasch-Modell ist mit der additiv-konjunktiven Messung aber nicht identisch, vgl. Kyngdon (2008)

Definition (Rasch-Modell)

Für $i = 1, \dots, n$ Personen und $j = 1, \dots, m$ dichotome Items seien

- $\xi_i > 0$ die *Personeneigenschaft* von Person i ,
- $\beta_j > 0$ der *Schwierigkeitsparameter* von Item j ,
- $\lambda_{ij} := \frac{\xi_i}{\beta_j}$ der *Situationsparameter* von Person i und Item j
- $\lambda_i := (\lambda_{ij})_{j=1, \dots, m}$ der *Situationsparametervektor* von Person i ,
- y_{ij} die Zufallsvariable zur Modellierung der j ten Itemantwort von Person i mit Wertebereich $\{0, 1\}$,
- $y_i := (y_{i1}, \dots, y_{im})^T$ der Zufallsvektor der Itemantworten von Person i ,

Dann heißt die Item-Response-Verteilung

$$p_{\lambda_i}(y_i) := \prod_{j=1}^m p_{\lambda_{ij}}(y_{ij}) \text{ mit } p_{\lambda_{ij}}(y_{ij}) := \left(\frac{\lambda_{ij}}{1 + \lambda_{ij}} \right)^{y_{ij}} \left(\frac{1}{1 + \lambda_{ij}} \right)^{1-y_{ij}} \quad (81)$$

Rasch-Modell.

Bemerkungen

- Im Gegensatz zum (zeitgenössischen) Birnbaum-Modell sind die Personeneigenschaften keine Zufallsvariablen
- Notationell schreiben wir $p(y|\theta)$, wenn θ zufällig ist, und $p_\theta(y)$, wenn es dies nicht ist
- $\prod_{j=1}^m p_{\lambda_{ij}}(y_{ij})$ modelliert die personeneigenschaftsbedingte Unabhängigkeit der Itemantworten

Bemerkungen (fortgeführt)

- Offenbar gelten für alle $i = 1, \dots, n$ und $j = 1, \dots, m$

$$p_{\lambda_{ij}}(y_{ij} = 1) = \frac{\lambda_{ij}}{1 + \lambda_{ij}} \quad (82)$$

sowie

$$p_{\lambda_{ij}}(y_{ij} = 0) = \frac{1}{1 + \lambda_{ij}} = \frac{1 + \lambda_{ij}}{1 + \lambda_{ij}} - \frac{\lambda_{ij}}{1 + \lambda_{ij}} = 1 - \frac{\lambda_{ij}}{1 + \lambda_{ij}} \quad (83)$$

Invariante Vergleichseigenschaften auf Parameterebene

- Der Vergleich der Personeneigenschaft zweier Personen $i = 1, 2$ ist unabhängig von dem betrachteten Item j :
- Für jedes Item $j = 1, \dots, m$ gilt

$$\frac{\lambda_{1j}}{\lambda_{2j}} = \frac{\frac{\xi_1}{\beta_j}}{\frac{\xi_2}{\beta_j}} = \frac{\xi_1}{\beta_j} \cdot \frac{\beta_j}{\xi_2} = \frac{\xi_1}{\xi_2} \quad (84)$$

- Der Vergleich der Itemschwierigkeiten zweier Items $j = 1, 2$ ist unabhängig von der betrachteten Person i :
- Für jede Person $i = 1, \dots, n$ gilt

$$\frac{\lambda_{i1}}{\lambda_{i2}} = \frac{\frac{\xi_i}{\beta_1}}{\frac{\xi_i}{\beta_2}} = \frac{\xi_i}{\beta_1} \cdot \frac{\beta_2}{\xi_i} = \frac{\beta_2}{\beta_1} \quad (85)$$

Theorem (Rasch-Modell und 1PL-Birnbaum-Modell)

Gegeben sei das Rasch-Modell. Seien ferner

$$x_i := \ln(\xi_i) \text{ und } b_j := \ln(\beta_j) \quad (86)$$

und x_i als Zufallsvariable konzipiert. Dann sind die Item-Response-Verteilungen des Rasch-Modells und des 1PL-Birnbaum-Modells identisch, es gilt also

$$p_{\lambda_i}(y_i) = p_{\kappa}(y_i|x_i). \quad (87)$$

Bemerkungen

- Im zeitgenössischen Birnbaum-Modell sind die Personeneigenschaften Zufallsvariablen, im Rasch-Modell nicht.
- Für eine Person i und ein Item j gelten nach dem Rasch-Modell also wie nach dem 1PL-Birnbaum-Modell

$$p_{x_i, b_j}(y_{ij} = 1) = \frac{1}{1 + \exp(-(x_i - b_j))} \text{ und } p_{x_i, b_j}(y_{ij} = 0) = 1 - \frac{1}{1 + \exp(-(x_i - b_j))} \quad (88)$$

Beweis

Wir zeigen die Äquivalenz für $y_{ij} = 1$, der Fall $y_{ij} = 0$ folgt analog:

$$\begin{aligned} p_{\lambda_{ij}}(y_{ij} = 1) &= \frac{\lambda_{ij}}{1 + \lambda_{ij}} \\ &= \frac{\frac{\xi_i}{\beta_j}}{1 + \frac{\xi_i}{\beta_j}} \\ &= \frac{\frac{\exp(\ln(\xi_i))}{\exp(\ln(\beta_j))}}{1 + \frac{\exp(\ln(\xi_i))}{\exp(\ln(\beta_j))}} \\ &= \frac{\exp(\ln(\xi_i) - \ln(\beta_j))}{1 + \exp(\ln(\xi_i) - \ln(\beta_j))} \\ &= \frac{\exp(x_i - b_j)}{1 + \exp(x_i - b_j)} \\ &= \frac{1}{1 + \exp(-(x_i - b_j))} \\ &= p_{\kappa_j}(y_{ij} = 1 | x_i) \text{ mit } \kappa_j = (1, b_j, 0) \end{aligned} \tag{89}$$

Im letzten Schritt haben wir die Personeneigenschaft dabei als Zufallsvariable konzipiert. Die lokale Unkorreliertheit von Birnbaum- und Rasch-Modell impliziert dann die im Theorem behauptete Äquivalenz.

Bemerkungen (fortgeführt)

- Für eine Person i und ein Item j gilt nach dem Rasch-Modell also wie nach dem 1PL-Birnbaum-Modell

$$p_{x_i, b_j}(y_{ij} = 1) = \frac{\exp(x_i - b_j)}{1 + \exp(x_i - b_j)} = \frac{\exp(1 \cdot (x_i - b_j))}{1 + \exp(x_i - b_j)} = \frac{\exp(y_{ij}(x_i - b_j))}{1 + \exp(x_i - b_j)} \quad (90)$$

sowie

$$\begin{aligned} p_{x_i, b_j}(y_{ij} = 0) &= 1 - \frac{\exp(x_i - b_j)}{1 + \exp(x_i - b_j)} \\ &= \frac{1 + \exp(x_i - b_j)}{1 + \exp(x_i - b_j)} - \frac{\exp(x_i - b_j)}{1 + \exp(x_i - b_j)} \\ &= \frac{1}{1 + \exp(x_i - b_j)} \\ &= \frac{\exp(0)}{1 + \exp(x_i - b_j)} \\ &= \frac{\exp(0 \cdot (x_i - b_j))}{1 + \exp(x_i - b_j)} \\ &= \frac{\exp(y_{ij}(x_i - b_j))}{1 + \exp(x_i - b_j)} \end{aligned} \quad (91)$$

- Man schreibt deshalb

$$p_{x_i, b_j}(y_{ij}) = \frac{\exp(y_{ij}(x_i - b_j))}{1 + \exp(x_i - b_j)} \quad (92)$$

Bemerkungen (fortgeführt)

Invariante Vergleichseigenschaften auf der Ebene von Odds-Ratios

- Bei dichotomen Ereignissen $y = 0$ oder $y = 1$ wird häufig von *Odds* (Chancen) gesprochen
- Odds bezeichnen das Verhältnis der Eintrittschance zur Nichteintrittschance,

$$\text{Odds} := \frac{p(y=1)}{p(y=0)} \quad (93)$$

- Zum Beispiel gilt

$$p(y=1) = \frac{1}{4} \text{ und } p(y=0) = \frac{3}{4} \Rightarrow \text{Odds} = \frac{1}{4} \cdot \frac{4}{3} = \frac{1}{3} \text{ ("Chance von 1 zu 3")}. \quad (94)$$

- *Odds-Ratio (OR)* vergleicht die Odds zwischen zwei Dingen

$$\text{Odds-Ratio} := \frac{\text{Odds}_1}{\text{Odds}_2} = \frac{\frac{p_1(y=1)}{p_1(y=0)}}{\frac{p_2(y=1)}{p_2(y=0)}} \quad (95)$$

Zum Beispiel gilt bei Odds von 1:4 und 1:10 unter zwei Bedingungen

$$\text{Odds-Ratio} := \frac{\text{Odds}_1}{\text{Odds}_2} = \frac{\frac{1}{4}}{\frac{1}{10}} = 2.5 \quad (96)$$

- Die erste Bedingung (1:4) weist 2,5-fach höhere Odds für das Ereignis auf als die zweite Bedingung (1:10).
- Das Odds-Ratio wird häufig in klinischen Fall-Kontroll-Studien verwendet
- Popularität von Odds-Ratios als Belege für Assoziation von Rauchen und Lungenkrebs (vgl. Doll & Hill (1950))

Bemerkungen (fortgeführt)

Invariante Vergleichseigenschaften auf der Ebene von Odds-Ratios

- Die Odds für eine richtige Antwort von Person i in Item j sind nach dem Rasch-Modell

$$\text{Odds}_{ij} = \frac{p_{x_i, b_j}(y_{ij} = 1)}{p_{x_i, b_j}(y_{ij} = 0)} = \frac{\frac{\exp(1 \cdot (x_i - b_j))}{1 + \exp(x_i - b_j)}}{\frac{\exp(0 \cdot (x_i - b_j))}{1 + \exp(x_i - b_j)}} = \frac{\exp(x_i - b_j)}{1 + \exp(x_i - b_j)} \cdot (1 + \exp(x_i - b_j)) = \exp(x_i - b_j)$$

- Die Odds-Ratio für eine richtige Antwort von Person i und Person i' in Item j ist nach dem Rasch-Modell

$$\text{Odds-Ratio}_{ii'} = \frac{\exp(x_i - b_j)}{\exp(x_{i'} - b_j)} = \exp(x_i - b_j - x_{i'} + b_j) = \exp(x_i - x_{i'}) \quad (97)$$

- Die Log-Odds-Ratio für eine richtige Antwort von Person i und Person i' in Item j ist nach dem Rasch-Modell

$$\text{Log-Odds-Ratio}_{ii'} = x_i - x_{i'} \quad (98)$$

und hängt damit nur von den Eigenschaften von Personen i und i' aber nicht von dem gewählten Item ab.

- Die Odds-Ratio für eine richtige Antwort von Person i in Item j und Item j' ist nach dem Rasch-Modell

$$\text{Odds-Ratio}_{jj'} = \frac{\exp(x_i - b_j)}{\exp(x_i - b_{j'})} = \exp(x_i - b_j - x_i + b_{j'}) = \exp(b_{j'} - b_j) \quad (99)$$

- Die Log-Odds-Ratio für eine richtige Antwort von Person i in Item j und Item j' ist nach dem Rasch-Modell

$$\text{Log-Odds-Ratio}_{jj'} = b_{j'} - b_j \quad (100)$$

und hängt damit nur von den Eigenschaften der Items j und j' , aber nicht von der betrachteten Person ab.

Überblick zur Parameterschätzung

Conditional-Maximum-Likelihood-Schätzung (CML)

- Personeneigenschaften werden durch eine suffiziente Statistik aus der Likelihood “herauskonditioniert”
- Die Itemparameter werden dann durch Maximierung dieser bedingten Likelihood geschätzt
- Itemparameterschätzungen sind konsistent, ohne dass Annahmen über Eigenschaftsverteilungen nötig sind
- Anwendung nur beim Rasch-Modell, auf 2PL oder 3PL nicht anwendbar (keine suffizienten Statistiken)
- Klare Trennung zwischen “Itemkalibrierung” und “Personenmessung”

Suffiziente Statistik

- Eine Statistik heißt suffizient, wenn sie alle in Daten enthaltenen Parameterinformationen vollständig erfasst
- Die bedingte Verteilung der Daten bei gegebener suffizienter Statistik hängt nicht vom Parameter ab
- Die Parameter von Interesse sind hier die Personeneigenschaften $x_1, \dots, x_n$
- Im Rasch-Modell ist der Summenscore (Anzahl gelöster Items) eine suffiziente Statistik für $x_1, \dots, x_n$
- Man kann die Likelihood nur in Abhängigkeit der Itemparameter schreiben

Überblick zur Parameterschätzung

Wie im Rahmen der MML-Schätzung wird das Rasch-Modell auch im Rahmen der Conditional-Maximum-Likelihood-Schätzung als parameterisiertes Modell konzipiert, wobei die Personeneigenschaften $x_i, i = 1, \dots, n$ allerdings als nicht zufällige Parameter eingehen. In diesem Kontext werden sie z. T. auch als “nuisance parameter”, also als Nebeneffekts- oder Störparameter bezeichnet. Seien formal also wieder

- y die Gesamtheit aller nm beobachteten Datenpunkte,
- x die Gesamtheit aller n Personeneigenschaften,
- b der Vektor aller Itemschwierigkeitsparameter.

Das Rasch-Modell entspricht dann der durch x und b parameterisierten Wahrscheinlichkeitsverteilung $p_{x,b}(y)$. Grundlegende Idee der CML-Schätzung ist es, durch Konditionierung auf eine suffiziente Statistik s für x die Personeneigenschaftsparameter aus der Likelihood-Funktion herauszurechnen und dann die Itemschwierigkeitsparameter ohne die Notwendigkeit einer Schätzung der Personeneigenschaften schätzen zu können. Betrachtet wird also die bedingte Likelihood-Funktion

$$L : b \rightarrow \mathbb{R}_{>0}, b \mapsto L(b) := p_b(y|s) \quad (101)$$

Statistisch abgesichert im Sinne sich ergebender konsistenter und asymptotisch normalverteilter Schätzer für die Itemparameter b ist dieses Verfahren durch Andersen (1970). Wir führen im Folgenden kurz den Begriff der suffizienten Statistik ein und betrachten dann das Rasch-Modell in diesem Lichte.

Theorem (Suffiziente Statistik)

Es sei $y := (y_1, \dots, y_n)$ eine Stichprobe mit durch θ parameterisierter gemeinsamer Verteilung $p_\theta(y)$ und $s = s(y)$ sei eine Statistik. s wird *suffiziente Statistik* für den Parameter θ genannt, wenn eine der folgenden äquivalenten Bedingungen gilt:

- (1) Die bedingte Verteilung von y gegeben s hängt nicht von θ ab, also

$$p_\theta(y|s) = p(y|s). \quad (102)$$

- (2) Es existieren Funktionen $g_\theta(s)$ und $h(y)$, sodass

$$p_\theta(y) = g_\theta(s)h(y) \text{ für alle } y \text{ und alle } \theta. \quad (103)$$

Bemerkungen

- Es handelt sich um eine mathematisch sehr unpräzise Darstellung der Suffizienz.
- Eine Einführung zum Prinzip der Suffizienz findet sich z.B. in Casella & Berger (2002), Abschnitt 6.
- Würde man θ als Zufallsvariable betrachten, so wäre (1) äquivalent zu der bedingten Unabhängigkeit

$$p(y|s, \theta) = p(y|s). \quad (104)$$

- Aussage (2) wird nach (oder trotz) Halmos & Savage (1949) *Neyman-Fisher-Faktorisierung* genannt.

Beweis

Wir zeigen zunächst (2) $\Rightarrow$ (1). Es gelte also $p_\theta(y) = g_\theta(s)h(y)$ und wir betrachten die gemeinsame Verteilung von y und s . Setzt man die Kongruenz von s und y voraus, nimmt also an, dass

$$p_\theta(s|y) = 1 \text{ für } s = s(y) \text{ und } p_\theta(s|y) = 0 \text{ für } s \neq s(y), \quad (105)$$

so gilt für die gemeinsame Verteilung von y und s , dass

$$p_\theta(y, s) = p_\theta(s|y)p_\theta(y) = 1 \cdot p_\theta(y) = p_\theta(y) \text{ für alle } y \text{ und } s \text{ mit } s = s(y). \quad (106)$$

Betrachtet man dann die bedingte Verteilung von y gegeben s , so ergibt sich

$$\begin{aligned} p_\theta(y|s) &= \frac{p_\theta(y, s)}{\int_{y'} p_\theta(y', s) dy'} \\ &= \frac{p_\theta(y)}{\int_{y': s(y')=s} p_\theta(y', s) dy'} \\ &= \frac{p_\theta(y)}{\int_{y': s(y')=s} p_\theta(y') dy'} \\ &= \frac{g_\theta(s)h(y)}{\int_{y': s(y')=s} g_\theta(s)h(y') dy'} \\ &= \frac{g_\theta(s)h(y)}{g_\theta(s) \int_{y': s(y')=s} h(y') dy'} \\ &= \frac{h(y)}{\int_{y': s(y')=s} h(y') dy'} \end{aligned} \quad (107)$$

und die rechte Seite hängt nicht mehr von θ ab und kann als $p(y|s)$ geschrieben werden.

Beweis (fortgeführt)

Wir zeigen nun $(1) \Rightarrow (2)$. s sei also suffizient, das heißt,

$$p_{\theta}(y|s) = p(y|s) \quad (108)$$

Zunächst ergibt sich, wiederum unter Annahme der Kongruenz von s und y , dass

$$p_{\theta}(s|y) = 1 \text{ für } s = s(y) \text{ und } p_{\theta}(s|y) = 0 \text{ für } s \neq s(y) \quad (109)$$

und damit

$$p_{\theta}(y, s) = p_{\theta}(s|y)p_{\theta}(y) = 1 \cdot p_{\theta}(y) = p_{\theta}(y) \text{ für alle } y \text{ und } s \text{ mit } s = s(y). \quad (110)$$

Dann aber ergibt sich für $p_{\theta}(y)$, dass

$$p_{\theta}(y) = p_{\theta}(y, s) = p_{\theta}(s)p_{\theta}(y|s) = p_{\theta}(s)p(y|s) =: g_{\theta}(s)h(y). \quad (111)$$

Definition (Verteilungsform des Rasch-Modells)

Für $i = 1, \dots, n$ Personen und $j = 1, \dots, m$ dichotome Items seien

- $x_i \in \mathbb{R}$ die Personeneigenschaft von Person i
- $x := (x_1, \dots, x_n)$ die Eigenschaften aller n Personen,
- $b_j \in \mathbb{R}$ der Schwierigkeitsparameter des j -ten Items,
- $b := (b_1, \dots, b_m)$ der Itemparametervektor,
- y_{ij} die Zufallsvariable zur Modellierung der j -ten Itemantwort von Person i mit Wertebereich $\{0, 1\}$,
- $y_i := (y_{i1}, \dots, y_{im})$ der Zufallsvektor der Itemantworten von Person i ,
- $y := (y_1, \dots, y_n)$ die Zufallsmatrix der Itemantworten aller Personen.

Dann hat das Rasch-Modell die Verteilungsform

$$p_{x,b}(y) := \prod_{i=1}^n p_{x_i,b}(y_i) := \prod_{i=1}^n \prod_{j=1}^m p_{x_i,b_j}(y_{ij}), \text{ mit } p_{x_i,b_j}(y_{ij}) := \frac{\exp(y_{ij}(x_i - b_j))}{1 + \exp(x_i - b_j)}. \quad (112)$$

Bemerkungen

- $\prod_{i=1}^n p_{x_i,b}(y_i)$ kodiert die Unabhängigkeitsannahme über Personen.
- $\prod_{j=1}^m p_{x_i,b_j}(y_{ij})$ kodiert die bedingte Unabhängigkeit der Itemantworten von Person i bei gegebenem x_i .

Theorem (Summenschore-bedingte Verteilung des Rasch-Modells)

Gegeben sei die Verteilungsform des Rasch-Modells und für $i = 1, \dots, n$ sei

$$s_i := \sum_{j=1}^m y_{ij} \quad (113)$$

der Summenschore von Person i . Sei weiterhin für alle $s_i \in \{0, \dots, m\}$

$$Y_{s_i} := \left\{ y_i \in \{0, 1\}^m \mid \sum_{j=1}^m y_{ij} = s_i \right\} \quad (114)$$

die Menge aller zu einem Summenschore s_i kongruenten Itemantwortvektoren einer Person. Sei schließlich

$$s := (s_1, \dots, s_n) \quad (115)$$

der Vektor der Summenscores aller n Personen. Dann gilt für die Verteilungsform des Rasch-Modells

$$p_{x,b}(y|s) = p_b(y|s) \quad (116)$$

und speziell

$$p_b(y|s) = \prod_{i=1}^n p_b(y_i|s_i) \text{ mit } p_b(y_i|s_i) = \frac{\exp\left(-\sum_{j=1}^m y_{ij} b_j\right)}{\sum_{y_i \in Y_{s_i}} \exp\left(-\sum_{j=1}^m y_{ij} b_j\right)}. \quad (117)$$

Bemerkung

- Die Aussage des Theorems wird auch als "Parameterseparierbarkeit" bezeichnet.

Beweis

Wir zeigen zunächst

$$p_{x_i,b}(y_i|s_i) = p_b(y_i|s_i) \text{ mit } p_b(y_i|s_i) = \frac{\exp\left(-\sum_{j=1}^m y_{ij}b_j\right)}{\sum_{y_i \in Y_{s_i}} \exp\left(-\sum_{j=1}^m y_{ij}b_j\right)}. \quad (118)$$

Nach Definition der bedingten Wahrscheinlichkeit gilt

$$p_{x_i,b}(y_i|s_i) = \frac{p_{x_i,b}(y_i, s_i)}{\sum_{y_i} p_{x_i,b}(y_i, s_i)} = \frac{p_{x_i,b}(y_i)p_{x_i,b}(s_i|y_i)}{\sum_{y_i} p_{x_i,b}(y_i)p_{x_i,b}(s_i|y_i)} \quad (119)$$

Da definitionsgemäß gilt, dass

$$s_i := \sum_{j=1}^m y_{ij}, \quad (120)$$

also s_i deterministisch von y_i abhängt, ist die bedingte Verteilung des Summscores s_i bei gegebenen Itemantworten y_{ij} für $j = 1, \dots, m$ der i -ten Person degeneriert, d. h., sie nimmt nur die Werte 0 oder 1 an. Speziell gilt

$$p_{x_i,b}(s_i|y_i) = \left[s_i = \sum_{j=1}^m y_{ij} \right] = \begin{cases} 1 & \text{für } s_i = \sum_{j=1}^m y_{ij} \\ 0 & \text{für } s_i \neq \sum_{j=1}^m y_{ij} \end{cases} \quad (121)$$

Beweis (fortgeführt)

Dabei stellen wir zum einen fest, dass die bedingte Verteilung des Summenscores bei gegebenen Itemantworten der i -ten Person weder von der Personeneigenschaft x_i noch vom Itemparametervektor b abhängt, also gilt

$$p_{x_i, b}(s_i | y_i) = p(s_i | y_i). \quad (122)$$

Zum anderen stellen wir fest, dass (119) nur im Falle der Kongruenz von s_i und y_i von null verschieden ist. Wir schränken unsere Betrachtungen deshalb im Folgenden auf den kongruenten Fall $s_i = \sum_{j=1}^m y_{ij}$ und damit $p(s_i | y_i) = 1$ ein. Es ergibt sich mit dieser Einschränkung also

$$p_{x_i, b}(y_i | s_i) = \frac{p_{x_i, b}(y_i) p(s_i | y_i)}{\sum_{y_i} p_{x_i, b}(y_i) p(s_i | y_i)} = \frac{p_{x_i, b}(y_i)}{\sum_{y_i \in Y_{s_i}} p_{x_i, b}(y_i)} \quad (123)$$

Wir betrachten nun zunächst den Zähler von (123). Es gilt

Beweis (fortgeführt)

$$\begin{aligned} p_{x_i, b}(y_i) &= \prod_{j=1}^m p_{x_i, b_j}(y_{ij}) \\ &= \prod_{j=1}^m \frac{\exp(y_{ij}(x_i - b_j))}{1 + \exp(x_i - b_j)} \\ &= \frac{\prod_{j=1}^m \exp(y_{ij}(x_i - b_j))}{\prod_{j=1}^m (1 + \exp(x_i - b_j))} \\ &= \frac{\exp\left(\sum_{j=1}^m y_{ij}(x_i - b_j)\right)}{\prod_{j=1}^m (1 + \exp(x_i - b_j))} \\ &= \frac{\exp\left(\sum_{j=1}^m y_{ij}x_i - \sum_{j=1}^m y_{ij}b_j\right)}{\prod_{j=1}^m (1 + \exp(x_i - b_j))} \\ &= \frac{\exp\left(x_i \sum_{j=1}^m y_{ij} - \sum_{j=1}^m y_{ij}b_j\right)}{\prod_{j=1}^m (1 + \exp(x_i - b_j))} \\ &= \frac{\exp\left(x_i s_i - \sum_{j=1}^m y_{ij}b_j\right)}{\prod_{j=1}^m (1 + \exp(x_i - b_j))} \\ &= \frac{\exp(x_i s_i) \exp\left(-\sum_{j=1}^m y_{ij}b_j\right)}{\prod_{j=1}^m (1 + \exp(x_i - b_j))} \end{aligned} \tag{124}$$

Beweis (fortgeführt)

Für den Nenner von (123) gilt damit

$$\begin{aligned}\sum_{y_i \in Y_{s_i}} p_{x_i, b}(y_i) &= \sum_{y_i \in Y_{s_i}} \frac{\exp(x_i s_i) \exp\left(-\sum_{j=1}^m y_{ij} b_j\right)}{\prod_{j=1}^m (1 + \exp(x_i - b_j))} \\&= \left(\prod_{j=1}^m (1 + \exp(x_i - b_j)) \right)^{-1} \exp(x_i s_i) \sum_{y_i \in Y_{s_i}} \exp\left(-\sum_{j=1}^m y_{ij} b_j\right) \\&= \frac{\exp(x_i s_i) \sum_{y_i \in Y_{s_i}} \exp\left(-\sum_{j=1}^m y_{ij} b_j\right)}{\prod_{j=1}^m (1 + \exp(x_i - b_j))}.\end{aligned}\tag{125}$$

Es ergibt sich also

$$\begin{aligned}p_{x_i, b}(y_i | s_i) &= \frac{\exp(x_i s_i) \exp\left(-\sum_{j=1}^m y_{ij} b_j\right)}{\prod_{j=1}^m (1 + \exp(x_i - b_j))} \cdot \frac{\prod_{j=1}^m (1 + \exp(x_i - b_j))}{\exp(x_i s_i) \sum_{y_i \in Y_{s_i}} \exp\left(-\sum_{j=1}^m y_{ij} b_j\right)} \\&= \frac{\exp\left(-\sum_{j=1}^m y_{ij} b_j\right)}{\sum_{y_i \in Y_{s_i}} \exp\left(-\sum_{j=1}^m y_{ij} b_j\right)}.\end{aligned}\tag{126}$$

Damit hängt $p_{x_i, b}(y_i | s_i)$ aber nicht mehr von x_i ab und es gilt

$$p_{x_i, b}(y_i | s_i) = p_b(y_i | s_i).\tag{127}$$

Beweis (fortgeführt)

Wir betrachten nun die gemeinsame bedingte Verteilung $p_{x,b}(y|s)$. Dazu halten wir zunächst mit der Definition der bedingten Wahrscheinlichkeit fest, dass

$$p_{x,b}(y|s) = \frac{p_{x,b}(y, s)}{p_{x,b}(s)} = \frac{p_{x,b}(y, s)}{\sum_y p_{x,b}(y, s)} = \frac{p_{x,b}(y)p_{x,b}(s|y)}{\sum_y p_{x,b}(y)p_{x,b}(s|y)}. \quad (128)$$

Wir betrachten nun die bedingte Verteilung des Summenvektors s bei gegebener Itemantwortmatrix aller Personen y . Mit der Definition von $s_i := \sum_{j=1}^m y_{ij}$ für alle $i = 1, \dots, n$ gilt zunächst, dass auch diese Verteilung unabhängig von x und b ist. Weiterhin ist auch diese Verteilung degeneriert, nimmt also nur die Werte 0 und 1 an. Speziell gilt

$$p(s|y) = \left[s_i = \sum_{j=1}^m y_{ij} \text{ für alle } i = 1, \dots, n \right]. \quad (129)$$

Damit gilt dann aber auch

$$p(s|y) = \prod_{i=1}^n p(s_i|y_i) \text{ mit } p(s_i|y_i) = \left[s_i = \sum_{j=1}^m y_{ij} \right]. \quad (130)$$

Mit der Verteilungsform des Rasch-Modells, der Tatsache, dass die Summation über y äquivalent zur sequentiellen Summation über $y_1, \dots, y_n$ ist, unter Einschränkung auf den kongruenten Fall $s_i = \sum_{j=1}^m y_{ij}$ (und damit $p(s_i|y_i) = 1$) für alle $i = 1, \dots, n$ und mit obigem Ergebnis zu $p_{x_i,b}(y_i|s_i)$ können wir (128) also schreiben als

Beweis (fortgeführt)

$$\begin{aligned} p_{x,b}(y|s) &= \frac{\prod_{i=1}^n p_{x_i,b}(y_i) \prod_{i=1}^n p(s_i|y_i)}{\sum_{y_1} \cdots \sum_{y_n} \prod_{i=1}^n p_{x_i,b}(y_i) \prod_{i=1}^n p(s_i|y_i)} \\ &= \frac{\prod_{i=1}^n p_{x_i,b}(y_i) p(s_i|y_i)}{\sum_{y_1} \cdots \sum_{y_n} \prod_{i=1}^n p_{x_i,b}(y_i) p(s_i|y_i)} \\ &= \frac{\prod_{i=1}^n p_{x_i,b}(y_i) p(s_i|y_i)}{\prod_{i=1}^n \sum_{y_i} p_{x_i,b}(y_i) p(s_i|y_i)} \\ &= \frac{\prod_{i=1}^n p_{x_i,b}(y_i)}{\prod_{i=1}^n \sum_{y_i \in Y_{s_i}} p_{x_i,b}(y_i)} \tag{131} \\ &= \prod_{i=1}^n \frac{p_{x_i,b}(y_i)}{\sum_{y_i \in Y_{s_i}} p_{x_i,b}(y_i)} \\ &= \prod_{i=1}^n p_{x_i,b}(y_i|s_i) \\ &= \prod_{i=1}^n p_b(y_i|s_i). \end{aligned}$$

Beweis (fortgeführt)

Wir können $p_{x,b}(y|s)$ also schreiben als

$$p_{x,b}(y|s) = p_b(y|s) = \prod_{i=1}^n p_b(y_i|s_i) = \prod_{i=1}^n \frac{\exp\left(-\sum_{j=1}^m y_{ij}b_j\right)}{\sum_{y_i \in Y_{s_i}} \exp\left(-\sum_{j=1}^m y_{ij}b_j\right)} \quad (132)$$

und damit ist alles gezeigt.

□

Definition (Rasch-Modell Conditional-Maximum-Likelihood-Schätzung)

Gegeben sei die Verteilungsform des Rasch-Modells und es sei $p_b(y|s)$ die Summenscore-bedingte Verteilung des Rasch-Modells. Dann heißt die Funktion

$$L : \mathbb{R}^m \rightarrow \mathbb{R}_{>0}, b \mapsto L(b) := p_b(y|s) \quad (133)$$

die *Conditional-Likelihood-Funktion* des Rasch-Modells. Ein

$$\hat{b} \in \arg \max_{b \in \mathbb{R}^m} L(b) \quad (134)$$

heißt *Conditional-Maximum-Likelihood-Schätzer* von b .

Bemerkungen

- Die Schätzung der Itemparameter b kommt ohne die Bestimmung der Personeneigenschaften $x_1, \dots, x_n$ aus.
- Als konsistentes Schätzverfahren für b ist dieses Vorgehen durch Andersen (1970) begründet worden.
- Die Anwendung der CML-Schätzung für das Rasch-Modell wurde durch Andersen (1977) geprägt.

Bemerkungen (fortgeführt)

- Für $m > 2$ muss $\hat{b}$ durch numerische Maximierung von L bestimmt werden.
- Für $m > 15$ ist eine explizite Summation über Y_{s_i} nicht möglich, es gilt

$$|Y_{s_i}| = \binom{m}{s_i} \text{ mit z.B. } \binom{30}{15} = 155.117.520 \quad (135)$$

- Es gibt rekursive Ansätze, um diese explizite Summation zu umgehen (Gustafsson (1977), Gustafsson (1980)).
- Diese Ansätze heißen *elementary symmetric functions* (Fischer (1995), Baker & Harwell (1996)).
- Der Ansatz ist nicht symmetrisch, Eigenschaften können nicht ohne Itemparameter bestimmt werden.

Generell sind CML-Ansätze möglich, wenn

- die Datenverteilung zur Exponentialfamilie gehört und
- suffiziente Statistiken für Nebeneffekt-Parameter wie die Personeneigenschaften existieren.
- Beispielmodelle sind das Partial-Credit-Modell oder das Cox-Proportional-Hazards-Modell der Survival-Analyse

Grundlagen

Birnbaum-Modell

Rasch-Modell

Selbstkontrollfragen

1. Geben Sie die Definition der logistischen Funktion wieder.
2. Geben Sie das Theorem zu den Eigenschaften der logistischen Funktion wieder.
3. Geben Sie die Definition des Birnbaum-Modells wieder.
4. Erläutern Sie die Bedeutung des Itemschwierigkeitsparameters des Birnbaum-Modells.
5. Erläutern Sie die Bedeutung des Itemdiskriminationsparameters des Birnbaum-Modells.
6. Erläutern Sie die Bedeutung des Itemrateparameters des Birnbaum-Modells.
7. Erläutern Sie den Begriff der spezifischen Objektivität im Kontext des Rasch-Modells.
8. Geben Sie die Definition des Rasch-Modells wieder.
9. Geben Sie das Theorem zum Rasch-Modell und 1PL-Birnbaum-Modell wieder.
10. Erläutern Sie die invarianten Vergleichseigenschaften des Rasch-Modells auf Parameterebene.
11. Erläutern Sie die invarianten Vergleichseigenschaften des Rasch-Modells auf Odds-Ratio-Ebene.

Jensensche Ungleichung

Theorem (Jensensche Ungleichung)

ξ sei eine Zufallsvariable und $g : \mathbb{R} \rightarrow \mathbb{R}$ eine konvexe Funktion, d. h.,

$$g(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda g(x_1) + (1 - \lambda)g(x_2) \quad (136)$$

für alle $x_1, x_2 \in \mathbb{R}, \lambda \in [0, 1]$. Dann gilt

$$\mathbb{E}(g(\xi)) \geq g(\mathbb{E}(\xi)). \quad (137)$$

Analog sei $g : \mathbb{R} \rightarrow \mathbb{R}$ eine konkave Funktion, d. h.,

$$g(\lambda x_1 + (1 - \lambda)x_2) \geq \lambda g(x_1) + (1 - \lambda)g(x_2) \quad (138)$$

für alle $x_1, x_2 \in \mathbb{R}, \lambda \in [0, 1]$. Dann gilt


$$\mathbb{E}(g(\xi)) \leq g(\mathbb{E}(\xi)). \quad (139)$$

Bemerkungen

- Bei konvexem g liegt der Funktionsgraph unter der Geraden von $g(x_1)$ zu $g(x_2)$.
- Bei konkavem g liegt der Funktionsgraph über der Geraden von $g(x_1)$ zu $g(x_2)$.
- Der Logarithmus ist eine konkave Funktion, also gilt $\mathbb{E}(\ln \xi) \leq \ln \mathbb{E}(\xi)$.

Visualisierung einer konvexen Funktion

$$— g(x) := x^2$$



$$— \lambda g(x_1) + (1 - \lambda)g(x_2) \text{ für } x_1 := -\sqrt{1.5}, x_2 := \sqrt{3.5}, \lambda \in [0, 1]$$

$$— t(x) := g(x_0) + g'(x_0)(x - x_0) \text{ für } x_0 := 1$$

Jensensche Ungleichung

Beweis

Es sei g eine konvexe Funktion. Dann gilt für die Tangente t von g in $x_0 \in \mathbb{R}$ für alle $x \in \mathbb{R}$, dass

$$g(x) \geq t(x) := g(x_0) + g'(x_0)(x - x_0) \quad (140)$$

Wir setzen nun $x := \xi$ und $x_0 := \mathbb{E}(\xi)$. Dann gilt mit obiger Ungleichung, dass

$$g(\xi) \geq g(\mathbb{E}(\xi)) + g'(\mathbb{E}(\xi))(\xi - \mathbb{E}(\xi)) \quad (141)$$

Erwartungswertbildung ergibt dann

$$\begin{aligned} \mathbb{E}(g(\xi)) &\geq \mathbb{E}(g(\mathbb{E}(\xi))) + \mathbb{E}(g'(\mathbb{E}(\xi))(\xi - \mathbb{E}(\xi))) \\ &\Leftrightarrow \mathbb{E}(g(\xi)) \geq g(\mathbb{E}(\xi)) + g'(\mathbb{E}(\xi))\mathbb{E}((\xi - \mathbb{E}(\xi))) \\ &\Leftrightarrow \mathbb{E}(g(\xi)) \geq g(\mathbb{E}(\xi)) + g'(\mathbb{E}(\xi))(\mathbb{E}(\xi) - \mathbb{E}(\xi)) \\ &\Leftrightarrow \mathbb{E}(g(\xi)) \geq g(\mathbb{E}(\xi)). \end{aligned} \quad (142)$$

Sei nun g eine konkave Funktion. Dann ist $-g$ eine konvexe Funktion. Mit der Jensenschen Ungleichung für konvexe Funktionen folgt dann die Jensensche Ungleichung für konkave Funktionen aus

$$\begin{aligned} \mathbb{E}(-g(\xi)) &\geq -g(\mathbb{E}(\xi)) \\ &\Leftrightarrow -\mathbb{E}(g(\xi)) \geq -g(\mathbb{E}(\xi)) \\ &\Leftrightarrow \mathbb{E}(g(\xi)) \leq g(\mathbb{E}(\xi)). \end{aligned} \quad (143)$$

□

Referenzen I

- Abramowitz, M., & Stegun, I. A. (1964). *Handbook of Mathematical Functions*. United States Department of Commerce, National Bureau of Standards (NBS).
- Andersen, E. B. (1970). Asymptotic Properties of Conditional Maximum-Likelihood Estimators. *Journal of the Royal Statistical Society. Series B (Methodological)*, 32(2), 283–301.
- Andersen, E. B. (1977). Sufficient Statistics and Latent Trait Models. *Psychometrika*, 42(1), 69–81. <https://doi.org/10.1007/BF02293746>
- Andrich, D. (1978). Application of a Psychometric Rating Model to Ordered Categories Which Are Scored with Successive Integers. *Applied Psychological Measurement*, 2(4), 581–594. <https://doi.org/10.1177/014662167800200413>
- Baker, F. B., & Harwell, M. R. (1996). Computing Elementary Symmetric Functions and Their Derivatives: A Didactic. *Applied Psychological Measurement*, 20(2), 169–192. <https://doi.org/10.1177/014662169602000206>
- Binet, A., & Simon, T. (1904). *Méthodes nouvelles pour le diagnostic du niveau intellectuel des anormaux*. <https://doi.org/10.3406/psy.1904.3675>
- Birnbaum, A. (1962). On the Foundations of Statistical Inference. *Journal of the American Statistical Association*, 57(298), 269–306. <https://doi.org/10.1080/01621459.1962.10480660>
- Blei, D. M., & Smyth, P. (2017). Science and data science. *Proceedings of the National Academy of Sciences*, 114(33), 8689–8692. <https://doi.org/10.1073/pnas.1702076114>
- Bock, R. D., & Aitkin, M. (1981). Marginal Maximum Likelihood Estimation of Item Parameters: Application of an EM Algorithm. *Psychometrika*, 46(4), 443–459. <https://doi.org/10.1007/BF02293801>
- Casella, G., & Berger, R. (2002). *Statistical Inference* (2nd ed.). Thomson Learning.
- Doll, R., & Hill, A. B. (1950). Smoking and Carcinoma of the Lung. *BMJ*, 2(4682), 739–748. <https://doi.org/10.1136/bmj.2.4682.739>

Referenzen II

- Embretson, S. E., & Reise, S. (2000). *Item response theory for psychologists*. Psychology Press.
- Finney, D. J. (1952). *Probit Analysis: A Statistical Treatment of the Sigmoid Response Curve*. (2nd ed.). Cambridge University Press.
- Fischer, G. H. (1995). *Rasch Models: Foundations, Recent Developments, and Applications* (1st ed.). Springer New York.
- Gustafsson, J.-E. (1977). *The Rasch Model for Dichotomous Items: Theory, Applications and a Computer Program* (63). Gothenburg University, Institute of Education.
- Gustafsson, J.-E. (1980). A Solution of the Conditional Estimation Problem for Long Tests in the Rasch Model for Dichotomous Items. *Educational and Psychological Measurement*, 40(2), 377–385. <https://doi.org/10.1177/001316448004000214>
- Haley, D. C. (1952). *Estimation of the dosage mortality relationship when the dose is subject to error*.
- Halmos, P. R., & Savage, L. J. (1949). Application of the Radon-Nikodym Theorem to the Theory of Sufficient Statistics. *The Annals of Mathematical Statistics*, 20(2), 225–241. <https://doi.org/10.1214/aoms/1177730032>
- Kyngdon, A. (2008). The Rasch Model from the Perspective of the Representational Theory of Measurement. *Theory & Psychology*, 18(1), 89–109. <https://doi.org/10.1177/0959354307086924>
- Lawley, D. N. (1943). On Problems connected with Item Selection and Test Construction. *Proceedings of the Royal Society of Edinburgh. Section A. Mathematical and Physical Sciences*, 61(3), 273–287. <https://doi.org/10.1017/S0080454100006282>
- Linden, W. J. van der (Ed.). (2016). *Handbook of Item Response Theory*. CRC Press. <https://doi.org/10.1201/9781315374512>
- Lord, F. M. (1951). A theory of test scores. *ETS Research Bulletin Series*, 1951(1). <https://doi.org/10.1002/j.2333-8504.1951.tb00922.x>

Referenzen III

- Lord, F. M., & Novick, M. R. (1968). *Statistical theories of mental test scores* (Nachdr. der Ausg. Reading, Mass. [u.a.], 1968). Information Age Publ.
- Luce, D., & Tukey, J. (1964). Simultaneous conjoint measurement: A new type of fundamental measurement. *Journal of Mathematical Psychology*, 1(1), 1–27. [https://doi.org/10.1016/0022-2496\(64\)90015-X](https://doi.org/10.1016/0022-2496(64)90015-X)
- Mosier, C. I. (1940). Psychophysics and mental test theory: Fundamental postulates and elementary theorems. *Psychological Review*, 47(4), 355–366. <https://doi.org/10.1037/h0059934>
- Murphy, K. P. (2023). *Probabilistic machine learning: Advanced topics*. The MIT Press.
- Ostwald, D., Kirilina, E., Starke, L., & Blankenburg, F. (2014). A tutorial on variational Bayes for latent linear stochastic time-series models. *Journal of Mathematical Psychology*, 60, 1–19. <https://doi.org/10.1016/j.jmp.2014.04.003>
- Parr, T., Pezzulo, G., & Friston, K. J. (2022). *Active inference: The free energy principle in mind, brain, and behavior*. The MIT Press.
- Rasch, G. (1960). *Probabilistic models for some intelligence and attainment tests* (Expanded ed). University of Chicago Press.
- Rasch, G. (1966). An item analysis which takes individual differences into account. *British Journal of Mathematical and Statistical Psychology*, 19(1), 49–57. <https://doi.org/10.1111/j.2044-8317.1966.tb00354.x>
- Richardson, M. W. (1936). The Relation between the Difficulty and the Differential Validity of a Test. *Psychometrika*, 1(2), 33–49. <https://doi.org/10.1007/BF02288003>
- Rigdon, S. E., & Tsutakawa, R. K. (1983). Parameter Estimation in Latent Trait Models. *Psychometrika*, 48(4), 567–574. <https://doi.org/10.1007/BF02293880>
- Starke, L., & Ostwald, D. (2017). Variational Bayesian Parameter Estimation Techniques for the General Linear Model. *Frontiers in Neuroscience*, 11. <https://doi.org/10.3389/fnins.2017.00504>

- Thissen, D. (1982). Marginal Maximum Likelihood Estimation for the One-Parameter Logistic Model. *Psychometrika*, 47(2), 175–186. <https://doi.org/10.1007/BF02296273>
- Titterton, D. M., Smith, A. F. M., & Makov, U. E. (1994). *Statistical analysis of finite mixture distributions* (3ème reprint). J. Wiley & sons.
- Verhulst, P. F. (1845). Recherches mathématiques sur la loi d'accroissement de la population. *Nouveaux mémoires de l'Académie Royale des Sciences et Belles-Lettres de Bruxelles*, 18, 14–54.
- Woodruff, D. J. (1996). Estimation of Item Response Models Using the EM Algorithm for Finite Mixtures. *ACT Research Report Series*.
- Wright, B. D. (1977). Solving measurement problems with the Rasch model. *Journal of Educational Measurement*, 14(2), 97–116. <https://doi.org/10.1111/j.1745-3984.1977.tb00031.x>
- Wright, B. D., & Panchapakesan, N. (1969). A procedure for sample-free item analysis. *Educational and Psychological Measurement*, 29, 23–48.
- Wu, M., Davis, R. L., Domingue, B. W., Piech, C., & Goodman, N. (2020). *Variational Item Response Theory: Fast, Accurate, and Expressive* (arXiv:2002.00276). arXiv. <https://doi.org/10.48550/arXiv.2002.00276>