



Psychometrische Diagnostik

MSc Psychologie

MSc Umweltpsychologie / Mensch-Technik-Interaktion

SoSe 2026

Prof. Dr. Dirk Ostwald

(5) Bayesianische Inferenz

Das Bayesianische Paradigma

Inferenzzusammenfassungen

Konjugierte Inferenz

Numerische Inferenz

Variationale Inferenz

Das Bayesianische Paradigma

Inferenzzusammenfassungen

Konjugierte Inferenz

Numerische Inferenz

Variationale Inferenz

Zentrale Postulate frequentistischer Inferenz

- Wahrscheinlichkeiten werden als Grenzwerte relativer Häufigkeiten interpretiert und als objektive Eigenschaften der realen Welt betrachtet.
- Parameter sind feste, unbekannte Konstanten, die als *wahre, aber unbekannte* Werte bezeichnet werden. Über Parameter werden keine Wahrscheinlichkeitsaussagen gemacht.
- Statistische Verfahren werden so konzipiert, dass sie gute Langzeit-Frequenzeigenschaften besitzen, und werden typischerweise durch Untersuchung ihrer Stichprobenverteilungen bewertet.

Zentrale Postulate Bayesianischer Inferenz

- Wahrscheinlichkeiten werden als Grade der Überzeugung interpretiert, nicht als Grenzhäufigkeiten. Aussagen wie „die Wahrscheinlichkeit, dass es heute Nachmittag regnet, beträgt 0.5“ sind sinnvoll.
- Parameter sind feste, unbekannte Konstanten, über die probabilistische Aussagen gemacht werden können, die unsere Unsicherheit über ihren wahren, aber unbekannten Wert quantifizieren.
- Probabilistische Aussagen über Parameter werden mithilfe von Wahrscheinlichkeitsverteilungen gemacht, aus denen weitere Inferenzen, wie Punkt- oder Intervallschätzungen, abgeleitet werden können.

Definition (Probabilistisches Modell)

Ein *probabilistisches Modell* ist eine gemeinsame Verteilung einer Familie direkt beobachtbarer zufälliger Entitäten $v := (v_1, \dots, v_n)$, die üblicherweise Daten modellieren, und einer Familie nicht direkt beobachtbarer zufälliger Entitäten $\vartheta := (\vartheta_1, \dots, \vartheta_p)$, die üblicherweise Parameter modellieren, die in Form einer gemeinsamen Dichtefunktion oder Wahrscheinlichkeitsfunktion spezifiziert ist

$$p(y, \theta). \quad (1)$$

Probabilistische Modelle werden auch als *generative Modelle* bezeichnet. Typischerweise werden probabilistische Modelle in Form des Produkts einer marginalen Dichtefunktion oder Wahrscheinlichkeitsfunktion von ϑ und einer bedingten Dichtefunktion oder Wahrscheinlichkeitsfunktion von v definiert, in der Form

$$p(y, \theta) = p(y|\theta)p(\theta). \quad (2)$$

Hier wird $p(\theta)$ als *Prior-Verteilung* bezeichnet und $p(y|\theta)$ als *Likelihood*. Oft wird angenommen, dass die beobachtbaren zufälligen Entitäten $v_1, \dots, v_n$ *bedingt unabhängig und identisch verteilt* sind, d.h.,

$$p(y|\theta) := \prod_{i=1}^n p(y_i|\theta) \text{ und } p(y_i|\theta) = p(y_1|\theta) \text{ für } i = 2, \dots, n. \quad (3)$$

Bemerkungen

- Zufällige Entitäten umfassen Zufallsvariablen, Zufallsvektoren, Zufallsmatrizen und Zufallsfunktionen.
- Wir nehmen durchgehend die Existenz der jeweiligen Wahrscheinlichkeitsfunktionen und/oder Dichtefunktionen an.

Definition (Posterior-Verteilung)

Gegeben ein probabilistisches Modell $p(y, \theta)$ wird die bedingte Verteilung der nicht direkt beobachtbaren zufälligen Entität θ gegeben die beobachtbare zufällige Entität y als *Posterior-Verteilung* bezeichnet. Mithilfe des Satzes von Bayes für Wahrscheinlichkeitsfunktionen oder Dichtefunktionen kann die Posterior-Verteilung in Form der Dichtefunktion oder Wahrscheinlichkeitsfunktion ausgewertet werden als

$$p(\theta|y) = \frac{p(y|\theta)p(\theta)}{\int p(y|\theta)p(\theta) d\theta}. \quad (4)$$

Der Nenner der rechten Seite oben wird manchmal als *Evidenz* bezeichnet, sodass eine Eselsbrücke für die Posterior-Verteilung gegeben ist durch

$$\text{Posterior} = \frac{\text{Likelihood} \times \text{Prior}}{\text{Evidenz}}. \quad (5)$$

Da die Evidenz unabhängig von θ und für eine gegebene Realisierung von y konstant ist, entspricht sie einer Normierungskonstante des Produkts aus Prior und Likelihood, die dieses Produkt zu einer gültigen Dichtefunktion oder Wahrscheinlichkeitsfunktion macht. Wenn nur die funktionale Form der Dichtefunktion oder Wahrscheinlichkeitsfunktion des Posteriors von Interesse ist, genügt die unnormalisierte Version, oft geschrieben als

$$p(\theta|y) \propto p(y|\theta)p(\theta). \quad (6)$$

Bemerkungen

- Die Auswertung der Posterior-Verteilung kann auf *Batch*- oder *rekursive* Weise erfolgen.

Batch-Bayesianische Schätzung

Angenommen, es sind n Datenpunkte $y_i, i = 1, \dots, n$, d.h. Beobachtungen von $v_i, i = 1, \dots, n$, verfügbar.

Dann erfolgt Bayesianische Schätzung typischerweise wie folgt:

- (1) Spezifikation einer Prior-Verteilung $p(\theta)$.
- (2) Spezifikation der Daten-Likelihood gegeben den Parameter, wobei oft angenommen wird, dass die beobachteten zufälligen Entitäten $v_i, i = 1, \dots, n$ bedingt unabhängig gegeben θ sind, sodass

$$p(y|\theta) = \prod_{i=1}^n p(y_i|\theta). \quad (7)$$

- (3) Auswertung von

$$p(\theta|y) = \frac{p(\theta) \prod_{i=1}^n p(y_i|\theta)}{\int p(\theta) \prod_{i=1}^n p(y_i|\theta) d\theta}. \quad (8)$$

Das Bayesianische Paradigma

Rekursive Bayesianische Schätzung

Angenommen, Datenpunkte $y_1, y_2, \dots$, d.h. Beobachtungen von $v_1, v_2, \dots$, sind nacheinander verfügbar. Dann erfolgt Bayesianische Schätzung wie folgt:

- (1) Spezifikation der Prior-Verteilung $p(\theta)$.
- (2) Spezifikation der Daten-Likelihood gegeben den Parameter, wobei angenommen wird, dass die beobachteten zufälligen Entitäten $v_i, i = 1, \dots, n$ bedingt unabhängig gegeben θ sind, sodass

$$p(y_1|\theta) = p(y_2|\theta) = \dots \quad (9)$$

- (3) Auswertung von

$$\begin{aligned} p(\theta|y_1) &= \frac{p(y_1|\theta)p(\theta)}{\int p(y_1|\theta)p(\theta) d\theta} \\ p(\theta|y_{1:2}) &= \frac{p(y_2|\theta)p(\theta|y_1)}{\int p(y_2|\theta)p(\theta|y_1) d\theta} \\ &\dots \end{aligned} \quad (10)$$

Hier dient für $i = 1, 2, \dots$ die Posterior-Verteilung bei $i - 1$ als Prior-Verteilung bei i („der Posterior von gestern ist der Prior von heute“). Für n Datenpunkte sind Batch- und rekursive Bayesianische Schätzung äquivalent:

$$p(\theta|y) = \frac{p(\theta) \prod_{i=1}^n p(y_i|\theta)}{\int p(\theta) \prod_{i=1}^n p(y_i|\theta) d\theta} = \frac{p(y_n|\theta)p(\theta|y_{1:n-1})}{\int p(y_n|\theta)p(\theta|y_{1:n-1}) d\theta}.$$

Definition (Marginale Likelihood)

Sei $p(y, \theta)$ die Wahrscheinlichkeitsfunktion oder Dichtefunktion eines probabilistischen Modells. Dann wird die marginale Dichtefunktion oder Wahrscheinlichkeitsfunktion der beobachtbaren zufälligen Entitäten

$$p(y) = \int p(y, \theta) d\theta = \int p(y|\theta)p(\theta) d\theta \quad (11)$$

als *marginale (Daten-)Likelihood* oder *Modellevidenz* bezeichnet.

Bemerkungen

- Die Evidenz ist „die Wahrscheinlichkeit(sichte) eines Datensatzes unter einem probabilistischen Modell“.
- $p(y)$ wird manchmal als *Prior-prädiktive Verteilung* bezeichnet.

Definition (Bayes-Faktor)

Für zwei probabilistische Modelle $p_1(y, \theta_1)$ und $p_2(y, \theta_2)$ mit identischem Datenergebnis und möglicherweise unterschiedlichen Parameterräumen wird das Verhältnis der marginalen Likelihoods

$$\text{BF} = \frac{p_1(y)}{p_2(y)} \quad (12)$$

als *Bayes-Faktor* bezeichnet.

Bemerkung

- Der Bayes-Faktor dient als grundlegendes Modellvergleichskriterium in der Bayesianischen Statistik.

Definition (Posterior-prädiktive Verteilung)

Sei $p(y, \theta)$ die Dichtefunktion oder Wahrscheinlichkeitsfunktion eines probabilistischen Modells. Dann wird die bedingte Verteilung einer beobachtbaren zufälligen Entität v_{n+1} gegeben die beobachteten zufälligen Entitäten v als *posterior-prädiktive Verteilung* bezeichnet. Eine Wahrscheinlichkeitsfunktion oder Dichtefunktion der posterior-prädiktiven Verteilung ist gegeben durch

$$p(y_{n+1}|y) = \int p(y_{n+1}|\theta)p(\theta|y) d\theta, \quad (13)$$

wobei typischerweise

$$p(y_{n+1}|\theta) = p(y_i|\theta) \text{ für } i = 1, \dots, n. \quad (14)$$

Bemerkung

- Im Gegensatz zu $p_{\hat{\theta}}(y_{n+1})$ für eine Punktschätzung $\hat{\theta}$ von θ berücksichtigt $p(y_{n+1}|\theta)$ Schätzunsicherheit.

Zusammenfassung

Bezeichnung	Mathematischer Charakter	Notation
Probabilistisches Modell	Gemeinsame Verteilung	$p(y, \theta)$
Prior-Verteilung	Marginale Verteilung	$p(\theta)$
Likelihood	Bedingte Verteilung	$p(y \theta)$
Posterior-Verteilung	Bedingte Verteilung	$p(\theta y)$
Marginale Likelihood	Marginale Verteilung	$p(y)$

Bayesianische Punktschätzung

- Die zentrale Entität der Bayesianischen Inferenz ist die Posterior-Verteilung.
- In angewandten Kontexten sind Punktschätzungen jedoch oft nützlich.
- Bayesianische Punktschätzung ist ein entscheidungstheoretisches Problem.
- Entscheidungstheorie beruht auf den Begriffen von Nutzen- oder Verlustfunktionen.

Definition (Verlustfunktion, erwarteter posteriorer Verlust, Bayes-Schätzer)

Sei $p(y, \theta)$ ein probabilistisches Modell und sei $\hat{\theta}$ eine Punktschätzung für den wahren, aber unbekannten Wert des Parameters des probabilistischen Modells. Dann heißt eine reellwertige Funktion

$$l : \Theta \times \Theta \rightarrow \mathbb{R}, (\hat{\theta}, \theta) \mapsto l(\hat{\theta}, \theta) \quad (15)$$

die die Unerwünschtheit der Wahl der Punktschätzung $\hat{\theta}$ misst, wenn der wahre, aber unbekannte Parameterwert θ ist, eine *Verlustfunktion*. Der Erwartungswert der Verlustfunktion bezüglich der Posterior-Verteilung von ϑ wird als *erwarteter posteriorer Verlust* bezeichnet und hat die Form

$$l_p : \Theta \rightarrow \mathbb{R}, \hat{\theta} \mapsto l_p(\hat{\theta}) := \int l(\hat{\theta}, \theta) p(\theta|y) d\theta. \quad (16)$$

Der Punktschätzer

$$\hat{\theta}_B := \arg \min_{\hat{\theta} \in \Theta} l_p(\hat{\theta}) \quad (17)$$

der den erwarteten posterioren Verlust minimiert, ist als *Bayes-Schätzer* bekannt.

Theorem (Quadratische Verlustfunktion, posteriorer Erwartungswert)

Sei $p(y, \theta)$ ein probabilistisches Modell mit skalarem Parameter ϑ und sei die quadratische Verlustfunktion definiert als

$$l : \Theta \times \Theta \rightarrow \mathbb{R}, (\hat{\theta}, \theta) \mapsto l(\hat{\theta}, \theta) := (\hat{\theta} - \theta)^2. \quad (18)$$

Dann ist der Bayes-Schätzer der posterior erwartete Wert des Parameters, d.h.,

$$\hat{\theta}_B = \arg \min_{\hat{\theta} \in \Theta} l_p(\hat{\theta}) = \int \theta p(\theta|y) d\theta. \quad (19)$$

Dieser Schätzer wird auch als Minimum Mean Squared Error (MMSE)-Schätzer bezeichnet.

Beweis

Die erwartete posteriore Verlustfunktion ist gegeben durch

$$l_p : \Theta \rightarrow \mathbb{R}, \hat{\theta} \mapsto l_p(\hat{\theta}) := \int (\hat{\theta} - \theta)^2 p(\theta|y) d\theta \quad (20)$$

Ihre Ableitung bezüglich $\hat{\theta}$ ergibt

$$\frac{d}{d\hat{\theta}} l_p(\hat{\theta}) = \int \frac{d}{d\hat{\theta}} (\hat{\theta} - \theta)^2 p(\theta|y) d\theta = 2 \int (\hat{\theta} - \theta) p(\theta|y) d\theta. \quad (21)$$

Nullsetzen liefert

$$\int (\hat{\theta} - \theta) p(\theta|y) d\theta = 0 \Leftrightarrow \hat{\theta} - \int \theta p(\theta|y) d\theta = 0 \Leftrightarrow \hat{\theta} = \int \theta p(\theta|y) d\theta. \quad (22)$$

□

Theorem (Null-Eins-Verlustfunktion, posteriorer Modus)

Sei $p(y, \theta)$ ein probabilistisches Modell und sei die Null-Eins-Verlustfunktion definiert als

$$l : \Theta \times \Theta \rightarrow \mathbb{R}, (\hat{\theta}, \theta) \mapsto l(\hat{\theta}, \theta) := 1 - 1_{\hat{\theta}}(\theta) = \begin{cases} 0, & \theta = \hat{\theta} \\ 1, & \theta \neq \hat{\theta} \end{cases} \quad (23)$$

Dann ist der Bayes-Schätzer der posteriore Modus des Parameters, d.h.,

$$\hat{\theta}_B = \arg \min_{\hat{\theta} \in \Theta} l_p(\hat{\theta}) = \arg \max_{\hat{\theta} \in \Theta} p(\hat{\theta}|y). \quad (24)$$

Dieser Schätzer wird auch als Maximum-a-posteriori (MAP)-Schätzer bezeichnet.

Beweis

Die erwartete posteriore Verlustfunktion ist gegeben durch

$$\begin{aligned} l_p : \Theta \rightarrow \mathbb{R}, \hat{\theta} \mapsto l_p(\hat{\theta}) &:= \int (1 - 1_{\hat{\theta}}(\theta)) p(\theta|y) d\theta \\ &= \int 1 p(\theta|y) d\theta - \int 1_{\hat{\theta}}(\theta) p(\theta|y) d\theta \\ &= 1 - p(\hat{\theta}|y) \end{aligned} \quad (25)$$

Die Minimierung von $l_p(\hat{\theta})$ bezüglich $\hat{\theta}$ ist somit äquivalent zur Maximierung von $p(\hat{\theta}|y)$ bezüglich $\hat{\theta}$. □

Bayesianische Intervallschätzung

- Die zentrale Entität der Bayesianischen Inferenz ist die Posterior-Verteilung.
- In angewandten Kontexten sind Intervallschätzungen oft nützlich.
- Bayesianische Intervallschätzungen werden als *Kredibilitätsintervalle* bezeichnet.
- Kredibilitätsintervalle sind „intuitiver“ als Konfidenzintervalle.
- *Kredibilitätsregionen* verallgemeinern Kredibilitätsintervalle für nicht-skalare Parameter.

Definition (δ -Kreditibilitätsregion, δ -Kreditibilitätsintervall)

Sei $p(y, \theta)$ ein probabilistisches Modell mit Parameterraum Θ und sei $p(\theta|y)$ die Posterior-Verteilung. Dann wird jede Region $R_\delta \subset \Theta$, sodass

$$\int_{R_\delta} p(\theta|y) d\theta = \delta \text{ für } \delta \in]0, 1[\quad (26)$$

als posteriore δ -Kreditibilitätsregion bezeichnet. Wenn $R_\delta \subset \mathbb{R}$ ein Intervall ist, dann wird R_δ auch als δ -Kreditibilitätsintervall bezeichnet.

Bemerkungen

- δ -Kreditibilitätsintervalle sind typischerweise nicht eindeutig definiert ... Konfidenzintervalle sind es aber auch nicht
- Ansätze zur eindeutigen Spezifikation von δ -Kreditibilitätsintervallen umfassen die Auswahl von
 - δ -Kreditibilitätsintervallen höchster posteriorer Dichte (minimaler Größe),
 - symmetrischen δ -Kreditibilitätsintervallen um den posterioren Erwartungswert,
 - δ -Kreditibilitätsintervallen mit gleicher oberer und unterer Randwahrscheinlichkeit.

Zusammenfassung

- Parameter-Punktschätzungen und Intervallschätzungen können aus $p(\theta|y)$ abgeleitet werden.
- Bayes-Schätzer minimieren den erwarteten posterioren Verlust (EPL) bzgl. einer Verlustfunktion.
- Der posteriore Erwartungswert minimiert den EPL bezüglich einer quadratischen Verlustfunktion.
- Der MAP-Schätzer minimiert den EPL bezüglich einer Null-Eins-Verlustfunktion.
- Der wahre, aber unbekannte Parameter liegt mit Wahrscheinlichkeit δ innerhalb eines δ -Kredibilitätsintervalls.

Das Bayesianische Paradigma

Inferenzzusammenfassungen

Konjugierte Inferenz

Numerische Inferenz

Variationale Inferenz

Definition (Konjugierte Verteilungsfamilie und Hyperparameter)

Sei

$$p(\theta, y) = \prod_{i=1}^n p(y_i|\theta)p(\theta) \quad (27)$$

ein probabilistisches Modell mit bedingt unabhängigen und identisch verteilten beobachteten zufälligen Entitäten $v_1, \dots, v_n$ und nicht direkt beobachteter zufälliger Entität ϑ . Sei ϕ eine Verteilungsfamilie von ϑ . ϕ heißt *konjugierte Verteilungsfamilie bezüglich* $p(y_i|\theta)$, wenn die Posterior-Verteilung $p(\theta|y)$ ein Element von ϕ ist, unabhängig von der Prior-Verteilung $p(\theta) \in \phi$ und den Beobachtungen $y_1, \dots, y_n$ von $v_1, \dots, v_n$. Wenn sowohl die Prior- als auch die Posterior-Verteilung Elemente von ϕ bezüglich $p(y_i|\theta), i = 1, \dots, n$, sind, sagt man auch, dass ϕ *unter Stichprobenziehung abgeschlossen* ist. Da ϑ häufig Parameter modelliert, werden die Parameter der Verteilungen in ϕ häufig als *Hyperparameter* bezeichnet.

Bemerkungen

- Die Prior- und Posterior-Verteilungen der konjugierten Inferenz sind vom gleichen Typ.
- Die Parameter des Posteriors ergeben sich aus den Parametern des Priors und den Daten.
- Die Aktualisierungsformel für die Hyperparameter kann analytisch gefunden werden.

Definition (Binomiale Zufallsvariable)

Sei v eine Zufallsvariable mit Ergebnismenge $\mathcal{Y} := \mathbb{N}_n^0$ und Wahrscheinlichkeitsfunktion

$$p : \mathcal{Y} \rightarrow [0, 1], y \mapsto p(y) := \binom{n}{y} \theta^y (1 - \theta)^{n-y} \text{ für } \theta \in [0, 1]. \quad (28)$$


Dann heißt v gemäß einer *Binomialverteilung* mit Parametern $\theta \in [0, 1]$ und $n \in \mathbb{N}$ verteilt, wofür wir $v \sim \text{Bin}(\theta, n)$ schreiben. Wir bezeichnen die Wahrscheinlichkeitsfunktion einer binomialen Zufallsvariable mit

$$\text{Bin}(y; \theta, n) := \binom{n}{y} \theta^y (1 - \theta)^{n-y} \quad (29)$$


Bemerkungen

- $\text{Bin}(y; \theta, 1) = \text{Bern}(y; \theta)$, was als *Bernoulli-Verteilung* bezeichnet wird.
- Wenn wir 0 und 1 „Misserfolg“ und „Erfolg“ mit Wahrscheinlichkeiten $1 - \theta$ bzw. θ in einem einzelnen Versuch modellieren, dann modelliert $\text{Bin}(\theta, n)$ die Verteilung der Summe der Erfolge in n Versuchen.


$\text{Bin}(y; 0.1, 5)$



$\text{Bin}(y; 0.5, 10)$



$\text{Bin}(y; 0.7, 15)$



Definition (Beta-Zufallsvariable)

Sei ϑ eine Zufallsvariable mit Ergebnismenge $\Theta := [0, 1]$ und Dichtefunktion

$$p : \Theta \rightarrow \mathbb{R}_{\geq 0}, \theta \mapsto p(\theta) := \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1} \text{ für } \alpha, \beta \in \mathbb{R}_{>0}, \quad (30)$$


wobei Γ die Gammafunktion bezeichnet. Dann heißt ϑ gemäß einer *Beta-Verteilung* mit Parametern α, β verteilt, wofür wir $\vartheta \sim \text{Beta}(\alpha, \beta)$ schreiben. Wir bezeichnen die Dichtefunktion einer Beta-Zufallsvariable mit

$$\text{Beta}(\theta; \alpha, \beta) := \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1}. \quad (31)$$


Bemerkungen

- Eine Beta-Zufallsvariable kann zur Modellierung der Verteilung einer Wahrscheinlichkeit θ verwendet werden, da $\theta \in [0, 1]$.
- Der Erwartungswert einer Beta-Zufallsvariable ist $\mathbb{E}(\vartheta) = \frac{\alpha}{\alpha + \beta}$.
- Die Varianz einer Beta-Zufallsvariable ist $\mathbb{V}(\vartheta) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$.
- $\text{Beta}(\theta; 1, 1) = U(\theta; 0, 1)$, die stetige Gleichverteilung auf $[0, 1]$.
- Für $\alpha < 1, \beta < 1$ ist die Ergebnismenge $\Theta :=]0, 1[$.


Beta(θ ;1,1)



Beta(θ ;3,2)



Beta(θ ;10,5)



Theorem (Das Beta-Binomial-Modell)

Betrachte das probabilistische Modell

$$p(y, \theta) = p(y|\theta)p(\theta) := \text{Bin}(y; \theta, n)\text{Beta}(\theta; \alpha, \beta). \quad (32)$$

Dann ist die Posterior-Verteilung gegeben durch

$$p(\theta|y) = \text{Beta}(\theta; \alpha + y, \beta + n - y) \quad (33)$$

und die MMSE- und MAP-Bayes-Schätzer sind

$$\hat{\theta}_{\text{MMSE}} = \frac{\alpha + y}{\alpha + \beta + n} \quad \text{und} \quad \hat{\theta}_{\text{MAP}} = \frac{\alpha + y - 1}{\alpha + \beta + n - 2}. \quad (34)$$

Bemerkungen

- Die Prior-Verteilung ist $p(\theta) = \text{Beta}(\theta; \alpha, \beta)$.
- Die Likelihood ist $p(y|\theta) = \text{Bin}(y; \theta, n)$.
- Kreditabilitätsintervalle können mithilfe der Verteilungsfunktion der Beta-Verteilungsdichte $p(\theta|y)$ abgeleitet werden.
- Der MMSE-Schätzer des Beta-Binomial-Modells kann geschrieben werden als

$$\begin{aligned}\hat{\theta}_{\text{MMSE}} &= \frac{\alpha + y}{\alpha + \beta + n} \\ &= \frac{\alpha}{\alpha + \beta + n} + \frac{y}{\alpha + \beta + n} \\ &= \frac{\alpha(\alpha + \beta)}{(\alpha + \beta + n)(\alpha + \beta)} + \frac{yn}{(\alpha + \beta + n)n} \\ &= \frac{\alpha + \beta}{\alpha + \beta + n} \cdot \frac{\alpha}{\alpha + \beta} + \frac{n}{\alpha + \beta + n} \cdot \frac{y}{n}\end{aligned}\tag{35}$$

- Der MMSE-Schätzer des Beta-Binomial-Modells ist ein gewichteter Durchschnitt aus Prior-Erwartungswert und ML-Schätzer $\frac{y}{n}$.
- Die Gewichtungskonstanten sind proportional zu (1) der Anzahl virtueller Prior-Beobachtungen $\alpha + \beta$ und (2) der Anzahl tatsächlicher Beobachtungen n .

Beweis

Posterior-Verteilung

Wir stellen zunächst fest, dass bis auf Proportionalitätskonstanten die Posterior-Verteilung gegeben ist durch

$$\begin{aligned} p(\theta|y) &\propto p(y|\theta)p(\theta) \\ &= \text{Bin}(y; \theta, n) \text{Beta}(\theta; \alpha, \beta) \\ &\propto \theta^y (1 - \theta)^{n-y} \theta^{\alpha-1} (1 - \theta)^{\beta-1} \\ &= \theta^{\alpha+y-1} (1 - \theta)^{\beta+n-y-1} \end{aligned} \tag{36}$$

Die rechte Seite oben entspricht dem Kern der Dichtefunktion einer Beta-Verteilung mit Parametern $\alpha + y$ und $\beta + n - y$. Die Posterior-Verteilung ist somit gegeben durch

$$p(\theta|y) = \text{Beta}(\theta; \alpha + y, \beta + n - y) \tag{37}$$

MMSE- und MAP-Bayes-Schätzer

Der Erwartungswert und der Modus einer Zufallsvariable $\vartheta \sim \text{Beta}(\alpha, \beta)$ sind gegeben durch

$$\mathbb{E}(\vartheta) = \frac{\alpha}{\alpha + \beta} \quad \text{und} \quad \mathbb{M}(\vartheta) = \frac{\alpha - 1}{\alpha + \beta - 2} \quad (\alpha, \beta > 1) \tag{38}$$

Einsetzen der Parameter der Posterior-Verteilung liefert somit direkt die MMSE- und MAP-Bayes-Schätzer.

Beispiel

- Betrachte Interesse an der Wirksamkeit einer „Behandlung“.
- Sei 0 das Behandlungsergebnis „Misserfolg“ und 1 das Behandlungsergebnis „Erfolg“.
- Sei $\theta_{\text{TBU}} \in [0, 1]$ der wahre, aber unbekannte Anteil von „Erfolgs“-Ergebnissen.
- Angenommen, die Prior-Unsicherheit über θ_{TBU} wird angemessen durch $\text{Beta}(\theta; 1, 1)$ beschrieben.
- Betrachte eine Studie mit $n = 30$ experimentellen Einheiten und einer Beobachtung von $y = 18$ „Erfolgs“-Ergebnissen.
- Dann wird die Posterior-Unsicherheit über θ_{TBU} beschrieben durch $\text{Beta}(\theta; 1 + 18, 1 + 30 - 18) = \text{Beta}(\theta; 19, 13)$.
- Aus der Posterior-Verteilung sind Punktschätzungen für θ_{TBU} gegeben durch

$$\hat{\theta}_{\text{MMSE}} = \frac{1 + 18}{1 + 1 + 30} = \frac{19}{32} = 0.59. \text{ und } \hat{\theta}_{\text{MAP}} = \frac{18}{30} = 0.60. \quad (39)$$

- In Bezug auf Kreditabilitätsintervalle können wir zum Beispiel ableiten, dass die posteriore Wahrscheinlichkeit von $\vartheta \geq 0.5$ ist

$$\mathbb{P}(\vartheta \geq 0.5) = 1 - \mathbb{P}(\vartheta \leq 0.5) = 1 - P(0.5) = 1 - 0.14 = 0.86, \quad (40)$$


während die Prior-Wahrscheinlichkeit von $\vartheta \geq 0.5$ 0.5 betrug.

- Beachte, dass für dieselbe Prior-Verteilung und $n = 1$ und $y = 1$ gilt


$$\hat{\theta}_{ML} = 1, \text{ aber } \hat{\theta}_{\text{MMSE}} = \frac{1 + 1}{1 + 1 + 1} = \frac{2}{3} = 0.6\bar{6}. \quad (41)$$

Beispiel

$$p(\theta) = \text{Beta}(\theta; 1, 1)$$



$$p(\theta|y=18) = \text{Beta}(\theta; 19, 13)$$



Definition (Gaußsche Zufallsvariable)

Sei v eine Zufallsvariable mit Ergebnismenge $\mathbb{R}$ und Dichtefunktion




$$p : \mathbb{R} \rightarrow \mathbb{R}_{>0}, y \mapsto p(y) := \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(y-\theta)^2\right). \quad (42)$$

Dann heißt v gemäß einer *Gauß-Verteilung mit Parametern $\theta \in \mathbb{R}$ und $\sigma^2 > 0$* verteilt und heißt eine *Gaußsche Zufallsvariable*, wofür wir $v \sim N(\theta, \sigma^2)$ schreiben. Wir bezeichnen die Dichtefunktion einer Gaußschen Zufallsvariable mit

$$N(y; \theta, \sigma^2) := \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(y-\theta)^2\right). \quad (43)$$

Bemerkungen

- θ entspricht dem Wert höchster Wahrscheinlichkeitsdichte und $\mathbb{E}(v) = \theta$.
- σ^2 spezifiziert die Breite von $N(y; \theta, \sigma^2)$ und $\mathbb{V}(v) = \sigma^2$.



Theorem (Das univariate Gauß-Gauß-Modell)

Für $y := (y_1, \dots, y_n)$ betrachte das probabilistische Modell

$$p(y, \theta) = p(y|\theta)p(\theta) := \prod_{i=1}^n p(y_i|\theta)p(\theta) := \prod_{i=1}^n N(y_i; \theta, \sigma_y^2)N(\theta; \mu_\theta, \sigma_\theta^2). \quad (44)$$

Dann ist die Posterior-Verteilung gegeben durch

$$p(\theta|y) = N\left(\theta; \left(\frac{n}{\sigma_y^2} + \frac{1}{\sigma_\theta^2}\right)^{-1} \left(\frac{\mu_\theta}{\sigma_\theta^2} + \frac{n\bar{y}}{\sigma_y^2}\right), \left(\frac{n}{\sigma_y^2} + \frac{1}{\sigma_\theta^2}\right)^{-1}\right), \quad (45)$$

wobei $\bar{y} := \frac{1}{n} \sum_{i=1}^n y_i$ den Stichprobenmittelwert bezeichnet, und die MMSE- und MAP-Bayes-Schätzer sind

$$\hat{\theta}_{\text{MMSE}} = \hat{\theta}_{\text{MAP}} = \left(\frac{n}{\sigma_y^2} + \frac{1}{\sigma_\theta^2}\right)^{-1} \left(\frac{\mu_\theta}{\sigma_\theta^2} + \frac{n\bar{y}}{\sigma_y^2}\right). \quad (46)$$

Bemerkungen

- Die Prior-Verteilung ist $p(\theta) = N(\theta; \mu_\theta, \sigma_\theta^2)$.
- Die Likelihood ist $p(y|\theta) = \prod_{i=1}^n N(y_i; \theta, \sigma_y^2)$.
- $\sigma_y^2 > 0$ wird als bekannt angenommen und daher im vorliegenden Szenario nicht mit einer Prior-Verteilung versehen.
- Kreditibilitätsintervalle können mithilfe der Verteilungsfunktion der Gaußschen Dichte $p(\theta|y)$ abgeleitet werden.
- Der MMSE-Schätzer des univariaten Gauß-Gauß-Modells hat die Form

$$\hat{\theta}_{\text{MMSE}} \propto \frac{1}{\sigma_\theta^2} \mu_\theta + \frac{n}{\sigma_y^2} \bar{y}. \quad (47)$$

- $\hat{\theta}_{\text{MMSE}}$ ist somit ein gewichteter Durchschnitt des Prior-Erwartungswerts und des ML-Schätzers.
- Die Gewichtungskonstanten sind gegeben durch (1) die Prior-Präzision (reziproke Varianz) $1/\sigma_\theta^2$ und (2) die Datenpräzision $1/\sigma_y^2$ und die Anzahl der Beobachtungen.
- Der Posterior-Varianzparameter

$$\left(\frac{n}{\sigma_y^2} + \frac{1}{\sigma_\theta^2} \right)^{-1} \quad (48)$$

steht in reziproker Beziehung zur Anzahl der Beobachtungen.

Beweis

Posterior-Verteilung

Indem wir uns auf die Tatsache konzentrieren, dass die Posterior-Verteilung eine Funktion von θ ist, und daher multiplikative Konstanten, die unabhängig von θ sind, in Proportionalitätsaussagen zusammenfassen, haben wir

$$\begin{aligned} p(\theta|y) &\propto \prod_{i=1}^n N(y_i; \theta, \sigma_y^2) N(\theta; \mu_\theta, \sigma_\theta^2) \\ &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma_y^2}} \exp\left(-\frac{1}{2\sigma_y^2}(y_i - \theta)^2\right) \frac{1}{\sqrt{2\pi\sigma_\theta^2}} \exp\left(-\frac{1}{2\sigma_\theta^2}(\theta - \mu_\theta)^2\right) \\ &\propto \exp\left(-\frac{1}{2}\left(\frac{\sum_{i=1}^n (y_i - \theta)^2}{\sigma_y^2} + \frac{(\theta - \mu_\theta)^2}{\sigma_\theta^2}\right)\right) \\ &= \exp\left(-\frac{1}{2}\left(\frac{\sum_{i=1}^n (y_i^2 - 2y_i\theta + \theta^2)}{\sigma_y^2} + \frac{\theta^2 - 2\theta\mu_\theta + \mu_\theta^2}{\sigma_\theta^2}\right)\right) \\ &= \exp\left(-\frac{1}{2}\left(\frac{\sum_{i=1}^n y_i^2 - 2n\bar{y}\theta + n\theta^2}{\sigma_y^2} + \frac{\theta^2 - 2\theta\mu_\theta + \mu_\theta^2}{\sigma_\theta^2}\right)\right) \\ &\propto \exp\left(-\frac{1}{2}\left(\frac{-2n\bar{y}\theta + n\theta^2}{\sigma_y^2} + \frac{\theta^2 - 2\theta\mu_\theta}{\sigma_\theta^2}\right)\right). \end{aligned} \tag{49}$$

Beweis (Fortsetzung)

Daher

$$\begin{aligned} p(\theta|y) &\propto \exp\left(-\frac{1}{2}\left(\frac{\theta^2 n - 2n\bar{y}\theta}{\sigma_y^2} + \frac{\theta^2 - 2\theta\mu_\theta}{\sigma_\theta^2}\right)\right) \\ &= \exp\left(-\frac{1}{2}\left(\theta^2 \frac{n}{\sigma_y^2} - 2\theta \frac{n\bar{y}}{\sigma_y^2} + \theta^2 \frac{1}{\sigma_\theta^2} - 2\theta \frac{\mu_\theta}{\sigma_\theta^2}\right)\right) \\ &= \exp\left(-\frac{1}{2}\theta^2 \frac{n}{\sigma_y^2} - \frac{1}{2}\theta^2 \frac{1}{\sigma_\theta^2} + \theta \frac{n\bar{y}}{\sigma_y^2} + \theta \frac{\mu_\theta}{\sigma_\theta^2}\right) \\ &= \exp\left(-\frac{1}{2}\theta^2 \left(\frac{n}{\sigma_y^2} + \frac{1}{\sigma_\theta^2}\right) + \theta \left(\frac{\mu_\theta}{\sigma_\theta^2} + \frac{n\bar{y}}{\sigma_y^2}\right)\right). \end{aligned} \tag{50}$$

Durch Definition von

$$\phi_1 := \left(\frac{n}{\sigma_y^2} + \frac{1}{\sigma_\theta^2}\right)^{-1} \quad \text{und} \quad \phi_2 := \phi_1 \left(\frac{\mu_\theta}{\sigma_\theta^2} + \frac{n\bar{y}}{\sigma_y^2}\right) \tag{51}$$

haben wir dann

$$\begin{aligned} p(\theta|y) &\propto \exp\left(-\frac{1}{2\phi_1}\theta^2 + \frac{1}{\phi_1}\theta\phi_2\right) \\ &\propto \exp\left(-\frac{1}{2\phi_1}\theta^2 + \frac{1}{\phi_1}\theta\phi_2 - \frac{1}{2\phi_1}\phi_2^2\right). \end{aligned} \tag{52}$$

Beweis (Fortsetzung)

Daher

$$p(\theta|y) \propto \exp\left(-\frac{1}{2\phi_1}(\theta - \phi_2)^2\right) \quad (53)$$

Ausgehend von der Normierungskonstante der Gaußschen Dichtefunktion haben wir somit

$$\begin{aligned} p(\theta|y) &= \frac{1}{\sqrt{2\pi\phi_1}} \exp\left(-\frac{1}{2\phi_1}(\theta - \phi_2)^2\right) \\ &= N(\theta; \phi_2, \phi_1), \end{aligned} \quad (54)$$

sodass die Posterior-Verteilung durch eine univariate Gaußsche Dichtefunktion mit Erwartungswertparameter gegeben ist

$$\phi_2 = \left(\frac{n}{\sigma_y^2} + \frac{1}{\sigma_\theta^2}\right)^{-1} \left(\frac{\mu_\theta}{\sigma_\theta^2} + \frac{n\bar{y}}{\sigma_y^2}\right) \quad (55)$$

und Varianzparameter

$$\phi_1 = \left(\frac{n}{\sigma_y^2} + \frac{1}{\sigma_\theta^2}\right)^{-1}. \quad (56)$$

□

Beispiel

- Betrachte Interesse am gemeinsamen Erwartungswert $\theta \in \mathbb{R}$ Gauß-verteilter Entitäten $v_i, i = 1, \dots, n$, z.B. dem Erwartungswert einer Gruppe von Voxel-Aktivitätsmessungen in einer Mehrpersonen-fMRT-Studie mit n Teilnehmenden.
- Angenommen, die gemeinsame Varianz dieser Entitäten $\sigma_y^2 := 2$ ist bekannt.
- Sei $\theta_{\text{TBU}} \in \mathbb{R}$ der wahre, aber unbekannte gemeinsame Erwartungswert.
- Angenommen, die Prior-Unsicherheit über θ_{TBU} wird angemessen durch $N(\theta; 0, 10)$ beschrieben.
- Betrachte eine Studie mit 12 experimentellen Einheiten (Teilnehmenden) und Stichprobenmittelwert $\bar{y} = 3.14$.
- Dann

$$\left(\frac{n}{\sigma_y^2} + \frac{1}{\sigma_\theta^2} \right)^{-1} = \left(\frac{12}{2} + \frac{1}{10} \right)^{-1} \approx 0.16 \quad (57)$$

und

$$\frac{\mu_\theta}{\sigma_\theta^2} + \frac{n\bar{y}}{\sigma_y^2} = \frac{0}{10} + \frac{12 \cdot 3.14}{2} = 18.84. \quad (58)$$

Beispiel (Fortsetzung)

- Die Posterior-Unsicherheit über θ_{TBU} wird somit beschrieben durch

$$N\left(\theta; \mu_{\theta|y}, \sigma_{\theta|y}^2\right) \text{ mit } \mu_{\theta|y} \approx 0.16 \cdot 18.84 = 3.01 \text{ und } \sigma_{\theta|y}^2 = 0.16. \quad (59)$$

- Aus der Posterior-Verteilung sind Punktschätzungen für θ_{TBU} gegeben durch

$$\hat{\theta}_{\text{MMSE}} = \hat{\theta}_{\text{MAP}} \approx 3.01. \quad (60)$$

- In Bezug auf Kredititätsintervalle können wir zum Beispiel ableiten, dass die posteriore Wahrscheinlichkeit von $\vartheta \geq 0$ ist

$$\mathbb{P}(\vartheta \geq 0) = 1 - \mathbb{P}(\vartheta \leq 0) = 1 - P(0) \approx 1 - 0 = 1. \quad (61)$$


während die Prior-Wahrscheinlichkeit von $\vartheta \geq 0$ 0.5 betrug.

- Die Z-Statistik und der p-Wert für den Nullhypothesenparameter $\mu_0 = 0$ in einem solchen Z-Test-Szenario entsprechen


$$Z := \sqrt{n} \left(\frac{\bar{y} - \mu_0}{\sigma_y} \right) = \sqrt{12} \cdot \frac{3.14}{\sqrt{2}} \approx 7.69 \text{ und p-Wert} \approx 0. \quad (62)$$

Beispiel (Fortsetzung)

$$p(\theta) = N(\theta; 0, 10)$$



$$p(\theta|y) = N(\theta; 3.01, 0.16)$$



Weitere häufig anzutreffende konjugierte Modelle umfassen

- das Dirichlet-Multinomial-Modell,
- das Gauß-Gamma-Gauß-Modell,
- das multivariate Gauß-Gauß-Modell,
- das Gauß-Wishart-Gauß-Modell.

Eine umfassende Theorie für konjugierte Analyse wird bereitgestellt durch

- Konjugierte Inferenz in der Exponentialfamilie.

Das Bayesianische Paradigma

Inferenzzusammenfassungen

Konjugierte Inferenz

Numerische Inferenz

Variationale Inferenz

Definition (Cauchy-Zufallsvariable)

Sei v eine Zufallsvariable mit Ergebnismenge $\mathbb{R}$ und Dichtefunktion

$$p : \mathbb{R} \rightarrow \mathbb{R}_{>0}, y \mapsto p(y) := \frac{1}{\pi s} \left(1 + \left(\frac{y - \theta}{s} \right)^2 \right)^{-1} \quad (63)$$




Dann heißt v gemäß einer *Cauchy-Verteilung* mit Lageparameter $\theta \in \mathbb{R}$ und Skalenparameter $s > 0$ verteilt, wofür wir $v \sim C(\theta, s)$ schreiben. Wir bezeichnen die Dichtefunktion einer Cauchy-Zufallsvariable mit

$$C(y; \theta, s) := \frac{1}{\pi s} \left(1 + \left(\frac{y - \theta}{s} \right)^2 \right)^{-1} \quad (64)$$

Bemerkungen

- Cauchy-Verteilungen modellieren Phänomene mit höheren Wahrscheinlichkeiten für Extremwerte als die Gauß-Verteilung.
- Sowohl der Erwartungswert als auch die Varianz einer Cauchy-Zufallsvariable sind nicht definiert.
- Der Modus und der Median einer Cauchy-Zufallsvariable sind durch θ gegeben.
- Das Verhältnis zweier standardnormalverteilter Zufallsvariablen ist gemäß $C(0, 1)$ verteilt.

Cauchy-Dichtefunktionen



Die Posterior-Verteilung ist zentral für die Bayesianische Inferenz.

Prior und Likelihood sind Modellierungsentscheidungen, aber der Normierungsfaktor

$$p(y) = \int p(y|\theta)p(\theta) d\theta \quad (65)$$

muss ausgewertet werden.

In konjugierten Modellen ist die Auswertung des Posteriors analytisch handhabbar.

In nicht-konjugierten Modellen ist dies möglicherweise nicht der Fall.

Zum Beispiel ergeben $p(\theta) = N(\theta; \mu, \sigma^2)$ und $p(y|\theta) = \prod_{i=1}^n C(y_i; \theta, 1)$

$$p(\theta|y) \propto \exp\left(-\frac{1}{2\sigma^2}(\theta - \mu)^2\right) \prod_{i=1}^n (1 + (y_i - \theta)^2)^{-1}. \quad (66)$$

Die rechte Seite kann nicht analytisch integriert werden.

Selbst wenn die Posterior-Verteilung analytisch handhabbar ist, kann die Auswertung Bayesianischer Schätzer




$$\hat{\theta}_B = \mathbb{E}_{p(\theta|y)}(f(\theta)) = \int f(\theta)p(\theta|y) d\theta \quad (67)$$

analytisch unmöglich sein.

⇒ Bayesianische Inferenz erfordert häufig Methoden zur numerischen Integration.

Beispiel

$p(\theta) := N(\theta; 0, 1)$ und $p(y_i|\theta) := C(y_i; \theta, 1), i = 1, \dots, n$ für $n := 1$ und $y_1 := 2$



Hier geben wir einen Überblick über die folgenden numerischen Integrationsmethoden

- Quadraturansätze als klassische Mittel zur numerischen Integration,
- die Laplace-Approximation als analytische Integralapproximationsmethode und
- Monte-Carlo-Integration, d.h. numerische Integration durch Stichprobenziehung und Schätzung.

Zusätzlich betrachten wir

- Importance Sampling
- Acceptance-Rejection-Sampling

als spezialisierte Stichprobenverfahren für Monte-Carlo-Integration.

Der Kürze halber verzichten wir darauf,

- die Vor- und Nachteile verschiedener Methoden zu diskutieren,
- Markov-Ketten-basierte Stichprobenverfahren (MCMC) zu betrachten.

Quadratur

... ist ein Synonym für deterministische numerische Integration.

... ist ein Thema der numerischen Mathematik.

... funktioniert typischerweise gut für niedrigdimensionale Integrationsprobleme.

... umfasst viele verschiedene Methoden, wie etwa

- Riemann-Summen
- Trapezregel
- Simpson-Regel
- Newton-Cotes-Formeln

Wir wiederholen kurz Riemann-Summen als Beispiel.

Definition (Riemann-Summe und Riemann-Integral)

Sei $f : [a, b] \rightarrow \mathbb{R}$ eine univariate reellwertige Funktion auf $[a, b] \subset \mathbb{R}$. Sei

$$P_n := \{[x_0, x_1], [x_1, x_2], \dots, [x_{n-1}, x_n]\} \quad (68)$$

mit

$$a =: x_0 < x_1 < x_2 < \dots < x_n := b \quad (69)$$

eine Partition des Intervalls $[a, b]$. Dann ist die *Riemann-Summe* S_n von f über dem Intervall $[a, b]$ basierend auf der Partition P_n definiert als

$$S_n := \sum_{i=1}^n f(x_i^*) \Delta x_i \text{ mit } \Delta x_i := x_i - x_{i-1} \text{ und } x_i^* \in [x_{i-1}, x_i]. \quad (70)$$

Das *bestimmte Riemann-Integral* von f auf $[a, b]$ ist definiert als

$$\int_a^b f(x) dx = \lim_{\Delta x \rightarrow 0} \sum_{i=1}^n f(x_i^*) \Delta x_i, \quad (71)$$

falls der Grenzwert auf der rechten Seite existiert.

Bemerkung

- Eine grundlegende Quadraturidee ist es, Integrale durch Riemann-Summen zu approximieren.

Definition (Linksregel, Rechtsregel, Mittelpunktregel)

Sei $f : [a, b] \rightarrow \mathbb{R}$ und angenommen, das Ziel ist es, das Integral

$$I = \int_a^b f(x) dx \quad (72)$$

mithilfe einer Riemann-Summe S_n zu approximieren. Dann heißt das Setzen von

- $x_i^* := x_{i-1}$ die *Linksregel*,
- $x_i^* := x_i$ die *Rechtsregel*, und
- $x_i^* := \frac{1}{2}(x_i + x_{i-1})$ die *Mittelpunktregel*.

Bemerkungen

- Für $\Delta x \rightarrow 0$ spielt die Wahl von x_i^* für das Riemann-Integral keine Rolle.
- Häufig werden Äquidistantzerlegungen der Form $\Delta x = (b - a)/n$ verwendet.
- f wird durch stückweise konstante Funktionen approximiert.

```
\begin{minipage}{.32\begin{center} Linksregel
```

```
\end{center} \end{minipage} \begin{minipage}{.32\begin{center} Rechtsregel
```

```
\end{center} \end{minipage} \begin{minipage}{.32\begin{center} Mittelpunktregel
```

```
\end{center} \end{minipage}
```

Beispiele

Numerische Integration univariater reellwertiger Funktionen in R mithilfe der Quadraturmethoden von Piessens et al. (1983)

Integral von $f(x) = N(x; 2, 3)$ auf $]-\infty, \infty[$: 1

Integral von $f(x) = N(x; 0, 1)$ von -1.96 bis 1.96: 0.9500042

Integral von $f(x) = xN(x; 2, 3)$ auf $]-\infty, \infty[$: 2

Integral von $f(x) = (x-2)^2 N(x; 2, 3)$ auf $]-\infty, \infty[$: 3

Beispiele

Numerische Integration univariater reellwertiger Funktionen in R mithilfe der Quadraturmethoden von Piessens et al. (1983)

Integral von $N(\theta; 0, 1)C(2; \theta, 1)$ auf $[-2, 2]$: 0.3726037

Integral von $(1/p(2)) * N(\theta; 0, 1)C(2; \theta, 1)$ auf $[-2, 2]$: 1

Integral von $\theta * (1/p(2)) * N(\theta; 0, 1)C(2; \theta, 1)$ auf $[-2, 2]$: 0.6231123

Die Laplace-Approximation

- ... ist eine Methode zur Approximation posteriorer Erwartungswerte des Typs

$$\mathbb{E}_{p(\theta|y)}(f(\theta)) = \int f(\theta)p(\theta|y) d\theta, \quad (73)$$

wie etwa des posterioren Erwartungswerts

$$\mathbb{E}_{p(\theta|y)} = \int \theta p(\theta|y) d\theta. \quad (74)$$

- ... benötigt nicht die funktionale Form der Posterior-Verteilung.
- ... ist eine Anwendung von *Laplace's Integralapproximationsmethode*.

Definition (Laplaces Integralapproximationsmethode)

Für eine univariate, reellwertige, konvexe und zweimal differenzierbare Funktion f mit einem Minimum bei $\tilde{x}$ ist eine sinnvolle Approximation des Integrals

$$I_n = \int_{-\infty}^{\infty} \exp(-nf(x)) dx \quad (75)$$

gegeben durch

$$I_n \approx \exp(-nf(\tilde{x})) \sqrt{\frac{2\pi}{n\kappa}}, \quad (76)$$

wobei

$$\kappa := f''(\tilde{x}) > 0 \quad (77)$$

die zweite Ableitung von f an seiner Minimumstelle $\tilde{x}$ bezeichnet.

Bemerkungen

- Die Minimumstelle $\tilde{x}$ und $\kappa = f''(\tilde{x})$ müssen ausgewertet werden.
- Die Approximation beruht auf einer Taylor-Approximation zweiter Ordnung von f in $\tilde{x}$ und

$$\int_{-\infty}^{\infty} \exp(-a(x-b)^2) dx = \sqrt{\pi/a}. \quad (78)$$

- „Sinnvoll“ bedeutet, dass der Approximationsfehler für $n \rightarrow \infty$ abnimmt.

Motivation von Laplaces Integralapproximationsmethode

Betrachte die Taylor-Approximation zweiter Ordnung von f in $\tilde{x}$,

$$f(x) \approx f(\tilde{x}) + f'(\tilde{x})(x - \tilde{x}) + \frac{1}{2} f''(\tilde{x})(x - \tilde{x})^2. \quad (79)$$

Da $\tilde{x}$ ein Minimum von f ist, gilt $f'(\tilde{x}) = 0$ und $\kappa := f''(\tilde{x}) > 0$. Wir haben dann

$$\begin{aligned} I_n &= \int_{-\infty}^{\infty} \exp(-nf(x)) dx \\ &\approx \int_{-\infty}^{\infty} \exp\left(-n\left(f(\tilde{x}) + \frac{1}{2}\kappa(x - \tilde{x})^2\right)\right) dx \\ &= \int_{-\infty}^{\infty} \exp\left(-nf(\tilde{x}) - \frac{n}{2}\kappa(x - \tilde{x})^2\right) dx \\ &= \int_{-\infty}^{\infty} \exp(-nf(\tilde{x})) \exp\left(-\frac{n}{2}\kappa(x - \tilde{x})^2\right) dx \\ &= \exp(-nf(\tilde{x})) \int_{-\infty}^{\infty} \exp\left(-\frac{n\kappa}{2}(x - \tilde{x})^2\right) dx. \end{aligned} \quad (80)$$

Mit

$$\int_{-\infty}^{\infty} \exp(-a(x - b)^2) dx = \sqrt{\pi/a}, \quad (81)$$

folgt dann

$$I_n = \exp(-nf(\tilde{x})) \sqrt{\frac{2\pi}{n\kappa}}. \quad (82)$$

Definition (Laplace-Approximation)

Sei

$$p(\theta, y) = p(y|\theta)p(\theta) \quad (83)$$

ein probabilistisches Modell mit skalarem Parameter θ und bezeichne $v = (v_1, \dots, v_n)$ eine Zufallsstichprobe mit Dichte-/Wahrscheinlichkeitsfunktion $p(y_i|\theta)$ für $i = 1, \dots, n$. Betrachte das Problem der Auswertung eines Posterior-Verteilungserwartungswerts der Form

$$\mathbb{E}_{p(\theta|y)}(f(\theta)) \text{ für } f: \mathbb{R} \rightarrow \mathbb{R}, \theta \mapsto f(\theta). \quad (84)$$

Eine sinnvolle Approximation eines solchen Merkmals ist gegeben durch

$$\mathbb{E}_{p(\theta|y)}(f(\theta)) \approx \sqrt{\frac{\kappa_1}{\kappa_2}} \exp\left(-n\left(h_2(\tilde{\theta}_2) - h_1(\tilde{\theta}_1)\right)\right), \quad (85)$$

wobei

$$\begin{aligned} h_1: \mathbb{R} \rightarrow \mathbb{R}, \theta \mapsto h_1(\theta) &:= -\ln f(\theta) - \ln p(y_i|\theta) - \ln p(\theta) \\ h_2: \mathbb{R} \rightarrow \mathbb{R}, \theta \mapsto h_2(\theta) &:= -\ln p(y_i|\theta) - \ln p(\theta), \end{aligned} \quad (86)$$

$\tilde{\theta}_1$ und $\tilde{\theta}_2$ Minimumstellen von h_1 bzw. h_2 sind, und

$$\kappa_1 := h_1''(\tilde{\theta}_1) > 0 \text{ und } \kappa_2 := h_2''(\tilde{\theta}_2) > 0. \quad (87)$$

Bemerkungen

- „Sinnvoll“ bedeutet, dass der Approximationsfehler für $n \rightarrow \infty$ abnimmt.
- Wenn $\kappa_1, \kappa_2, \tilde{\theta}_1, \tilde{\theta}_2$ nicht analytisch verfügbar sind, werden sie numerisch ausgewertet.

Motivation der Laplace-Approximation

Wir stellen zunächst fest, dass wir mit den Definitionen von h_1 und h_2 haben

$$\begin{aligned}\mathbb{E}_{p(\theta|y)}(f(\theta)) &= \int f(\theta)p(\theta|y) d\theta \\&= \int f(\theta) \frac{p(y|\theta)p(\theta)}{\int p(y|\theta)p(\theta) d\theta} d\theta \\&= \frac{\int f(\theta)p(y|\theta)p(\theta) d\theta}{\int p(y|\theta)p(\theta) d\theta} \\&= \frac{\int \exp(\ln(f(\theta)p(y|\theta)p(\theta))) d\theta}{\int \exp(\ln(p(y|\theta)p(\theta))) d\theta} \\&= \frac{\int \exp(\ln(f(\theta) \prod_{i=1}^n p(y_i|\theta)p(\theta))) d\theta}{\int \exp(\ln(\prod_{i=1}^n p(y_i|\theta)p(\theta))) d\theta} \tag{88} \\&= \frac{\int \exp(\ln(\prod_{i=1}^n f(\theta)p(y_i|\theta)p(\theta))) d\theta}{\int \exp(\ln(\prod_{i=1}^n p(y_i|\theta)p(\theta))) d\theta} \\&= \frac{\int \exp(n \ln f(\theta) + n \ln p(y_i|\theta) + n \ln p(\theta)) d\theta}{\int \exp(n \ln p(y_i|\theta) + n \ln p(\theta)) d\theta} \\&= \frac{\int \exp(-nh_2(\theta)) d\theta}{\int \exp(-nh_1(\theta)) d\theta}.\end{aligned}$$

Motivation der Laplace-Approximation (Fortsetzung)

Anwendung von Laplaces Integralapproximationsmethode auf Zähler und Nenner von

$$\mathbb{E}_{p(\theta|y)}(\theta) = \frac{\int \exp(-nh_2(\theta)) d\theta}{\int \exp(-nh_1(\theta)) d\theta} \quad (89)$$

liefert dann

$$\begin{aligned} \mathbb{E}_{p(\theta|y)}(\theta) &\approx \frac{\exp(-nh_1(\tilde{\theta}_1)) \sqrt{\frac{2\pi}{n\kappa_1}}}{\exp(-nh_2(\tilde{\theta}_2)) \sqrt{\frac{2\pi}{n\kappa_2}}} \\ &= \sqrt{\frac{2\pi}{n\kappa_1} \frac{n\kappa_2}{2\pi}} \exp(-nh_1(\tilde{\theta}_1) + nh_2(\tilde{\theta}_2)) \\ &= \sqrt{\frac{\kappa_1}{\kappa_2}} \exp(-n(h_1(\tilde{\theta}_1) - h_2(\tilde{\theta}_2))) . \end{aligned} \quad (90)$$

Monte-Carlo-Integration

- ... ist ein Mittel zur Approximation von Integralen mithilfe zufälliger Stichprobenziehung.
- ... war angeblich ein Codewort im Manhattan-Projekt.
- ... wird für hochdimensionale Integration mit starker Lokalisierung verwendet.
- ... ersetzt deterministische Stützpunkte durch zufällige Stützpunkte.

Definition (Monte-Carlo-Schätzer, Monte-Carlo-Algorithmus)

Für eine univariate stetige Zufallsvariable ξ mit Verteilung $\mathbb{P}$ und Dichte p und eine univariate reellwertige Funktion f sei

$$I := \mathbb{E}_{\mathbb{P}}(f(\xi)) := \int_{\mathcal{X}} f(x)p(x) dx. \quad (91)$$

Ferner seien $\xi_1, \dots, \xi_m$ eine Stichprobe unabhängiger Kopien von ξ . Dann heißt

$$\hat{I}_m = \frac{1}{m} \sum_{i=1}^m f(\xi_i) \quad (92)$$

der *Monte-Carlo-Schätzer* des Integrals I . Ein *Monte-Carlo-Algorithmus* zur Gewinnung einer Monte-Carlo-Schätzung von I ist gegeben durch

- (1) Ziehe $\xi_1, \dots, \xi_m \sim \mathbb{P}$.
- (2) Werte $\hat{I}_m = \frac{1}{m} \sum_{i=1}^m f(\xi_i)$ aus und gib ihn zurück.

Theorem (Unverzerrtheit und Konsistenz des Monte-Carlo-Schätzers)

Der Monte-Carlo-Schätzer ist unverzerrt und konsistent.

Beweis

Unverzerrtheit

$$\mathbb{E}_{\mathbb{P}}(\hat{I}_m) = \mathbb{E}_{\mathbb{P}}\left(\frac{1}{m} \sum_{i=1}^m f(\xi_i)\right) = \frac{1}{m} \sum_{i=1}^m \mathbb{E}_{\mathbb{P}}(f(\xi_i)) = \frac{1}{m} m \mathbb{E}_{\mathbb{P}}(f(\xi)) = \mathbb{E}_{\mathbb{P}}(f(\xi)). \quad (93)$$

Konsistenz

Das schwache Gesetz der großen Zahlen besagt, dass

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\left|\frac{1}{m} \sum_{i=1}^m f(\xi_i) - \mathbb{E}_{\mathbb{P}}(f(\xi))\right| \geq \epsilon\right) = 0 \quad (94)$$

was die Konsistenz des Schätzers $\hat{I}_m = \frac{1}{m} \sum_{i=1}^m f(\xi_i)$ impliziert

□

Beispiel

Betrachte die Auswertung des Integrals

$$I = \int_0^1 f(x) dx \text{ für } f: \mathbb{R} \rightarrow \mathbb{R}, x \mapsto f(x) := x^2. \quad (95)$$

Wir stellen zunächst fest, dass

$$\int_0^1 x^2 dx = \int_0^1 x^2 \cdot 1 dx = \int_0^1 x^2 \cdot p(x) dx \text{ für } p(x) := 1, x \in [0, 1]. \quad (96)$$

Eine Zufallsvariable ξ mit Ergebnisraum $\mathcal{X} = [0, 1]$ und $p(x) := 1$ ist $\xi \sim U(0, 1)$.

Somit ist ein Monte-Carlo-Schätzer von I

$$\hat{I}_m = \frac{1}{m} \sum_{i=1}^m x_i^2, \quad (97)$$

wobei $x_1, \dots, x_m$ m unabhängige Realisierungen von Zufallsvariablen $\xi_1, \dots, \xi_m \sim U(0, 1)$ bezeichnen.

Beispiel (Fortsetzung)

Analytisch haben wir mit der Stammfunktion $F(x) = \frac{1}{3}x^3$ von $f(x) = x^2$

$$I = \int_0^1 x^2 dx = F(1) - F(0) = \frac{1}{3}1^3 - \frac{1}{3}0^3 = \frac{1}{3}. \quad (98)$$

Numerische Integration mithilfe von Quadratur

Quadraturapproximation des Integrals von x^2 auf $[0,1]$: 0.3333333

Numerische Integration mithilfe von Monte-Carlo-Schätzung

Monte-Carlo-Schätzung des Integrals von x^2 auf $[0,1]$: 0.3331614

Importance Sampling

- ... ist eine Methode zur Approximation von Erwartungswerten $\mathbb{E}_p(f(\xi))$.
- ... funktioniert durch Ziehen von Stichproben $\xi \sim q$ anstelle von $\xi \sim p$.
- ... kann auch angewendet werden, wenn die Normierungskonstanten von q und p unbekannt sind.
- ... kann verwendet werden, um die Varianz von Monte-Carlo-Schätzern zu reduzieren.

Theorem (Importance-Sampling-Identität)

Seien p und q Dichtefunktionen auf $\mathcal{X} \subseteq \mathbb{R}$, sodass $q(x) > 0$ für alle $x \in \mathcal{X}$ mit $p(x) > 0$. Dann gilt für jede Funktion $f : \mathcal{X} \rightarrow \mathbb{R}$

$$\mathbb{E}_p(f(\xi)) = \mathbb{E}_q(f(\xi)w(\xi)), \quad (99)$$

wobei

$$w : \mathcal{X} \rightarrow \mathbb{R}_{>0}, x \mapsto w(x) := \frac{p(x)}{q(x)} \quad (100)$$

die *Importance-Gewichtsfunktion* bezeichnet.

Beweis

$$\mathbb{E}_p(f(\xi)) = \int_{\mathcal{X}} f(x)p(x) dx = \int_{\mathcal{X}} f(x) \frac{p(x)}{q(x)} q(x) dx = \int_{\mathcal{X}} f(x)w(x)q(x) dx = \mathbb{E}_q(f(\xi)w(\xi)) \quad (101)$$

□

Bemerkungen

- Beachte, dass der Erwartungswert von f unter p gleich dem Erwartungswert von $f \cdot w$ unter q ist.
- p und q werden als *nominale Verteilung* bzw. *Importance-Verteilung* bezeichnet.

Theorem (Importance-Sampling-Schätzer)

Seien p und q Dichtefunktionen auf $\mathcal{X} \subseteq \mathbb{R}$ und sei $f : \mathcal{X} \rightarrow \mathbb{R}$ eine Funktion, sodass

$$I := \mathbb{E}_p(f(\xi)) \quad (102)$$

existiert. Angenommen, $q(x) > 0$ für alle $x \in \mathcal{X}$ mit $p(x)f(x) \neq 0$. Schließlich sei angenommen, dass $\xi_1, \dots, \xi_m \sim q$. Dann ist

$$\hat{I}_m := \frac{1}{m} \sum_{i=1}^m f(\xi_i) w(\xi_i) \quad (103)$$

ein unverzerrter und konsistenter Schätzer von I .

Beweis

Wir haben

$$\mathbb{E}_q(\hat{I}_m) = \mathbb{E}_q\left(\frac{1}{m} \sum_{i=1}^m f(\xi_i) w(\xi_i)\right) = \frac{1}{m} m \mathbb{E}_q(f(\xi_i) w(\xi_i)) = \mathbb{E}_p(f(\xi_i)) \quad (104)$$

und daher ist der Schätzer unverzerrt. Konsistenz folgt mit dem Gesetz der großen Zahlen.

□

Bemerkungen

- $\xi_1, \dots, \xi_m \sim q$ und $\hat{I}_m := \frac{1}{m} \sum_{i=1}^m f(\xi_i) \frac{p(\xi_i)}{q(\xi_i)}$ werden verwendet, um $\mathbb{E}_p(f(\xi))$ zu schätzen.

Theorem (Normalisierte Importance-Sampling-Identität)

Für Normierungskonstanten c_p, c_q seien $p := \tilde{p}/c_p$ und $q = \tilde{q}/c_q$ Dichtefunktionen auf $\mathcal{X} \subseteq \mathbb{R}$, sodass $q(x) > 0$ für alle $x \in \mathcal{X}$ mit $p(x) > 0$. Dann gilt für jede Funktion $f : \mathcal{X} \rightarrow \mathbb{R}$

$$\mathbb{E}_p(f(\xi)) = \frac{\mathbb{E}_q(f(\xi)\tilde{w}(\xi))}{\mathbb{E}_q(\tilde{w}(\xi))}, \quad (105)$$

wobei $\tilde{w}$ die Importance-Gewichtsfunktion bezeichnet

$$\tilde{w} : \mathcal{X} \rightarrow \mathbb{R}_{>0}, x \mapsto \tilde{w}(x) := \frac{\tilde{p}(x)}{\tilde{q}(x)}. \quad (106)$$

Bemerkung

- $\mathbb{E}_p(f(\xi))$ wird hier auf Basis einer „unnormalisierten Dichte“ $\tilde{p} = c_p p$ geschätzt.

Beweis

$$\begin{aligned}
 \frac{\mathbb{E}_q(f(\xi)\tilde{w}(\xi))}{\mathbb{E}_q(\tilde{w}(\xi))} &= \frac{\mathbb{E}_q\left(f(\xi)\frac{\tilde{p}(\xi)}{\tilde{q}(\xi)}\right)}{\mathbb{E}_q\left(\frac{\tilde{p}(\xi)}{\tilde{q}(\xi)}\right)} \\
 &= \frac{\mathbb{E}_q\left(f(\xi)\frac{c_p c_q \tilde{p}(\xi)}{c_p c_q \tilde{q}(\xi)}\right)}{\mathbb{E}_q\left(\frac{c_p c_q \tilde{p}(\xi)}{c_p c_q \tilde{q}(\xi)}\right)} \\
 &= \frac{\mathbb{E}_q\left(f(\xi)\frac{c_q p(\xi)}{c_p q(\xi)}\right)}{\mathbb{E}_q\left(\frac{c_q p(\xi)}{c_p q(\xi)}\right)} \\
 &= \frac{\int_{\mathcal{X}} f(x) \frac{c_q p(x)}{c_p q(x)} q(x) dx}{\int_{\mathcal{X}} \frac{c_q p(x)}{c_p q(x)} q(x) dx} \\
 &= \frac{\int_{\mathcal{X}} f(x) \frac{c_q p(x)}{c_p} dx}{\int_{\mathcal{X}} \frac{c_q p(x)}{c_p} dx} \\
 &= \frac{\frac{c_q}{c_p} \int_{\mathcal{X}} f(x) p(x) dx}{\frac{c_q}{c_p} \int_{\mathcal{X}} p(x) dx} \\
 &= \int_{\mathcal{X}} f(x) p(x) dx = \mathbb{E}_p(f(\xi))
 \end{aligned} \tag{107}$$

Definition (Normalisierter Importance-Sampling-Schätzer)

Für eine unbekannte Normierungskonstante c_p und $c_q := 1$ seien $p := \tilde{p}/c_p$ und $q := \tilde{q}/c_q$ Dichtefunktionen auf $\mathcal{X} \subseteq \mathbb{R}$, sodass $q(x) > 0$ für alle $x \in \mathcal{X}$ mit $p(x) > 0$. Sei $f : \mathcal{X} \rightarrow \mathbb{R}$ eine Funktion, sodass

$$I := \mathbb{E}_p(f(\xi)) \quad (108)$$

existiert. Angenommen, $q(x) > 0$ für alle $x \in \mathcal{X}$ mit $p(x)f(x) \neq 0$. Schließlich sei angenommen, dass $\xi_1, \dots, \xi_m \sim q$. Dann heißt

$$\hat{I}_m := \frac{\sum_{i=1}^n f(\xi_i) \tilde{w}(\xi_i)}{\sum_{i=1}^n \tilde{w}(\xi_i)} \quad (109)$$

der *normalisierte Importance-Sampling-Schätzer* von I .

Bemerkungen

- $\xi_1, \dots, \xi_m \sim q$ und $\hat{I}_m$ werden verwendet, um I für die „unnormalisierte Dichte“ $\tilde{p}$ zu schätzen.
- Der Stichprobenmittelwertfaktor m^{-1} kürzt sich im Bruch von $\hat{I}_m$ heraus.
- Es kann gezeigt werden, dass $\hat{I}_m$ verzerrt, aber asymptotisch unverzerrt und konsistent ist.

Beispiel

- Wir betrachten die Approximation des posterioren Erwartungswerts eines Gauß-Gauß-Modells für $n := 1$

$$p(y, \theta) = p(y|\theta)p(\theta) := N(y; \theta, \sigma_y^2)N(\theta; \mu_\theta, \sigma^2). \quad (110)$$

- Wir betrachten somit die Approximation des Erwartungswerts von

$$\tilde{p}(\theta) := p(y|\theta)p(\theta) = N(y; \theta, \sigma_y^2)N(\theta; \mu_\theta, \sigma^2) \propto p(\theta|y). \quad (111)$$

- Wir nehmen $y = 4$, $\sigma_y^2 = 2$, $\mu_\theta := 0$, $\sigma_\theta^2 = 10$ an.
- Aus den analytischen Ergebnissen in (2) Konjugierte Inferenz haben wir

$$\mathbb{E}_{p(\theta|y)}(\theta) = \left(\frac{n}{\sigma_y^2} + \frac{1}{\sigma_\theta^2} \right)^{-1} \left(\frac{\mu_\theta}{\sigma_\theta^2} + \frac{ny}{\sigma_y^2} \right) = \left(\frac{1}{2} + \frac{1}{10} \right)^{-1} \left(\frac{0}{10} + \frac{4}{2} \right) = \frac{10 \cdot 2}{6} \approx 3.3\bar{3}.$$

- Wir betrachten die Stichprobenziehung $\vartheta_1, \dots, \vartheta_m \sim N(0, 1)$, d.h. $q(\theta) := N(\theta; 0, 1)$.
- In Bezug auf den normalisierten Importance-Sampling-Schätzer haben wir somit

$$x := \theta, f = \text{id}_{\mathbb{R}}, \tilde{p}(\theta) := N(4; \theta, 2)N(\theta; 0, 10), \tilde{q}(\theta) = N(\theta; 0, 1) \quad (112)$$

und

$$\tilde{w}(\theta) := \frac{N(4; \theta, 2)N(\theta; 0, 10)}{N(\theta; 0, 1)} \quad (113)$$

Beispiel (Fortsetzung)

Approximierter posteriorer Erwartungswert: 3.3028

Acceptance-Rejection-Sampling

- ... ist eine Methode, um Stichproben aus $v \sim p_Y$ durch Stichprobenziehung $X \sim p_X$ zu erhalten.
- ... ist eine algorithmische Alternative zur Wahrscheinlichkeitsintegraltransformation.
- ... funktioniert durch strategisches Verwerfen von Stichproben aus X .
- ... funktioniert durch Induktion eines Stichprobenbias in den Stichproben aus X .
- ... kann in MC-Integration verwendet werden, wenn Stichprobenziehung aus dem Posterior schwierig ist.

Theorem (Acceptance-Rejection-Sampling)

Seien p_X und p_Y zwei Dichtefunktionen, bezeichnet als *Vorschlagsdichte* bzw. *Zieldichte*, sodass

- o Zufallsstichproben von $X \sim p_X$ gewonnen werden können,
- o die Funktion p_Y/p_X ausgewertet werden kann, und
- o $p_Y \leq cp_X$ für eine Konstante $c \in \mathbb{R}$.

Betrachte den folgenden *Acceptance-Rejection-Algorithmus*

1. Ziehe eine Realisierung $X \sim p_X$ der Vorschlagsdichte.
2. Ziehe eine Realisierung $U \sim U(0, 1)$ der Gleichverteilung auf $[0, 1]$.
3. Falls

$$U \leq \frac{p_Y(X)}{cp_X(X)} \quad (114)$$

gib $Y = X$ zurück. Andernfalls kehre zu Schritt 1 zurück.

Dann ist Y gemäß der Zieldichte verteilt, $Y \sim p_Y$.

Bemerkungen

- Beachte, dass der Algorithmus $X \sim p_X$ bedingt auf $U \leq \frac{p_Y(X)}{cp_X(X)}$ zurückgibt.
- Die Aussage des Theorems kann somit äquivalent ausgedrückt werden als

$$\mathbb{P}\left(X \leq x \mid U \leq \frac{p_Y(X)}{cp_X(X)}\right) = \int_{-\infty}^x p_Y(\xi) d\xi. \quad (115)$$

Beweis

Wir wollen zeigen, dass die bedingte Verteilung von X gegeben das Ereignis $U \leq p_Y(X)/cp_X(X)$ der Zieldichte p_Y entspricht. Zur Vereinfachung der Notation sei

$$f(X) := p_Y(X)/cp_X(X). \quad (116)$$

Die bedingte Wahrscheinlichkeit des Ereignisses $X \leq x$ gegeben das Ereignis $U \leq f(X)$ kann dann geschrieben werden als

$$\mathbb{P}(X \leq x | U \leq f(X)) = \frac{\mathbb{P}(X \leq x, U \leq f(X))}{\mathbb{P}(U \leq f(X))}. \quad (117)$$

Um den Zähler der rechten Seite oben auszuwerten, stellen wir zunächst fest, dass

$$\begin{aligned} \mathbb{P}(X \leq x, U \leq f(X)) &= \mathbb{P}(U \leq f(X) | X \leq x) \mathbb{P}(X \leq x) \\ &= \mathbb{P}(U \leq f(x)) \mathbb{P}(X \leq x) \\ &= \int_{-\infty}^x \mathbb{P}(U \leq f(\xi)) p_X(\xi) d\xi. \end{aligned} \quad (118)$$

Mit der Verteilungsfunktion der stetigen Gleichverteilung auf $[0, 1]$ und der Definition von $f(X)$ erhalten wir dann

Beweis (Fortsetzung)

$$\begin{aligned}\mathbb{P}(X \leq x, U \leq f(X)) &= \int_{-\infty}^x \mathbb{P}(U \leq f(\xi)) p_X(\xi) d\xi \\ &= \int_{-\infty}^x f(\xi) p_X(\xi) d\xi \\ &= \int_{-\infty}^x \frac{p_Y(\xi)}{c p_X(\xi)} p_X(\xi) d\xi \\ &= \frac{1}{c} \int_{-\infty}^x p_Y(\xi) d\xi.\end{aligned}\tag{119}$$

Als Nächstes werten wir den Nenner oben aus und erhalten

$$\begin{aligned}\mathbb{P}(U \leq f(X)) &= \int_{-\infty}^{\infty} \mathbb{P}(U \leq f(X) | X = x) \mathbb{P}(X = x) dx \\ &= \int_{-\infty}^{\infty} \mathbb{P}(U \leq f(x)) \mathbb{P}(X = x) dx \\ &= \int_{-\infty}^{\infty} \mathbb{P}(U \leq f(\xi)) p_X(\xi) d\xi \\ &= \int_{-\infty}^{\infty} \frac{p_Y(\xi)}{c p_X(\xi)} p_X(\xi) d\xi \\ &= \frac{1}{c}.\end{aligned}\tag{120}$$

Beweis (Fortsetzung)

Zusammenfassend erhalten wir

$$\mathbb{P}(X \leq x | U \leq f(X)) = \frac{\frac{1}{c} \int_{-\infty}^x p_Y(\xi) d\xi}{\frac{1}{c}} d\xi = \int_{-\infty}^x p_Y(\xi) d\xi \quad (121)$$

Die bedingte Verteilung von X gegeben $U \leq \frac{p_Y(X)}{cp_X(X)}$ hat somit Dichte p_Y . Da wir die gemäß dieser Verteilung verteilte Zufallsvariable Y nennen, haben wir $Y \sim p_Y$ erhalten.

□

Das Bayesianische Paradigma

Inferenzzusammenfassungen

Konjugierte Inferenz

Numerische Inferenz

Variationale Inferenz

Definition (Variationales Inferenzproblem)

Sei $v := (v_1, \dots, v_n)$ eine Menge beobachtbarer zufälliger Entitäten, und sei $\zeta := (\zeta_1, \dots, \zeta_m)$ eine Menge latenter zufälliger Variablen. Angenommen, v und ζ bilden ein *probabilistisches Modell* mit Dichte-/Wahrscheinlichkeitsfunktion

$$p(y, z) = p(y|z)p(z). \quad (122)$$

Dann besteht das *variationale Inferenzproblem* darin,

- (1) die bedingte Verteilung $p(z|y)$ und
- (2) die logarithmische Modellevidenz $\ln p(y) = \ln \int p(y, z) dz$

zu approximieren.

Bemerkungen

- Bedingte Dichten und marginale Likelihoods sind zentral in der Bayesianischen Inferenz.
- Variationale Inferenz ist auch als Variational Bayes oder neuerdings als „variational autoencoding“ bekannt.
- Die latenten Variablen können Parameter oder latente Zustände repräsentieren.
- Es ist üblicher, dass $p(y, z)$ eine Dichtefunktion als eine Wahrscheinlichkeitsfunktion ist.

Theorem (Zerlegung der logarithmischen Modellevidenz)

Sei $p(y, z)$ ein probabilistisches Modell und sei $q(z)$ die Dichte-/Wahrscheinlichkeitsfunktion einer Verteilung über die latenten zufälligen Variablen, bezeichnet als *variationale Verteilung*. Dann gilt die folgende Zerlegung der logarithmischen Modellevidenz

$$\ln p(y) = \text{ELBO}(q(z)) + \text{KL}(q(z) || p(z|y)), \quad (123)$$

wobei

$$\text{ELBO}(q(z)) := \int q(z) \ln \left(\frac{p(y, z)}{q(z)} \right) dz \quad (124)$$

als *evidence lower bound* bezeichnet wird und

$$\text{KL}(q(z) || p(z|y)) := \int q(z) \ln \left(\frac{q(z)}{p(z|y)} \right) dz \quad (125)$$

als *Kullback-Leibler-Divergenz* zwischen $q(z)$ und $p(z|y)$ bezeichnet wird.

Bemerkungen

- Parameter von $q(z)$ werden als *Variationsparameter* bezeichnet.
- Die ELBO wird manchmal als *variationelle freie Energie* bezeichnet.

Beweis

Mit den Definitionen der evidence lower bound und der Kullback-Leibler-Divergenz haben wir

$$\begin{aligned}\text{ELBO}(q(z)) &= \int q(z) \ln \left(\frac{p(y, z)}{q(z)} \right) dz \\ &= \int q(z) \ln \left(\frac{p(y)p(z|y)}{q(z)} \right) dz \\ &= \int q(z) \ln p(y) dz + \int q(z) \ln \left(\frac{p(z|y)}{q(z)} \right) dz \\ &= \ln p(y) \int q(z) dz - \int q(z) \ln \left(\frac{q(z)}{p(z|y)} \right) dz \\ &= \ln p(y) - \text{KL}(q(z) || p(z|y)),\end{aligned}\tag{126}$$

woraus die Zerlegung der logarithmischen Modellevidenz unmittelbar folgt. □

Theorem (Kullback-Leibler-Divergenz)

Die *Kullback-Leibler (KL)-Divergenz* zweier Dichten $q(z)$ und $p(z)$ ist definiert als

$$\text{KL}(q(z)||p(z)) := \int q(z) \ln \left(\frac{q(z)}{p(z)} \right) dz \quad (127)$$

Sie dient als Unähnlichkeitsmaß von $q(z)$ und $p(z)$. Insbesondere gilt

$$\text{KL}(q(z)||p(z)) > 0 \text{ für } q(z) \neq p(z). \quad (128)$$

und

$$\text{KL}(q(z)||p(z)) = 0 \text{ für } q(z) = p(z) \quad (129)$$

Bemerkungen

- Die Nichtnegativität der KL-Divergenz ist zentral für variationale Inferenz.
- Die KL-Divergenz ist keine Metrik, aber $\frac{1}{2} (\text{KL}(q(z)||p(z)) + \text{KL}(p(z)||q(z)))$ ist eine.

Beweis

Wir stellen zunächst fest, dass für eine Dichte $q(z)$ und eine konvexe Funktion f die Jensen-Ungleichung gilt, d.h.

$$\int q(z) f(z) dz \geq f \left(\int q(z) z dz \right). \quad (130)$$

Da $\ln$ eine konkave Funktion ist und somit $-\ln$ eine konvexe Funktion ist, haben wir

$$\begin{aligned} \text{KL}(q(z)||p(z)) &:= \int q(z) \ln \left(\frac{q(z)}{p(z)} \right) dz \\ &= - \int q(z) \ln \left(\frac{p(z)}{q(z)} \right) dz \\ &\geq - \ln \left(\int q(z) \frac{p(z)}{q(z)} dz \right) = - \ln \left(\int p(z) dz \right) = - \ln 1 = 0. \end{aligned} \quad (131)$$



Schließlich gilt für $q(z) = p(z)$

$$\text{KL}(q(z)||p(z)) = \int q(z) \ln \left(\frac{q(z)}{p(z)} \right) dz = \int q(z) \cdot \ln 1 dz = \int q(z) \cdot 0 dz = 0. \quad (132)$$

Beispiel

KL-Divergenzen univariater Gauß-Verteilungen

$$\text{KL} \left(N(x; \mu_q, \sigma_q^2) || N(x; \mu_p, \sigma_p^2) \right), \mu_q := 0, \sigma_q^2 := 1. \quad (133)$$



Hintergrund

Theorem (Jensen-Ungleichung, diskreter Fall)

Sei $f : \mathbb{R} \rightarrow \mathbb{R}$ eine konvexe Funktion auf $]a, b[$, d.h., für $0 \leq q \leq 1$ und $x_1, x_2 \in]a, b[$ gilt

$$qf(x_1) + (1 - q)f(x_2) \geq f(qx_1 + (1 - q)x_2), \quad (134)$$

und seien $x_1, \dots, x_n \in]a, b[$ und $q_1, \dots, q_n$ mit $q_i \geq 0$ und $\sum_{i=1}^n q_i = 1$. Dann gilt

$$\sum_{i=1}^n q_i f(x_i) \geq f\left(\sum_{i=1}^n q_i x_i\right) \quad (135)$$

Bemerkung

- Intuitiv ergibt sich durch $n \rightarrow \infty$ und damit $q_i \mapsto q(x)$ mit $\int q(x) dx = 1$ und $f(x_i) \mapsto f(x)$ für $x \in \mathbb{R}$

$$\int q(x)f(x) dx \geq f\left(\int q(x)x dx\right) \quad (136)$$

Hintergrund (Fortsetzung)

Beweis

Wir beweisen das Theorem durch Induktion bezüglich n .

Induktionsanfang

Sei $n = 2$. Dann impliziert die Konvexität von f , dass für $q_1 := q$ und $q_2 := 1 - q$ mit $0 \leq q \leq 1$ und somit $q_i \geq 0, i = 1, 2$ und $\sum_{i=1}^2 q_i = 1$ gilt

$$\begin{aligned}\sum_{i=1}^2 q_i f(x_i) &= q_1 f(x_1) + q_2 f(x_2) \\ &= q f(x_1) + (1 - q) f(x_2) \\ &\geq f(q x_1 + (1 - q) x_2) \\ &= f(q_1 x_1 + q_2 x_2) \\ &= f\left(\sum_{i=1}^2 q_i x_i\right)\end{aligned}$$

Hintergrund (Fortsetzung)

Wir nehmen an, dass die Induktionsvoraussetzung für ein $n = k$ gilt, d.h.

$$\sum_{i=1}^k q_i f(x_i) \geq f\left(\sum_{i=1}^k q_i x_i\right) \quad (137)$$

und dass für $q_i \geq 0, i = 1, \dots, k+1$ gilt

$$\begin{aligned} \sum_{i=1}^{k+1} q_i &= 1 \Leftrightarrow \\ \sum_{i=1}^k q_i &= 1 - q_{k+1} \Leftrightarrow \\ \frac{1}{1 - q_{k+1}} \sum_{i=1}^k q_i &= \frac{1 - q_{k+1}}{1 - q_{k+1}} \\ \Leftrightarrow \sum_{i=1}^k \frac{q_i}{1 - q_{k+1}} &= 1. \end{aligned} \quad (138)$$

Wir haben dann durch zweimalige Verwendung der Konvexität von f

Hintergrund (Fortsetzung)

Beweis

$$\begin{aligned} f\left(\sum_{i=1}^{k+1} q_i x_i\right) &= f\left(\sum_{i=1}^k q_i x_i + q_{k+1} x_{k+1}\right) \\ &= f\left((1 - q_{k+1}) \sum_{i=1}^k \frac{q_i}{1 - q_{k+1}} x_i + q_{k+1} x_{k+1}\right) \\ &\leq (1 - q_{k+1}) f\left(\sum_{i=1}^k \frac{q_i}{1 - q_{k+1}} x_i\right) + q_{k+1} f(x_{k+1}) \\ &\leq (1 - q_{k+1}) \sum_{i=1}^k \frac{q_i}{1 - q_{k+1}} f(x_i) + q_{k+1} f(x_{k+1}) \\ &= \frac{1 - q_{k+1}}{1 - q_{k+1}} \sum_{i=1}^k q_i f(x_i) + q_{k+1} f(x_{k+1}) = \sum_{i=1}^{k+1} q_i f(x_i), \end{aligned} \tag{139}$$

sodass die Ungleichung auch für $n := k + 1$ gilt.

□

Theorem (Evidence lower bound)

Die ELBO ist eine untere Schranke der logarithmischen Modellevidenz,

$$\text{ELBO}(q(z)) \leq \ln p(y). \quad (140)$$

Beweis

Die Eigenschaft der ELBO als untere Schranke folgt direkt aus der Zerlegung der logarithmischen Modellevidenz

$$\ln p(y) = \text{ELBO}(q(z)) + \text{KL}(q(z) \| p(z|y)) \quad (141)$$

und der Nichtnegativität der KL-Divergenz

$$\text{KL}(q(z) \| p(z|y)) \geq 0. \quad (142)$$

□

Bemerkungen

- Für einen festen Datensatz y ist $\ln p(y)$ eine feste skalare Größe.

$$\ln p(y) = \ln \int p(y, z) dz$$

ELBO($q(z)$)	KL($q(z) p(z y)$)
----------------	----------------------

- Die ELBO-Eigenschaft legt zwei äquivalente Optionen zur Lösung des VI-Problems nahe.

(1) Minimiere $\text{KL}(q(z)||p(z|y))$ bezüglich $q(z)$

$$\Rightarrow q(z) \rightarrow p(z|y) \text{ und } \text{ELBO}(q(z)) \rightarrow \ln p(y).$$

(2) Maximiere $\text{ELBO}(q(z))$ bezüglich $q(z)$

$$\Rightarrow \text{ELBO}(q(z)) \rightarrow \ln p(y) \text{ und } q(z) \rightarrow p(z|y).$$

- Variationale Inferenz folgt typischerweise dem letzteren Ansatz.

Definition (Mean-field-Variationsapproximation, Inferenz)

Sei $\zeta = (\zeta_1, \dots, \zeta_m)$ die latenten Zufallsvariablen eines probabilistischen Modells im Rahmen des variationalen Inferenzproblems, und sei $\mathcal{S} := (\zeta_{s_1}, \dots, \zeta_{s_S})$ eine Partition von ζ in S paarweise disjunkte Teilmengen, sodass $\bigcup_{i=1}^S \zeta_{s_i} = \zeta$ und $\zeta_{s_i} \cap \zeta_{s_j} = \emptyset$ für $i \neq j$. Dann wird die Annahme, dass $\zeta_{s_1}, \dots, \zeta_{s_S}$ Teilmengen unabhängiger Variablen bilden, d.h.,

$$q(z) := \prod_{i=1}^S q(z_{s_i}), \quad (143)$$

wobei $q(z_{s_i})$ die Dichte-/Wahrscheinlichkeitsfunktion der Verteilung der Elemente von ζ_{s_i} , $i = 1, \dots, S$ bezeichnet, als *Mean-field-Approximation* der variationalen Verteilung bezeichnet. Die Verwendung einer Mean-field-Approximation für die variationale Verteilung in variationaler Inferenz wird als *Mean-field-Variationsinferenz* bezeichnet.

Bemerkungen

- Gängige Mean-field-Approximationen in variationaler Inferenz sind
 - $q(z) = \prod_{i=1}^m q(z_i)$ (vollständige Faktorisierung)
 - $q(z) = q(z_s)q(z_{\setminus s})$, wobei $Z_s \subset \zeta$ und $\zeta_{\setminus s} := \zeta \setminus Z_s$ (binäre Faktorisierung)
- Mean-field-Variationsinferenz vernachlässigt potenzielle Nicht-Unabhängigkeiten von $p(z|y)$.

Theorem (Free-form Mean-field-Variationsinferenz)

Sei $p(y, z)$ ein probabilistisches Modell, das beobachtbare Zufallsvariablen $v = (y_1, \dots, y_n)$ und latente Zufallsvariablen $\zeta = (\zeta_1, \dots, \zeta_m)$ umfasst. Sei $q(z)$ eine variationale Verteilung und angenommen, dass $q(z)$ binär faktorisiert, d.h. $q(z) = q(z_s)q(z_{\setminus s})$ mit $Z_s \subset \zeta$ und $\zeta_{\setminus s} := \zeta \setminus Z_s$. Dann maximiert das Setzen von

$$q(z_s) := \frac{1}{\gamma_s} \exp \left(\int q(z_{\setminus s}) \ln p(y, z) dz_{\setminus s} \right), \quad (144)$$

wobei γ_s eine von z_s unabhängige Normierungskonstante bezeichnet, die evidence lower bound bezüglich $q(z_s)$.

Bemerkungen

- Das Vertauschen der Rollen von $q(z_s)$ und $q(z_{\setminus s})$ maximiert die ELBO bezüglich $q(z_{\setminus s})$, was einen koordinatenweisen ELBO-Maximierungsansatz impliziert.
- Die funktionale Form der maximierenden variationalen Verteilungen hängt von der rechten Seite der Proportionalitätsaussage ab, daher „free-form“.

Beweis

Unten zeigen wir, dass für eine Mean-field-Approximation $q(z) = q(z_s)q(z_{\setminus s})$ die ELBO umgeschrieben werden kann als

$$\text{ELBO}(q(z_s), q(z_{\setminus s})) = -\text{KL} \left(q(z_s) \parallel \frac{1}{\gamma_s} \exp \left(\int q(z_{\setminus s}) \ln p(y, z) dz_{\setminus s} \right) \right) - c, \quad (145)$$

wobei $c \in \mathbb{R}$ eine Konstante ist, die nicht von $q(z_s)$ abhängt. Die Maximierung dieser negativen KL-Divergenz durch Setzen von

$$q(z_s) := \frac{1}{\gamma_s} \exp \left(\int q(z_{\setminus s}) \ln p(y, z) dz_{\setminus s} \right) \quad (146)$$

maximiert somit $\text{ELBO}(q(z_s)q(z_{\setminus s}))$ bezüglich $q(z_s)$.

Beweis (Fortsetzung)

ELBO-Umformulierung

$$\begin{aligned} & \text{ELBO}(q(z_s), q(z_{\setminus s})) \\ &= \iint q(z_s)q(z_{\setminus s}) \ln \left(\frac{p(y, z)}{q(z_s)q(z_{\setminus s})} \right) dz_s dz_{\setminus s} \\ &= \iint q(z_s)q(z_{\setminus s}) (\ln p(y, z) - \ln q(z_s) - \ln q(z_{\setminus s})) dz_s dz_{\setminus s} \\ &= \iint q(z_s)q(z_{\setminus s}) (\ln p(y, z) - \ln q(z_s)) dz_s dz_{\setminus s} - \iint q(z_s)q(z_{\setminus s}) \ln q(z_{\setminus s}) dz_s dz_{\setminus s} \\ &= \iint q(z_s)q(z_{\setminus s}) (\ln p(y, z) - \ln q(z_s)) dz_s dz_{\setminus s} - \int q(z_{\setminus s}) \ln q(z_{\setminus s}) \left(\int q(z_s) dz_s \right) dz_{\setminus s} \\ &= \iint q(z_s)q(z_{\setminus s}) (\ln p(y, z) - \ln q(z_s)) dz_s dz_{\setminus s} - \int q(z_{\setminus s}) \ln q(z_{\setminus s}) dz_{\setminus s} \\ &= \iint q(z_s)q(z_{\setminus s}) \ln p(y, z) dz_s dz_{\setminus s} - \iint q(z_s)q(z_{\setminus s}) \ln q(z_s) dz_s dz_{\setminus s} + c_1 \end{aligned}$$

Beweis (Fortsetzung)

$$\begin{aligned}
 &= \int q(z_s) \left(\int q(z_{\setminus s}) \ln p(y, z) dz_{\setminus s} \right) dz_s - \int q(z_s) \ln q(z_s) \left(\int q(z_{\setminus s}) dz_{\setminus s} \right) dz_s + c_1 \\
 &= \int q(z_s) \left(\int q(z_{\setminus s}) \ln p(y, z) dz_{\setminus s} \right) dz_s - \int q(z_s) \ln q(z_s) dz_s + c_1 \\
 &= \int q(z_s) \left(\int q(z_{\setminus s}) \ln p(y, z) dz_{\setminus s} \right) dz_s - \int q(z_s) \ln q(z_s) dz_s + \int q(z_s) \ln \gamma_s dz_s - \int q(z_s) \ln \gamma_s dz_s + c_1 \\
 &= \int q(z_s) \left(\int q(z_{\setminus s}) \ln p(y, z) dz_{\setminus s} - q(z_s) \ln q(z_s) - q(z_s) \ln \gamma_s \right) dz_s + c_2 \\
 &= \int q(z_s) \left(\int q(z_{\setminus s}) \ln p(y, z) dz_{\setminus s} - \ln q(z_s) - \ln \gamma_s \right) dz_s + c_2 \\
 &= \int q(z_s) \left(\ln \left(\exp \left(\int q(z_{\setminus s}) \ln p(y, z) dz_{\setminus s} \right) \right) - \ln q(z_s) - \ln \gamma_s \right) dz_s + c_2 \\
 &= \int q(z_s) \left(\ln \left(\frac{\frac{1}{\gamma_s} \exp \left(\int q(z_{\setminus s}) \ln p(y, z) dz_{\setminus s} \right)}{q(z_s)} \right) \right) dz_s + c_2 \\
 &= - \int q(z_s) \left(\ln \left(\frac{q(z_s)}{\frac{1}{\gamma_s} \exp \left(\int q(z_{\setminus s}) \ln p(y, z) dz_{\setminus s} \right)} \right) \right) dz_s + c_2 \\
 &= -\text{KL} \left(q(z_s) \parallel \frac{1}{\gamma_s} \exp \left(\int q(z_{\setminus s}) \ln p(y, z) dz_{\setminus s} \right), \right) + c_2
 \end{aligned}$$

wobei wir definiert haben

$$c_1 := - \int q(z_{\setminus s}) \ln q(z_{\setminus s}) dz_{\setminus s} \text{ und } c_2 := c_1 + \int q(z_s) \ln \gamma_s dz_s = c_1 + \ln \gamma_s. \quad (147)$$

Definition (Coordinate-ascent variational inference (CAVI))

Sei $p(y, z)$ ein probabilistisches Modell, das beobachtbare Zufallsvariablen $v = (v_1, \dots, v_n)$ und latente Zufallsvariablen $\zeta = (\zeta_1, \dots, \zeta_m)$ umfasst. Sei $q(z)$ die Dichte-/Wahrscheinlichkeitsfunktion einer variationalen Verteilung und angenommen, dass $q(z)$ binär faktorisiert. Dann maximiert der folgende Algorithmus, bezeichnet als *coordinate-ascent variational inference*, die evidence lower bound:

Initialisierung

(0) Initialisiere $q^{(0)}(z_s)$ und $q^{(0)}(z_{\setminus s})$ angemessen, z.B. durch Setzen von $q^{(0)}(z_s) := \int p(z) dz_{\setminus s}$ und $q^{(0)}(z_{\setminus s}) := \int p(z) dz_s$, werte $\text{ELBO}(q^{(0)}(z_s)q^{(0)}(z_{\setminus s}))$ aus und wähle ein Konvergenzkriterium $\delta > 0$.

Für $i = 0, 1, 2, \dots$ bis $|\text{ELBO}(q^{(i+1)}(z_s)q^{(i+1)}(z_{\setminus s})) - \text{ELBO}(q^{(i)}(z_s)q^{(i)}(z_{\setminus s}))| < \delta$

(1) Setze $q^{(i+1)}(z_s) := \frac{1}{\gamma_s} \exp\left(\int q^{(i)}(z_{\setminus s}) \ln p(y, z) dz_{\setminus s}\right)$

(2) Setze $q^{(i+1)}(z_{\setminus s}) := \frac{1}{\gamma_{\setminus s}} \exp\left(\int q^{(i+1)}(z_s) \ln p(y, z) dz_s\right)$

(3) Werte $\text{ELBO}(q^{(i+1)}(z_s), q^{(i+1)}(z_{\setminus s}))$ aus.

Gib zurück $p(z|y) \approx q^{(i+1)}(z_s)q^{(i+1)}(z_{\setminus s})$ und $\ln p(y) \approx \text{ELBO}(q^{(i+1)}(z_s)q^{(i+1)}(z_{\setminus s}))$.

Coordinate-ascent variationale Inferenz

Before iteration $i = 1, 2, \dots$

$\text{ELBO} \left(q^{(i)}(z_s), q^{(i)}(z_{\setminus s}) \right)$	$\text{KL}(q^{(i)}(z_s)q^{(i)}(z_{\setminus s}) p(z y))$
---	---

On iteration $i = 1, 2, \dots$

$\text{ELBO} \left(q^{(i+1)}(z_s), q^{(i)}(z_{\setminus s}) \right)$	$\text{KL}(q^{(i+1)}(z_s)q^{(i)}(z_{\setminus s}) p(z y))$
---	---

$\text{ELBO} \left(q^{(i+1)}(z_s), q^{(i+1)}(z_{\setminus s}) \right)$	$\text{KL}(q^{(i+1)}(z_s)q^{(i+1)}(z_{\setminus s}) p(z y))$
---	---

Upon convergence

$$\ln p(y) \approx \text{ELBO} \left(q^{(i+1)}(z_s), q^{(i+1)}(z_{\setminus s}) \right) \text{ and } p(z|y) \approx q^{(i+1)}(z_s)q^{(i+1)}(z_{\setminus s})$$

Definition (Fixed-form variationale Inferenz)

Sei $p(y, z)$ ein probabilistisches Modell, das beobachtbare Zufallsvariablen $v = (v_1, \dots, v_n)$ und latente Zufallsvariablen $\zeta = (\zeta_1, \dots, \zeta_m)$ umfasst. Sei $q_\theta(z)$ die Dichte-/Wahrscheinlichkeitsfunktion einer variationalen Verteilung von vordefinierter parametrischer Form mit Parameter $\theta \in \Theta$. Angenommen weiter, dass das resultierende Integral der evidence lower bound

$$\text{ELBO}(q_\theta(z)) = \int q_\theta(z) \ln \left(\frac{p(y, z)}{q_\theta(z)} \right) dz \quad (148)$$

analytisch ausgewertet oder zumindest analytisch approximiert werden kann. Dann nimmt die evidence lower bound die Form einer reellwertigen Funktion an

$$f : \Theta \rightarrow \mathbb{R}, \theta \mapsto f(\theta) := \text{ELBO}(q_\theta(z)) \quad (149)$$

Die Maximierung von f bezüglich θ maximiert somit die (approximative) evidence lower bound.

Bemerkung

- Die funktionale Form der variationalen Verteilung ist vordefiniert, zum Beispiel

$$q(z) := N(z; \theta_q, \Sigma_q), \quad (150)$$

daher „fixed-form“.

- Im Kontext des Free-Energy-Prinzips/Active Inference wird die Verwendung Gaußscher Verteilungen als variationale Verteilungen oft als *Variational Laplace* bezeichnet.

Definition (Gamma-Zufallsvariable)

Sei ξ eine Zufallsvariable mit Ergebnisraum $\mathcal{X} := \mathbb{R}_{>0}$ und Dichtefunktion

$$p : \mathbb{R}_{>0} \rightarrow \mathbb{R}_{>0}, x \mapsto p(x) := \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} \exp\left(-\frac{x}{\beta}\right), \quad (151)$$




wobei Γ die Gammafunktion bezeichnet. Dann heißt ξ gemäß einer *Gamma-Verteilung mit Formparameter $\alpha > 0$ und Skalenparameter $\beta > 0$* verteilt, wofür wir $\xi \sim G(\alpha, \beta)$ schreiben. Wir bezeichnen die Dichtefunktion einer gammaverteilten Zufallsvariable mit

$$G(x; \alpha, \beta) := \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} \exp\left(-\frac{x}{\beta}\right). \quad (152)$$

Bemerkung

- $G\left(\frac{n}{2}, 2\right)$ wird auch als χ^2 -Verteilung mit Freiheitsgradparameter n bezeichnet.

Dichtefunktionen der Gamma-Verteilung



Definition (Das allgemeine lineare Modell)

Sei

$$y = X\beta + \varepsilon, \quad (153)$$

wobei

- y einen n -dimensionalen beobachtbaren Zufallsvektor bezeichnet, der als *Daten* bezeichnet wird,
- die Matrix $X \in \mathbb{R}^{n \times p}$ mit $p \leq n$ als *Designmatrix* bezeichnet wird,
- der Vektor $\beta \in \mathbb{R}^p$ als *Beta-Parametervektor* bezeichnet wird, und
- ε einen n -dimensionalen Zufallsvektor bezeichnet, der als *Zufallsfehler* bezeichnet wird, mit

$$\varepsilon \sim N(0_n, \sigma^2 I_n) \text{ und } \sigma^2 > 0. \quad (154)$$

Dann wird (153) als *allgemeines lineares Modell in generativer Form* bezeichnet.

Bemerkungen

- Zur Erinnerung: Im frequentistischen Setting impliziert das GLM $p(y) = N(y; X\beta, \sigma^2 I_n)$.
- Zur Erinnerung: $X := 1_n \in \mathbb{R}^{n \times 1}$ und $\beta := \mu \in \mathbb{R}$ entspricht n i.i.d. Stichproben einer univariaten Gauß-Verteilung.

Definition (Gauß-Gamma-Regressionsmodell)

Das *Gauß-Gamma-Regressionsmodell* ist ein probabilistisches Modell in Dichteform

$$p(y, \beta, \lambda) = p(y|\beta, \lambda)p(\beta)p(\lambda), \quad (155)$$

wobei

$$p(y|\beta, \lambda) := N(y; X\beta, \lambda^{-1}I_n), \quad p(\beta) := N(\beta; 0_p, \alpha^{-1}I_p), \quad p(\lambda) := G(\lambda; \beta_\lambda, \gamma_\lambda), \quad (156)$$

wobei y ein n -dimensionaler beobachteter Zufallsvektor ist, der Daten modelliert, β ein p -dimensionaler unbeobachteter Zufallsvektor von Regressionsgewichten ist, $\lambda > 0$ eine unbeobachtete Zufallsvariable ist, die die Datenrauschpräzision modelliert, $X \in \mathbb{R}^{n \times p}$ eine Designmatrix ist, und $\alpha, \beta_\lambda, \gamma_\lambda > 0$ Hyperparameter sind.

Bemerkungen

- Der unbeobachtbare Zufallsvektor nimmt die Form $z = (\beta, \lambda)$ an.
- Das Modell ist ein exemplarisches nicht-konjugiertes Bayesianisches Regressionsmodell.

Theorem (Free-form VI für das Gauß-Gamma-Modell)

Die Anwendung des Theorems der free-form Mean-field-Variationsinferenz auf das Gauß-Gamma-Modell für die Mean-field-Approximation

$$q(\beta, \lambda) := q(\beta)q(\lambda) \quad (157)$$

liefert den folgenden CAVI-Algorithmus:

Initialisierung

0. Setze

$$q^{(0)}(\beta) := N(\beta; m_\beta^{(0)}, S_\beta^{(0)}) \text{ und } q^{(0)}(\lambda) := G(\lambda; b_\lambda^{(0)}, c_\lambda^{(0)}) \quad (158)$$

mit Variationsparametern

$$m_\beta^{(0)} := 0_p, S_\beta^{(0)} := \alpha^{-1} I_p \text{ und } b_\lambda^{(0)} := \beta_\lambda, c_\lambda^{(0)} := \frac{n}{2} + \gamma_\lambda, \quad (159)$$

jeweils. Definiere ein Konvergenzkriterium $\Delta\text{ELBO} > 0$ und eine maximale Anzahl von Iterationen n_i .

Theorem (Free-form VI für das Gauß-Gamma-Modell (Fortsetzung))

Iterationen

Für $i = 1, \dots, n_i$ oder bis Konvergenz erreicht ist

1. $q(\beta)$ -Update

Setze

$$q^{(i)}(\beta) := N\left(\beta; m_{\beta}^{(i)}, S_{\beta}^{(i)}\right), \quad (160)$$

wobei

$$S_{\beta}^{(i)} := \left(b_{\lambda}^{(i-1)} c_{\lambda}^{(i-1)} X^T X + \alpha I_p\right)^{-1} \quad \text{und} \quad m_{\beta}^{(i)} := b_{\lambda}^{(i-1)} c_{\lambda}^{(i-1)} S_{\beta}^{(i)} X^T y. \quad (161)$$

2. $q(\lambda)$ -Update

Setze

$$q^{(i)}(\lambda) := G\left(\lambda; b_{\lambda}^{(i)}, c_{\lambda}^{(i)}\right), \quad (162)$$

wobei

$$b_{\lambda}^{(i)} := \left(\frac{1}{2} \left(\text{tr}\left(S_{\beta}^{(i)} X^T X\right) + \left(y - X m_{\beta}^{(i)}\right)^T \left(y - X m_{\beta}^{(i)}\right)\right) + \frac{1}{\beta_{\lambda}}\right)^{-1} \quad (163)$$

und

$$c_{\lambda}^{(i)} := \frac{n}{2} + \gamma_{\lambda}. \quad (164)$$

Beachte, dass $c_{\lambda}^{(i)}$ durchgehend konstant bleibt.

Theorem (Free-form VI für das Gauß-Gamma-Modell (Fortsetzung))

3. ELBO $(q(\beta), q(\lambda))$ -Update

Setze

$$\text{ELBO}^{(i)} := \text{ELBO} \left(q^{(i)}(\beta), q^{(i)}(\lambda) \right), \quad (165)$$

wobei

$$\text{ELBO} \left(q^{(i)}(\beta) q^{(i)}(\lambda) \right) := L_a^{(i)} - \text{KL} \left(q^{(i)}(\beta) \| p(\beta) \right) - \text{KL} \left(q^{(i)}(\lambda) \| p(\lambda) \right), \quad (166)$$

wobei mit der Digamma-Funktion ψ , $L_a^{(i)}$ den durchschnittlichen Likelihood-Term bezeichnet

$$L_a^{(i)} := -\frac{n}{2} \ln 2\pi - \frac{1}{2} b_\lambda^{(i)} c_\lambda^{(i)} \left(y - X m_\beta^{(i)} \right)^T \left(x - X m_\beta^{(i)} \right) \quad (167)$$

$$- \frac{1}{2} b_\lambda^{(i)} c_\lambda^{(i)} \text{tr} \left(S_\beta^{(i)} X^T X \right) + \frac{n}{2} \psi \left(c_\lambda^{(i)} \right) + \ln b_\lambda^{(i)} \quad (168)$$

4. Konvergenzbeurteilung

Falls $i > 1$, werte $\Delta \text{ELBO} = \text{ELBO}^{(i)} - \text{ELBO}^{(i-1)}$ aus. Dann, falls $\Delta \text{ELBO} < 0$, gib eine Warnung aus und beende den Algorithmus, falls $0 < \Delta \text{ELBO} < \delta$, beende den Algorithmus und erkläre Konvergenz, andernfalls gehe zu 1.

Bemerkungen



- Für eine Herleitung des Algorithmus siehe Penny et al. (2003).

Beispiel

[1] 1.694612 2.575781 2.738325 2.487429 1.179532 2.329508 3.595281 1.164371

[9] 2.183643 1.373546


Beispiel



— Prior-Dichte, • Wahrer, aber unbekannter Wert

Beispiel

Beispiel



- Wahrer, aber unbekannter Wert, — Prior-Dichte, — Posterior-Dichte, • posteriorer Erwartungswert.

- Penny, W., Kiebel, S., & Friston, K. (2003). Variational Bayesian inference for fMRI time series. *NeuroImage*, 19(3), 727–741. [https://doi.org/10.1016/S1053-8119\(03\)00071-5](https://doi.org/10.1016/S1053-8119(03)00071-5)
- Piessens, R., de Doncker-Kapenga, E., Überhuber, C. W., & Kahaner, D. K. (1983). *Quadpack* (Vol. 1). Springer Berlin Heidelberg. <https://doi.org/10.1007/978-3-642-61786-7>