



Psychometrische Diagnostik

MSc Psychologie

MSc Umweltpsychologie / Mensch-Technik-Interaktion

SoSe 2026

Prof. Dr. Dirk Ostwald

(6) Modellvergleichskriterien

Kriterium	Formel	Approximand	Referenz
AIC	$-2\ell(\hat{\theta}_n) + 2k$	$-2 \mathbb{E}_{\tilde{y}}(\ln p(\tilde{y} \mid y))$	Akaike (1974)
AICc	$-2\ell(\hat{\theta}_n) + 2k + \frac{2k(k+1)}{n-k-1}$	$-2 \mathbb{E}_{\tilde{y}}(\ln p(\tilde{y} \mid y))$	Hurvich und Tsai (1989)
BIC	$-2\ell(\hat{\theta}_n) + k \ln(n)$	$-2 \ln p(y)$	Schwarz (1978)
SABIC	$-2\ell(\hat{\theta}_n) + k \ln\left(\frac{n+2}{24}\right)$	$-2 \ln p(y)$	Sclove (1987)
CAIC	$-2\ell(\hat{\theta}_n) + k (\ln(n) + 1)$	$-2 \ln p(y)$	Bozdogan (1987)

Definition (Kullback-Leibler-Informationskriterium)

y sei ein $d \times 1$ -dimensionaler Datenvektor mit wahrer, aber unbekannter Wahrscheinlichkeitsdichtefunktion g und p_θ sei die WDF eines parametrischen Inferenzmodells für die Verteilung von y mit Parametervektor $\theta \in \Theta \subseteq \mathbb{R}^k$. Dann wird die Kullback-Leibler-Divergenz von g und p_θ als Funktion von θ ,

$$K : \Theta \rightarrow [0, \infty[, \theta \mapsto K(\theta) := \text{KL}(g||p_\theta) = \int g(y) \ln \left(\frac{g(y)}{p_\theta(y)} \right) dy, \quad (1)$$

als *Kullback-Leibler-Informationskriterium (KLIC)* bezeichnet.

Bemerkung

- Für festes g hängt K sowohl von θ als auch von der Modellklasse $\{p_\theta : \theta \in \Theta\}$ ab.
- Intuitiv misst K unsere Unwissenheit über die wahre, aber unbekannte, Verteilung g .

Theorem (Zerlegung des Kullback-Leibler-Informationskriteriums)

Das Kullback-Leibler-Informationskriterium kann äquivalent geschrieben werden als

$$K(\theta) = -\mathbb{H}(g) - \mathbb{E}_g(\ln p_\theta(y)), \quad (2)$$

wobei

$$\mathbb{H}(g) := - \int g(y) \ln g(y) dy \quad (3)$$

die *differentielle Entropie der wahren, aber unbekannten Verteilung von y* bezeichnet und

$$\mathbb{E}_g(\ln p_\theta(y)) := \int g(y) \ln p_\theta(y) dy \quad (4)$$

der *erwartete Log-Likelihood-Wert unter der generativen Verteilung* ist.

Beweis

Es gilt

$$K(\theta) = \int g(y) \ln \left(\frac{g(y)}{p_\theta(y)} \right) dy = \int g(y) \ln g(y) dy - \int g(y) \ln p_\theta(y) dy = -\mathbb{H}(g) - \mathbb{E}_g(\ln p_\theta(y)).$$

□

Definition (KLIC-Minimierer)

Für g und p_θ sei K das Kullback-Leibler-Informationskriterium. Dann heißt eine Minimalstelle von K ,

$$\theta_* \in \arg \min_{\theta \in \Theta} K(\theta), \quad (5)$$

KLIC-Minimierer.

Bemerkung

- θ_* ist der Parameterwert, für den p_θ der wahren, aber unbekannten Verteilung g am nächsten kommt.
- Da $-\mathbb{H}(g)$ nicht von θ abhängt, ist die Minimierung von $K(\theta)$ äquivalent zur Maximierung von $\mathbb{E}_g(\ln p_\theta(y))$.

Definition (Maximum-Likelihood-Schätzer)

p_θ sei die WDF eines parametrischen Inferenzmodells für die Verteilung eines Datenvektors y . Für die gemeinsame WDF π_θ einer Stichprobe $y_1, \dots, y_n$ gelte

$$\pi_\theta(y_1, \dots, y_n) = \prod_{i=1}^n p_\theta(y_i). \quad (6)$$

Dann heißt

$$\ell_n : \Theta \rightarrow \mathbb{R}, \theta \mapsto \ell_n(\theta) := \frac{1}{n} \sum_{i=1}^n \ln p_\theta(y_i) \quad (7)$$

die *normierte Log-Likelihood-Funktion* von $y_1, \dots, y_n$ und

$$\hat{\theta}_n \in \arg \max_{\theta \in \Theta} \ell_n(\theta) \quad (8)$$

heißt ein *Maximum-Likelihood-Schätzer* von θ .

Bemerkungen

- Da ℓ_n eine Funktion von $y_1, \dots, y_n$ ist, ist $\hat{\theta}_n$ eine Funktion von $y_1, \dots, y_n$, mnemonisch

$$\hat{\theta}_n = \hat{\theta}_n(y_1, \dots, y_n). \quad (9)$$

- Die Normierung mit $1/n$ ändert den Maximierer nicht, erleichtert aber die asymptotische Darstellung.

Theorem (Eigenschaften eines Maximum-Likelihood-Schätzers)

Die WDF der gemeinsamen Verteilung von Datenvektor $y_1, \dots, y_n$ unter einem Inferenzmodell p_θ sei

$$\pi_\theta(y_1, \dots, y_n) = \prod_{i=1}^n p_\theta(y_i). \quad (10)$$

Sei $\hat{\theta}_n$ ein Maximum-Likelihood-Schätzer des wahren, aber unbekannten, Parameters θ_0 . Dann gelten:

- (1) $\hat{\theta}_n$ ist ein konsistenter Schätzer von θ_0 , also

$$\lim_{n \rightarrow \infty} \mathbb{P}(\|\hat{\theta}_n - \theta_0\| > \epsilon) = 0 \quad \Leftrightarrow \quad \hat{\theta}_n \xrightarrow{P} \theta_0 \quad \text{für } n \rightarrow \infty. \quad (11)$$

- (2) $\hat{\theta}_n$ ist asymptotisch normalverteilt. Speziell gelten mit

$$S(\theta) := \nabla_\theta \ln p_\theta(y) \text{ und } I(\theta) := \mathbb{E}_{p_\theta(y)}(S(\theta)S(\theta)^T) \quad (12)$$

dass

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \overset{a}{\sim} N(0_k, I(\theta_0)^{-1}). \quad (13)$$

Bemerkungen

- Für einen Beweis verweisen wir auf Konishi & Kitagawa (2008), Abschnitt 3.3.

Definition (Quasi-Maximum-Likelihood-Schätzer)

g sei die wahre, aber unbekannte WDF der Verteilung von n unabhängige verteilten Datenvektoren $y_1, \dots, y_n$, so dass für die gemeinsame WDF γ der $y_1, \dots, y_n$ gilt, dass

$$\gamma(y_1, \dots, y_n) = \prod_{i=1}^n g(y_i). \quad (14)$$

p_θ sei die WDF eines parametrischen Inferenzmodells für die Verteilung eines solchen y_i und für die gemeinsame WDF π_θ der $y_1, \dots, y_n$ unter diesem Inferenzmodell gelte ebenfalls

$$\pi_\theta(y_1, \dots, y_n) = \prod_{i=1}^n p_\theta(y_i). \quad (15)$$

Dann heißt

$$\ell_n : \Theta \rightarrow \mathbb{R}, \quad \theta \mapsto \ell_n(\theta) := \frac{1}{n} \sum_{i=1}^n \ln p_\theta(y_i) \quad (16)$$

die *Quasi-Log-Likelihood-Funktion* von $y_1, \dots, y_n$ und

$$\hat{\theta}_n \in \arg \max_{\theta \in \Theta} \ell_n(\theta) \quad (17)$$

heißt ein *Quasi-Maximum-Likelihood-Schätzer* von θ .

Bemerkung

- Da ℓ_n eine Funktion von $y_1, \dots, y_n$ ist, ist $\hat{\theta}_n$ eine Funktion von $y_1, \dots, y_n$, mnemonisch

$$\hat{\theta}_n = \hat{\theta}_n(y_1, \dots, y_n). \quad (18)$$

Theorem (Eigenschaften eines Quasi-Maximum-Likelihood-Schätzers)

Die wahre, aber unbekannte WDF der gemeinsamen Verteilung von Datenvektoren $y_1, \dots, y_n$ sei gegeben durch

$$\gamma(y_1, \dots, y_n) = \prod_{i=1}^n g(y_i). \quad (19)$$

Das parametrische Inferenzmodell sei

$$\pi_\theta(y_1, \dots, y_n) = \prod_{i=1}^n p_\theta(y_i). \quad (20)$$

Sei θ_* der eindeutige KLIC-Minimierer und $\hat{\theta}_n$ ein Quasi-Maximum-Likelihood-Schätzer. Dann gelten:

- (1) $\hat{\theta}_n$ ist ein konsistenter Schätzer von θ_* , also

$$\lim_{n \rightarrow \infty} \mathbb{P}(\|\hat{\theta}_n - \theta_*\| > \epsilon) = 0 \quad \Leftrightarrow \quad \hat{\theta}_n \xrightarrow{P} \theta_* \quad \text{für } n \rightarrow \infty. \quad (21)$$

- (2) $\hat{\theta}_n$ ist asymptotisch normalverteilt. Speziell gelten mit

$$S(\theta) := \nabla_\theta \ln p_\theta(y), I(\theta) := \mathbb{E}_{g(y)}(S(\theta)S(\theta)^T) \quad \text{und} \quad J(\theta) := -\mathbb{E}_{g(y)}(\nabla_\theta^2 \ln p_\theta(y)),$$

gilt

$$\sqrt{n}(\hat{\theta}_n - \theta_*) \xrightarrow{d} \mathcal{N}(0_k, J(\theta_*)^{-1} I(\theta_*) J(\theta_*)^{-1}). \quad (22)$$

Bemerkungen

- Für einen Beweis verweisen wir auf Konishi & Kitagawa (2008), Abschnitt 3.3.

Definition (KLIC-basiertes Modellvergleichskriterium)

g sei die WDF der wahren, aber unbekannten Verteilung eines $d \times 1$ -dimensionalen Datenvektors y , p_θ sei die WDF eines parametrischen Inferenzmodells für y mit Parametervektor $\theta \in \Theta \subseteq \mathbb{R}^k$ und $\hat{\theta}_n$ sei ein Quasi-Maximum-Likelihood-Schätzer von θ . Dann gilt für y unabhängig von $y_1, \dots, y_n$

$$K(\hat{\theta}_n) = -\mathbb{H}(g) - \mathbb{E}_{g(y)} \left(\ln p_{\hat{\theta}_n}(y) \right). \quad (23)$$

und

$$K := \mathbb{E}_{g(y)} \left(\ln p_{\hat{\theta}_n}(y) \right) = \int g(y) \ln p_{\hat{\theta}_n}(y) dy. \quad (24)$$

wird *KLIC-basiertes Modellvergleichskriterium* des frequentistischen Inferenzmodells genannt.

Bemerkung

- Die Wahl von $\hat{\theta}_n \in \Theta$ ist durch seine Konsistenz für θ_* gerechtfertigt.
- $-\mathbb{H}(g)$ ist für beliebige Modelle p_θ identisch.
- Je größer K , desto näher ist Modell $p_{\hat{\theta}_n}$ dem wahren, aber unbekannten Modell g .
- K ist unbekannt und muss geschätzt werden, da g unbekannt ist.

Theorem (MC-Schätzer des KLIC-basierten Modellvergleichskriteriums)

g sei die WDF der wahren, aber unbekannten Verteilung eines $d \times 1$ -dimensionalen Datenvektors y , p_θ sei die WDF eines parametrischen Inferenzmodells für y mit Parametervektor $\theta \in \Theta \subseteq \mathbb{R}^k$ und $\hat{\theta}_n$ sei ein Quasi-Maximum-Likelihood-Schätzer von θ . Dann ist der Monte-Carlo-Schätzer

$$\hat{K} := \ell_n(\hat{\theta}_n) = \frac{1}{n} \sum_{i=1}^n \ln p_{\hat{\theta}_n}(y_i) \quad (25)$$

für das KLIC-basierte Modellvergleichskriterium

$$K := \mathbb{E}_{g(y)} \left(\ln p_{\hat{\theta}_n}(y) \right) \quad (26)$$

ein verzerrter Schätzer von K . Speziell gilt für den Bias $B(\hat{K})$ von $\hat{K}$, dass

$$B(\hat{K}) = \mathbb{E}_{\gamma(y_1, \dots, y_n)} \left(\hat{K} - \mathbb{E}_{g(y)} \left(\ln p_{\hat{\theta}_n}(y) \right) \right) = \frac{1}{n} \mathbb{E}_{\gamma(y_1, \dots, y_n)} \left(\ln \pi_{\hat{\theta}_n}(y_1, \dots, y_n) - n \mathbb{E}_{g(y)} \left(\ln p_{\hat{\theta}_n}(y) \right) \right). \quad (27)$$

und asymptotisch

$$nB(\hat{K}) \rightarrow \text{tr} \left(I(\theta_*) J(\theta_*)^{-1} \right) \quad \text{für } n \rightarrow \infty. \quad (28)$$

Bemerkung

- Für einen Beweis verweisen wir auf Konishi & Kitagawa (2008), Abschnitt 3.4.

Theorem (Akaike Information Criterion)

g sei die WDF der wahren, aber unbekannten Verteilung eines $d \times 1$ -dimensionalen Datenvektors y , p_θ sei die WDF eines parametrischen Inferenzmodells für y mit Parametervektor $\theta \in \Theta \subseteq \mathbb{R}^k$ für ein eindeutiges $\theta_0 \in \Theta$ gelte

$$g(y) = p_{\theta_0}(y). \quad (29)$$

Dann gelten

$$I(\theta_0) = J(\theta_0) \text{ und } \text{tr}(I(\theta_0)J(\theta_0)^{-1}) = k \quad (30)$$

und

$$\text{AIC} := \ell_n(\hat{\theta}_n) - \frac{k}{n} = \frac{1}{n} \sum_{i=1}^n \ln p_{\hat{\theta}_n}(y_i) - \frac{k}{n} \quad (31)$$

ein asymptotisch erwartungstreuer Schätzer von K .

Bemerkung

- Verwendung der unnormierten Log-Likelihood

$$\ell(\hat{\theta}_n) = n\ell_n(\hat{\theta}_n) \quad (32)$$

resultiert in der äquivalenten Minimierungskonvention

$$\text{AIC}_{-2} := -2n \text{AIC} = -2\ell(\hat{\theta}_n) + 2k. \quad (33)$$

Hurvich und Tsai (1989) schlagen eine Korrektur der AIC-Formel vor, um die Verzerrung des AIC-Schätzers für kleine Stichproben zu reduzieren. Das resultierende Kriterium, das als AICc bezeichnet wird, ist definiert als

$$\text{AICc} := \text{AIC} + \frac{2k(k+1)}{n-k-1} = -2\ell(\hat{\theta}_n) + 2k + \frac{2k(k+1)}{n-k-1}. \quad (34)$$

Die AICc-Formel enthält einen zusätzlichen Term, der die Anzahl der Parameter k und die Stichprobengröße n berücksichtigt. Für große Stichproben nähert sich die AICc-Formel der AIC-Formel an, da der zusätzliche Term gegen Null geht. Für kleine Stichproben kann die AICc-Formel jedoch eine bessere Schätzung des KLIC-basierten Modellvergleichskriteriums liefern als die AIC-Formel, da sie die Verzerrung des AIC-Schätzers korrigiert.

Definition (Bayesian Information Criterion (BIC))

Gegeben sei ein Bayesianisches Inferenzmodell mit Parameterraum $\Theta \subseteq \mathbb{R}^k$ und unabhängig und identisch verteilten Beobachtungen $y = (y_1, \dots, y_n)$, sodass die gemeinsame Dichte der Parameter und Daten gegeben ist durch

$$p(\theta, y) = p(\theta)p(y|\theta) = p(\theta) \prod_{i=1}^n p(y_i|\theta), \quad (35)$$

Weiterhin sei

$$\ell : \Theta \rightarrow \mathbb{R}, \theta \mapsto \ell(\theta) := \ln p(y|\theta) \quad (36)$$

die Log-Likelihood-Funktion des Modells, und es sei

$$\hat{\theta}_n \in \arg \max_{\theta \in \Theta} \ell(\theta) \quad (37)$$

eine Maximalstelle dieser Funktion. Dann ist das *Bayesian Information Criterion* definiert als

$$\text{BIC} := \ell(\hat{\theta}_n) - \frac{k}{2} \ln n. \quad (38)$$

Bemerkungen

- Im Anwendungskontext wird häufig folgende Konvention genutzt:

$$\text{BIC}_{-2} := -2\text{BIC} = -2\ell(\hat{\theta}_n) + k \ln n. \quad (39)$$

Theorem (Motivation der BIC-Formel)

Gegeben sei ein probabilistisches Modell mit Parameterraum $\Theta \subseteq \mathbb{R}^k$. Weiterhin sei

$$f : \Theta \rightarrow \mathbb{R}, \theta \mapsto f(\theta) := -\frac{1}{n} (\ln p(y|\theta) + \ln p(\theta)), \quad (40)$$

und sei $\tilde{\theta}$ ein Minimierer von f . Dann ergibt sich aus der Laplace-Approximation der logarithmierten marginalen Likelihood

$$\ln p(y) = \ln \int p(y|\theta)p(\theta) d\theta \quad (41)$$

die Näherung

$$\ln p(y) \approx \frac{k}{2} \ln 2\pi - \frac{k}{2} \ln n - \frac{1}{2} \ln |H^f(\tilde{\theta})| + \ln p(y|\tilde{\theta}) + \ln p(\tilde{\theta}), \quad (42)$$

wobei $H^f(\tilde{\theta})$ die Hesse-Matrix von f an der Stelle $\tilde{\theta}$ bezeichnet. Das BIC erhält aus dieser Näherung durch Vernachlässigung der Terme

$$\frac{k}{2} \ln 2\pi, \quad \ln p(\tilde{\theta}), \quad -\frac{1}{2} \ln |H^f(\tilde{\theta})| \quad (43)$$

sowie durch die asymptotische Ersetzung von $\tilde{\theta}$ durch $\hat{\theta}_n$ und die Identifikation $\ell(\hat{\theta}_n) = \ln p(y|\hat{\theta}_n)$.

Beweis

Wir erinnern zunächst an die Laplace-Approximation von Integralen. Sei dazu $f : \mathbb{R}^k \rightarrow \mathbb{R}$ eine zweimal differenzierbare konvexe Funktion mit einem Minimum bei $\tilde{x} \in \mathbb{R}^k$. Dann besteht die Laplace-Approximation darin, das Integral

$$I_n := \int_{\mathbb{R}^k} \exp(-nf(x)) dx \quad (44)$$

für $n \in \mathbb{N}$ wie folgt zu approximieren:

$$I_n \approx \left(\frac{2\pi}{n} \right)^{\frac{k}{2}} |H^f(\tilde{x})|^{-\frac{1}{2}} \exp(-nf(\tilde{x})), \quad (45)$$

wobei $|H^f(\tilde{x})|$ die Determinante der Hesse-Matrix von f an der Stelle $\tilde{x}$ bezeichnet. Für Motivation und Herleitung der Laplace-Approximation siehe z. B. Lauritzen (2009).

Wir definieren nun die Funktion

$$f : \Theta \rightarrow \mathbb{R}, \theta \mapsto f(\theta) := -\frac{1}{n} (\ln p(y|\theta) + \ln p(\theta)), \quad (46)$$

und bezeichnen mit $\tilde{\theta}$ einen Minimierer von f .

Bayesian Information Criterion

Beweis (fortgeführt)

Dann ergibt sich die Laplace-Approximation der logarithmierten marginalen Likelihood wie folgt:

$$\begin{aligned}\ln p(y) &= \ln \int p(y|\theta)p(\theta) d\theta \\&= \ln \int \exp(\ln(p(y|\theta)p(\theta))) d\theta \\&= \ln \int \exp(\ln p(y|\theta) + \ln p(\theta)) d\theta \\&= \ln \int \exp\left(-n\left(-\frac{1}{n}(\ln p(y|\theta) + \ln p(\theta))\right)\right) d\theta \\&= \ln \int \exp(-nf(\theta)) d\theta \\&\approx \ln\left(\left(\frac{2\pi}{n}\right)^{\frac{k}{2}} |H^f(\tilde{\theta})|^{-\frac{1}{2}} \exp(-nf(\tilde{\theta}))\right) \\&= \frac{k}{2} \ln 2\pi - \frac{k}{2} \ln n - \frac{1}{2} \ln |H^f(\tilde{\theta})| + \ln p(y|\tilde{\theta}) + \ln p(\tilde{\theta}).\end{aligned}$$

Die BIC-Formel ergibt sich schließlich aus der Vernachlässigung der Terme $\frac{k}{2} \ln 2\pi$, $\ln p(\tilde{\theta})$ und $-\frac{1}{2} \ln |H^f(\tilde{\theta})|$ sowie durch die asymptotische Ersetzung von $\tilde{\theta}$ durch $\hat{\theta}_n$ und die Identifikation $\ell(\hat{\theta}_n) = \ln p(y|\hat{\theta}_n)$. Damit folgt

$$\ln p(y) \approx \ell(\hat{\theta}_n) - \frac{k}{2} \ln n = \text{BIC}. \quad (47)$$

SABIC

Schlove (1987) schlägt eine modifizierte Version der BIC-Formel vor, die als Sample-Size Adjusted BIC (SABIC) bezeichnet wird. Die SABIC-Formel lautet

$$\text{SABIC} := \ell(\hat{\theta}_n) - \frac{k}{2} \ln \left(\frac{n+2}{24} \right). \quad (48)$$

Die SABIC-Formel enthält einen modifizierten Strafterm, der die Anzahl der Parameter k und die Stichprobengröße n berücksichtigt. Im Vergleich zur BIC-Formel, die einen Strafterm von $\frac{k}{2} \ln n$ verwendet, verwendet die SABIC-Formel einen Strafterm von $\frac{k}{2} \ln \left(\frac{n+2}{24} \right)$. Diese Modifikation soll die Leistung des BIC-Formel insbesondere bei kleinen Stichproben verbessern, da der modifizierte Strafterm weniger streng ist als der Strafterm der BIC-Formel. Für große Stichproben nähert sich die SABIC-Formel der BIC-Formel an, da der modifizierte Strafterm gegen $\frac{k}{2} \ln n$ geht.

CAIC

Bozdogan (1987) schlägt eine modifizierte Version der BIC-Formel vor, die als Consistent Akaike Information Criterion (CAIC) bezeichnet wird. Die CAIC-Formel lautet

$$\text{CAIC} := \ell(\hat{\theta}_n) - \frac{k}{2} \ln(n+1). \quad (49)$$

Die CAIC-Formel enthält einen modifizierten Strafterm, der die Anzahl der Parameter k und die Stichprobengröße n berücksichtigt. Im Vergleich zur BIC-Formel, die einen Strafterm von $\frac{k}{2} \ln n$ verwendet, verwendet die CAIC-Formel einen Strafterm von $\frac{k}{2} \ln(n+1)$. Diese Modifikation soll die Leistung des BIC-Formel insbesondere bei kleinen Stichproben verbessern, da der modifizierte Strafterm weniger streng ist als der Strafterm der BIC-Formel. Für große Stichproben nähert sich die CAIC-Formel der BIC-Formel an, da der modifizierte Strafterm gegen $\frac{k}{2} \ln n$ geht.

Konishi, S., & Kitagawa, G. (2008). *Information criteria and statistical modeling*. Springer.

Lauritzen, S. (2009). *Laplace's Method of Integration* (available from <http://www.stats.ox.ac.uk/~steffen/teaching/bs2HT9/laplace.pdf>).